



RÉPUBLIQUE ALGÉRIENNE DÉMOCRATIQUE ET POPULAIRE



Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

UNIVERSITÉ DES SCIENCES ET DE LA TECHNOLOGIE HOUARI BOUMEDIENE

Faculté d'Informatique

Département des Systèmes Informatiques

MÉMOIRE DE MASTER

Spécialité

RÉSEAU ET SYSTÈMES DISTRIBUÉS

Thème

Conception et déploiement d'une infrastructure
Cloud privée hyperconvergée basée sur
des technologies open source

Proposé et Dirigé par :

Mr. Neffah Mohammed

Prof. MERAZKA Fatiha

Réalisé et présenté par :

Mr. Bouzara Zakaria

Mr. Ouacherine Ilyes

Devant le jury composé de :

Mme. Mahdaoui Latifa

Mr. Chibani Said

Soutenu le : 17/06/2026

Binôme N° RSD-18/2026

Remerciements

Avant tout, nous rendons grâce à Allah, le Tout-Puissant, de nous avoir accordé la volonté, la patience et la clarté d'esprit nécessaires pour mener ce travail à son terme.

Nous souhaitons exprimer notre reconnaissance à Sonatrach, qui nous a ouvert ses portes pour ce stage de fin d'études et nous a offert un environnement professionnel dans lequel apprendre avait un sens concret.

*Nous remercions chaleureusement **Mme Merazka Fatiha**, notre co-encadrante pédagogique, pour ses conseils avisés et son suivi rigoureux, qui ont contribué à donner à ce mémoire sa cohérence académique.*

*Nos remerciements les plus sincères vont à **M. Neffah Mohammed** et **M. Soukeur Seif Eddine**, notre encadrant et co-encadrant au sein de Sonatrach, pour leur disponibilité, leurs orientations techniques et le soin qu'ils ont mis à nous guider à chaque étape du projet.*

*Une mention particulière à **Mme Benali Nawel**, dont les aides répétées, toujours apportées avec générosité, nous ont été précieuses à plus d'une occasion.*

*Nous adressons nos remerciements aux membres du jury, **Mme Mahdaoui Latifa** et **M. Chibani Saïd**, pour le temps qu'ils ont consacré à l'évaluation de ce travail et pour la rigueur de leur regard.*

Nous tenons également à nous remercier l'un l'autre, pour la bienveillance, la persévérance et la bonne humeur que chacun a su maintenir jusqu'au bout. Ce fut un vrai plaisir de travailler ensemble sur ce projet.

À tous ces intervenants, nous présentons nos sincères remerciements, notre respect et notre gratitude.

Dédicace

À Allah, le Tout Miséricordieux, pour Ses bienfaits et Sa grâce infinie qui m'ont guidé tout au long de ce parcours.

À mes parents et ma sœur qui m'ont soutenu et encouragé tout au long de ma vie. Votre amour, votre dévouement et vos sacrifices ont façonné la personne que je suis aujourd'hui. Je vous dédie ce travail en témoignage de ma gratitude du fond du cœur.

*À toute ma famille, qui ont toujours été présents à mes côtés. Qu'ils trouvent ici l'expression des liens profonds qui nous unissent. Une mention toute particulière à mes cousins **Baroud Raïd** et **Bouzara Tarek**, pour son soutien et sa présence indéfectible.*

À mes amis et collègues de promotion, une équipe qui a su traverser les obstacles avec persévérance et solidarité.

*À mes colocataires et amis **Ferhat abderrahmane**, **Berkani Abdelkader** et **Mira Mohamed Lamine**, pour leurs encouragements constants, leur aide précieuse dans la rédaction de ce mémoire et leur présence à chaque étape de ce travail. Votre soutien a compté bien plus que vous ne le pensez.*

À tous ceux qui osent rêver, persévérer et repousser leurs limites.

Dédicace

À Allah, le Tout Miséricordieux, pour Sa grâce et Sa guidance qui ont illuminé chaque étape de ce parcours.

À mes parents, pour tout ce qu'ils ont donné sans jamais le formuler comme un sacrifice. Chaque effort que j'ai fourni durant ces cinq années portait en lui une part de leur soutien silencieux. Ce travail leur appartient autant qu'à moi.

À mes frères et sœurs, pour les moments partagés, les encouragements lancés en passant, et cette chaleur familiale qui rend les longues nuits de travail un peu plus légères.

*À tous mes amis, qui ont jalonné ce parcours de leurs présences, leurs mots et leurs gestes, souvent simples, toujours précieux. Une mention toute particulière à **O. Houdhaifa, Kh. Adel** et **H. Ghiles**, pour une amitié franche, sans détour, qui ne s'est jamais démentie même dans les moments difficiles. Vous savez ce que vous représentez.*

À mon binôme, pour la patience, la rigueur et la bonne humeur qu'il a su garder du début à la fin. Ce projet, on l'a construit ensemble.

À tous ceux qui osent commencer quelque chose sans savoir comment ça finira, et qui continuent quand même.

Table des matières

Table des figures

Liste des tableaux

Liste des abréviations

API	: Application Programming Interface
BIOS	: Basic Input/Output System
BSD	: Berkeley Software Distribution
CD	: Continuous Deployment
CI	: Continuous Integration
CLI	: Command Line Interface
CSLB	: Central Scheduler Load Balancing
CPU	: Central Processing Unit
CRUSH	: Controlled Replication Under Scalable Hashing
CSLB	: Central Scheduler Load Balancing
DHCP	: Dynamic Host Configuration Protocol
DMZ	: DeMilitarized Zone
DNS	: Domain Name System
DRS	: Distributed Resource Scheduler
EC	: Erasure Coding
FTP	: File Transfer Protocol
GRE	: Generic Routing Encapsulation
GUI	: Graphical User Interface
HA	: High Availability
HCI	: Hyper Converged Infrastructure
HPC	: High Performance Computing
HTTP	: HyperText Transfer Protocol
HTTPS	: HyperText Transfer Protocol Secure
I/O	: Input / Output
ICMP	: Internet Control Message Protocol
IP	: Internet Protocol
ISO	: International Organization for Standardization (image disque)
KPI	: Key Performance Indicator
KVM	: Kernel-based Virtual Machine
LACP	: Link Aggregation Control Protocol
LAN	: Local Area Network
LDAP	: Lightweight Directory Access Protocol
LXC	: Linux Containers
MDS	: MetaData Server
MGR	: Manager
MON	: Monitor
NAT	: Network Address Translation
NIC	: Network Interface Card
NTP	: Network Time Protocol
OS	: Operating System

OSD	: Object Storage Daemon
OVMF	: Open Virtual Machine Firmware
OVS	: Open Virtual Switch
PBS	: Proxmox Backup Server
PC	: Personal Computer
PG	: Placement Group
PVE	: Proxmox Virtual Environment
PXE	: Preboot eXecution Environment
QEMU	: Quick EMUlator
QoS	: Quality of Service
RADOS	: Reliable Autonomic Distributed Object Store
RAM	: Random Access Memory
RBD	: RADOS Block Device
REST	: Representational State Transfer
RSD	: Réseau Et Systèmes Distribués
RTO	: Recovery Time Objective
SAN	: Storage Area Network
SAS	: Serial Attached SCSI
SCSI	: Small Computer System Interface
SDN	: Software Defined Networking
SFTP	: SSH File Transfer Protocol
SIEM	: Security Information and Event Management
SMTP	: Simple Mail Transfer Protocol
SPOF	: Single Point Of Failure
SSH	: Secure Shell
TCO	: Total Cost of Ownership
TCP	: Transmission Control Protocol
TFTP	: Trivial File Transfer Protocol
TLS	: Transport Layer Security
UDP	: User Datagram Protocol
UEFI	: Unified Extensible Firmware Interface
USB	: Universal Serial Bus
vCPU	: Virtual Central Processing Unit
VE	: Virtual Environment
VLAN	: Virtual Local Area Network
VM	: Virtual Machine
VNI	: VXLAN Network Identifier
VPN	: Virtual Private Network
VxLAN	: Virtual eXtensible LAN
WAL	: Write-Ahead Log
WAN	: Wide Area Network

Introduction générale

L'infrastructure informatique des grandes entreprises repose aujourd'hui sur trois piliers : le calcul, le stockage et le réseau. Pendant longtemps, chacun de ces piliers était géré par des équipements spécialisés distincts, ce qui entraînait une complexité administrative et des coûts élevés. L'hyperconvergence (HCI) est une architecture qui regroupe ces trois couches dans des serveurs standard, pilotés par une couche logicielle centralisée. Cette approche permet de simplifier l'administration, de réduire les coûts matériels et d'assurer la haute disponibilité de manière native. Dans un contexte de transformation numérique des entreprises industrielles, l'hyperconvergence est devenue une réponse concrète aux besoins d'infrastructures flexibles, évolutives et économiques.

Sonatrach, la compagnie nationale algérienne des hydrocarbures, dispose au sein de sa Direction Centrale Recherche & Développement d'une infrastructure hyperconvergée reposant sur des solutions propriétaires, Nutanix et VMware vSAN, pour ses environnements de production. Si ces solutions offrent des garanties solides en termes de fiabilité et de support, elles présentent des contraintes structurelles importantes : des licences coûteuses dont le prix augmente chaque année, une dépendance forte vis-à-vis des éditeurs qui limite toute liberté d'adaptation, et un manque de souveraineté technique. Pour les environnements de test, de développement et de pré-production, qui nécessitent des clusters de trois à quatre nœuds seulement, déployer ces mêmes solutions reste disproportionné par rapport aux besoins réels. La question qui se pose est donc la suivante : comment concevoir et déployer une infrastructure hyperconvergée open source, capable de répondre aux exigences de fiabilité et de performance de Sonatrach, tout en constituant une alternative crédible et souveraine aux solutions propriétaires ?

Plusieurs solutions open source existent pour répondre à ce besoin. OpenStack est la plateforme cloud la plus complète et la plus standardisée, mais sa complexité de déploiement et sa consommation élevée de ressources la rendent inadaptée aux petits clusters. Harvester, développé par SUSE sur Kubernetes et KubeVirt, propose une interface moderne mais reste orienté vers les charges de travail conteneurisées et consomme des ressources importantes avant même d'allouer des capacités aux machines virtuelles classiques. Proxmox VE, en revanche, est un hyperviseur open source léger, qui déploie un cluster de trois nœuds en quelques heures et intègre nativement Ceph pour le stockage distribué. Pour la couche réseau, Open vSwitch avec des tunnels VLAN permet de créer une segmentation réseau complète sans nécessiter de modifications sur le switch physique. Ces technologies constituent aujourd'hui une pile technique mature et bien documentée, mais aucune d'elles n'intègre nativement un mécanisme d'équilibrage dynamique de charge des ressources du Clusters.

Dans le cadre de ce projet, nous avons conçu et déployé une infrastructure Cloud privée hyperconvergée entièrement open source sur trois serveurs Dell PowerEdge R720 fournis par Sonatrach. Nous avons installé Proxmox VE en mode bare metal sur chaque nœud, puis formé un cluster haute disponibilité géré par Corosync, avec basculement automatique des machines virtuelles en cas de panne. Nous avons déployé un cluster Ceph à douze OSDs avec un facteur

de réplication de trois, garantissant la persistance des données même en cas de défaillance d'un nœud entier. Pour la couche réseau, nous avons conçu une architecture à neuf segments logiques, matérialisés par des tunnels VXLAN gérés par Open vSwitch, couvrant les flux d'infrastructure (Corosync, réplication Ceph, migration à chaud) et les zones applicatives (Dev, Prod, DMZ — “zone démilitarisée”). Nous avons également développé le **CSLB** (“Central Load Balancing Scheduler”), un service d'équilibrage dynamique de charge écrit en Go, qui surveille en continu la charge CPU et RAM des nœuds, calcule une bande de charge modérée et déclenche automatiquement des migrations à chaud pour redistribuer les machines virtuelles. Ce mécanisme est une adaptation de l'algorithme CSLB (“Central Scheduler Load Balancing”), étendu pour prendre en compte la RAM, avec des protections anti-oscillation et un circuit breaker. Pour compléter la plateforme, nous avons déployé une stack de supervision complète (InfluxDB, Prometheus, Grafana, Loki), des pipelines CI/CD via GitLab, une automatisation d'infrastructure par Ansible et Rundeck, une synchronisation temporelle par Chrony, et un pare-feu OPNsense assurant le routage et le filtrage inter-réseaux.

Ce mémoire est organisé en quatre chapitres :

- **Chapitre I** : Contexte du projet, infrastructure Sonatrach, problématique et objectifs.
- **Chapitre II** : État de l'art, comparaison des solutions et justification des choix technologiques.
- **Chapitre III** : Conception de l'architecture, dimensionnement physique, plan d'adressage et logique CSLB.
- **Chapitre IV** : Déploiement, configuration via PXE et Ansible, et validation de la plateforme.

Chapitre I

Présentation du Contexte

I.1 Introduction

Ce chapitre présente le contexte de notre projet de fin d'études. On commence par présenter Sonatrach, l'entreprise d'accueil, puis on décrit l'infrastructure existante et les problèmes qu'elle pose. Ensuite on définit la problématique, les objectifs et les limites du projet.

I.2 Présentation de Sonatrach

Sonatrach est une entreprise publique algérienne créée le 31 décembre 1963, peu après l'indépendance. Au départ, elle s'occupait surtout du transport et de la commercialisation du pétrole brut extrait en Algérie.

Avec le temps, Sonatrach est devenue la plus grande entreprise africaine dans le domaine des hydrocarbures. Elle couvre aujourd'hui toute la chaîne de valeur : exploration, production, transport, transformation et commercialisation. Elle est aussi active dans la pétrochimie et les énergies renouvelables.

La Figure I.1 présente le logo officiel de Sonatrach.



FIGURE I.1 – Logo de Sonatrach [?]

Après la nationalisation des hydrocarbures dans les années 1970, Sonatrach a pris le contrôle total des ressources naturelles du pays. Elle travaille aujourd'hui en partenariat avec de nombreuses compagnies étrangères, à travers des "joint-ventures" et des accords technologiques avec des entreprises européennes, américaines, asiatiques et africaines. Aujourd'hui, Sonatrach opère dans plusieurs pays et représente l'une des principales sources d'exportation pour l'Algérie [?].

Notre projet a été réalisé au sein du Centre d'Innovation, qui dépend de la Direction Infrastructure et Service IT, elle-même rattachée à la Direction Centrale Digitalisation et Systèmes d'Information (DC DSI) de Sonatrach. L'organigramme de la Figure I.2 illustre la position du Centre d'Innovation au sein de cette structure.




FIGURE I.2 – Organigramme de la Direction Centrale Digitalisation et Systèmes d’Information [?]

I.3 Infrastructure Existante et Contexte Technologique

Cette section décrit l’environnement technologique dans lequel s’inscrit le projet. Elle présente d’abord l’infrastructure hyperconvergée actuelle de Sonatrach, puis les besoins qui justifient la recherche d’une alternative open source pour les zones de test.

I.3.1 Infrastructure actuelle de Sonatrach

Sonatrach dispose actuellement d’une infrastructure hyperconvergée basée sur deux solutions propriétaires : Nutanix et VMware vSAN [?]. Nutanix est déployé à grande échelle sur plusieurs sites pour les environnements de production critiques, tandis que VMware vSAN est utilisé pour les déploiements de plus petite taille. Ces deux solutions sont bien établies, avec une gestion centralisée, une haute disponibilité et une scalabilité éprouvées.

Cependant, ces solutions présentent des contraintes qui deviennent préoccupantes sur le long terme :

- **Coûts de licences croissants** : les frais de licence de Nutanix et VMware augmentent régulièrement et représentent une charge financière importante pour l’entreprise, indépendamment du niveau d’utilisation réel.

- **Dépendance technologique forte** : le recours exclusif à des éditeurs propriétaires crée un risque de “vendor lock-in”, ce qui limite la capacité de négociation et l’adoption de nouvelles technologies.
- **Manque de souveraineté technique** : toutes les décisions sur les évolutions et mises à jour sont imposées par les éditeurs, sans possibilité d’adaptation aux besoins spécifiques de Sonatrach.
- **Inadaptation aux petits déploiements** : pour les environnements de test et de développement sur des clusters de 3 à 4 nœuds, ces solutions propriétaires sont disproportionnées par rapport aux besoins réels, tant en complexité qu’en coût.

Ce projet cherche donc à valider la viabilité d’une infrastructure hyperconvergée open source, d’abord en environnement de test, avec la possibilité de passer en production à terme.

I.3.2 Les besoins en infrastructure légère pour les zones de test

Pour les environnements de test et de pré-production, Sonatrach a besoin d’une infrastructure qui réponde à des exigences précises sans les contraintes des solutions propriétaires :

- **Fiabilité et haute disponibilité** : l’infrastructure doit continuer à fonctionner si un nœud tombe en panne, avec basculement automatique des machines virtuelles sans intervention humaine.
- **Performance et scalabilité** : la solution doit pouvoir s’agrandir en ajoutant des nœuds au cluster sans interruption de service.
- **Gestion unifiée des ressources** : le calcul, le stockage et le réseau doivent être administrés depuis une seule interface centralisée.
- **Équilibrage dynamique de charge** : la plateforme doit redistribuer automatiquement les machines virtuelles entre les nœuds selon leur utilisation des ressources.
- **Souveraineté et indépendance technologique** : en s’appuyant uniquement sur des technologies open source, Sonatrach reprend le contrôle total de son infrastructure.
- **Réduction du coût total de possession (TCO, “Total Cost of Ownership”)** : l’absence de licences propriétaires représente une économie importante sur le long terme, réallouable vers des investissements matériels ou humains.

I.4 Problématique

La problématique centrale de ce projet est la suivante :

Comment concevoir et déployer une infrastructure Cloud privée hyperconvergée, entièrement basée sur des technologies open source, capable de répondre aux exigences de fiabilité, de performance et de scalabilité d’une grande entreprise industrielle, tout en constituant une alternative crédible et souveraine aux solutions propriétaires de type Nutanix ?

Cette problématique soulève plusieurs questions techniques :

- Comment concevoir un système de stockage distribué, redondant et performant qui garantit l'intégrité des données en cas de défaillance d'un nœud ?
- Comment assurer le basculement et l'équilibrage automatique des charges de travail dans un cluster à plusieurs nœuds, sans perte de données ni interruption prolongée de service ?
- Comment segmenter et isoler les différents flux réseau au sein d'une infrastructure hyperconvergée, en séparant les trafics de gestion, de réplication, de migration et de production ?
- Dans quelle mesure une solution open source peut-elle répondre aux exigences d'une infrastructure de niveau production dans le contexte d'une grande entreprise ?

I.5 Objectifs du Projet

Les objectifs du projet se déclinent en un objectif général et en plusieurs objectifs spécifiques précisant les réalisations techniques attendues.

I.5.1 Objectif général

Concevoir et déployer une infrastructure Cloud privée hyperconvergée entièrement open source sur trois serveurs physiques Dell PowerEdge R720 mis à disposition par Sonatrach, offrant des garanties de fiabilité, de performance et d'évolutivité comparables aux solutions propriétaires tels que Nutanix.

I.5.2 Objectifs spécifiques

- **Déployer un cluster de trois nœuds physiques à haute disponibilité** sur les serveurs Dell PowerEdge R720 fournis par Sonatrach, avec gestion centralisée, administration simplifiée et support de la migration à chaud.
- **Configurer Proxmox VE sur chaque serveur physique** en exploitant pleinement les ressources matérielles disponibles : 64 Go de RAM pour PVE-01, 254 Go pour PVE-02 et PVE-03, et 5 disques SAS ("Serial Attached SCSI") par nœud.
- **Mettre en place un système de stockage distribué Ceph** en allouant quatre disques par nœud comme OSDs Ceph (1×300 Go et 3×600 Go), le cinquième disque de 300 Go étant réservé au système d'exploitation.
- **Implémenter une segmentation réseau avancée** via Open vSwitch, en configurant une architecture multi-VXLAN séparant les flux de gestion, de réplication, de migration et de production.
- **Développer un mécanisme d'équilibrage dynamique de la charge**, capable de redistribuer automatiquement les machines virtuelles selon les métriques de performance en temps réel.
- **Valider la solution** à travers un scénario de haute disponibilité démontrant la tolérance aux pannes sans perte de données ni interruption de service.
- **Fournir une base d'infrastructure évolutive**, accompagnée d'une documentation technique réutilisable à plus grande échelle au sein de Sonatrach.

I.6 Périmètre et Limitations du Projet

Ce projet vise le déploiement d'un cluster hyperconvergé open source destiné aux environnements de test, de développement et de pré-production. L'infrastructure est déployée sur trois serveurs Dell PowerEdge R720 mis à disposition par Sonatrach.

Le déploiement sur une architecture physique distribuée élimine le problème du point de défaillance unique (SPOF) matériel. Cependant, le périmètre reste volontairement limité à un environnement de laboratoire, ce qui implique les contraintes suivantes :

- **Capacité de stockage** : chaque serveur dispose de quatre disques OSD ($1 \times 300 \text{ Go} + 3 \times 600 \text{ Go}$, soit 2,1 To brut par nœud). Avec une réplication de facteur 3, le cluster offre environ 2,1 To d'espace utilisable. C'est suffisant pour des charges de développement et de validation, mais insuffisant pour des données à très grande échelle.
- **Limite de configuration du commutateur** : la segmentation réseau repose sur une configuration précise des commutateurs physiques (affectation des ports, mode trunk). Cette configuration est gérée exclusivement par l'équipe réseau de Sonatrach et ne peut pas être modifiée dans le cadre de ce projet.
- **Absence de multilocation** : la configuration mise en œuvre est orientée Cloud privé. La gestion multilocataire stricte, propre aux environnements Cloud publics, n'entre pas dans le périmètre de ce projet.
- **Maintenance à long terme** : la gestion opérationnelle continue de l'infrastructure (mises à jour, sauvegardes, pannes matérielles) n'est pas couverte par ce projet et constitue une perspective d'évolution naturelle pour l'équipe d'exploitation.

I.7 Conclusion

Dans ce chapitre, on a présenté le contexte du projet, les besoins identifiés au sein de Sonatrach et la problématique qui motive notre démarche. On a défini les objectifs, le périmètre et les limites du projet. Le chapitre suivant présente l'état de l'art des solutions disponibles et les bases théoriques de l'hyperconvergence et des technologies retenues.

Chapitre II

État de l'Art et Concepts Théoriques

II.1 Introduction

Ce chapitre présente les bases théoriques de notre projet. On commence par définir l'hyperconvergence et comparer les solutions disponibles pour justifier nos choix technologiques. Ensuite, on présente en détail les trois technologies retenues : Proxmox VE, Ceph et Open vSwitch. On termine par les outils complémentaires et les fondements de l'équilibrage de charge.

II.2 L'Hyperconvergence (HCI)

Cette section définit le concept d'hyperconvergence, présente ses composantes et ses avantages, puis le compare à l'architecture traditionnelle.

II.2.1 Définition

L'hyperconvergence (HCI, "Hyper-Converged Infrastructure") est une architecture qui regroupe dans un même système le calcul, le stockage et le réseau, pilotés par une couche logicielle centralisée. On n'a plus besoin de gérer des équipements distincts pour chaque fonction [?, ?].

L'infrastructure hyperconvergée repose sur trois composantes fondamentales :

- **Le calcul** : des processeurs virtuels (vCPU, "Virtual Central Processing Unit") alloués dynamiquement aux machines virtuelles.
- **Le stockage** : un système de stockage distribué logiciel, agrégé à partir des disques locaux de chaque nœud.
- **Le réseau** : un switch virtuel logiciel permettant la segmentation et l'isolation du trafic réseau.

II.2.2 Avantages de l'hyperconvergence

Par rapport aux architectures traditionnelles où le calcul, le stockage et le réseau sont gérés séparément, l'HCI offre plusieurs avantages :

- **Simplicité d'administration** : une interface unique pour gérer l'ensemble des ressources.
- **Réduction des coûts matériels** : pas besoin de baies de stockage ou de switchs réseau dédiés.
- **Évolutivité horizontale** : l'ajout d'un nœud augmente simultanément la capacité de calcul, de stockage et de réseau.
- **Haute disponibilité native** : la réplication des données entre les nœuds assure la continuité de service en cas de panne.

II.2.3 HCI face à l'Infrastructure Traditionnelle

Le Tableau II.1 compare l'architecture hyperconvergée à l'architecture traditionnelle selon cinq critères.

TABEAU II.1 – Comparaison entre l'infrastructure traditionnelle et l'infrastructure HCI

Critère	Infrastructure traditionnelle	Infrastructure HCI
Gestion	Silos séparés (calcul, stockage, réseau)	Interface unifiée
Coût initial	Élevé (équipements spécialisés)	Réduit (matériel standard)
Évolutivité	Verticale (mise à niveau du matériel)	Horizontale (ajout de nœuds)
Complexité	Haute	Faible
Haute disponibilité	Optionnelle et complexe	Native

II.3 Comparaison : Solutions Propriétaires et Open Source

Cette section met en regard les solutions propriétaires et les solutions open source dans le contexte du projet.

II.3.1 Solutions propriétaires

Les solutions propriétaires comme VMware vSAN ou Nutanix offrent un bon support et des fonctionnalités avancées, mais elles posent plusieurs problèmes dans notre contexte :

- **Coûts élevés** : les licences et la maintenance annuelle représentent un investissement important, difficilement justifiable pour des environnements de test.
- **Dépendance fournisseur** *Vendor Lock – in* : la migration vers une autre solution est souvent complexe et coûteuse.
- **Faible flexibilité** : les environnements propriétaires offrent peu de liberté pour personnaliser l'infrastructure.

II.3.2 Solutions open source

Les solutions open source présentent plusieurs avantages dans notre contexte :

- **Indépendance technologique** : aucune dépendance vis-à-vis d'un éditeur.
- **Absence de coûts de licence** : seuls les coûts matériels et de main-d'œuvre sont à prévoir.
- **Transparence et auditabilité** : le code source est accessible et modifiable.
- **Communauté active** : documentation abondante et mises à jour régulières.

Pour des environnements de test et de petits déploiements, l'approche open source est clairement la plus adaptée.

II.4 Analyse des Solutions Open Source HCI

Le critère principal de sélection est la légèreté et la capacité à fonctionner de façon stable sur un cluster de 3 nœuds.

II.4.1 OpenStack

OpenStack est une plateforme cloud open source complète, utilisée par de nombreuses grandes entreprises. Elle propose des services de calcul (Nova), stockage objet (Swift), stockage en bloc (Cinder), réseau (Neutron), identité (Keystone), etc. [?]

Cependant, OpenStack présente des inconvénients majeurs pour notre cas d'usage :

- **Complexité de déploiement** : l'installation implique l'orchestration de nombreux services interdépendants, ce qui rend le déploiement long et difficile à maintenir.
- **Consommation de ressources élevée** : les services de base consomment plusieurs Go de RAM avant même de démarrer des VMs.
- **Inadapté aux petits clusters** : OpenStack est conçu pour des déploiements de grande envergure. Sur 3 nœuds, ses performances et sa stabilité sont compromises.

II.4.2 Harvester HCI

Harvester est une solution HCI open source développée par SUSE, basée sur Kubernetes et KubeVirt. Elle propose une interface moderne et une intégration native avec Rancher [?].

Ses limites dans notre contexte :

- **Consommation en RAM et CPU élevée** : la couche Kubernetes sous-jacente consomme beaucoup de ressources avant même d'allouer quoi que ce soit aux VMs.
- **Maturité relative pour les VMs classiques** : Harvester est davantage orienté vers les conteneurs. La gestion de VMs Linux/Windows classiques y est moins optimisée [?].

II.4.3 Proxmox VE

Proxmox Virtual Environment (VE) est une plateforme de virtualisation open source basée sur KVM et LXC. Elle propose une interface web centralisée, un support natif de Ceph et une gestion intégrée du clustering et de la haute disponibilité [?].

Ses atouts pour notre cas d'usage :

- **Légereté** : moins de 1 Go de RAM consommé à vide, laissant l'essentiel des ressources aux VMs.
- **Déploiement rapide** : un cluster de 3 nœuds est opérationnel en quelques heures.
- **Interface web intuitive** : la console (accessible sur le port 8006) centralise la gestion des VMs, conteneurs, stockage, réseau et haute disponibilité.
- **Intégration native de Ceph** : les outils Ceph sont intégrés directement dans Proxmox, ce qui simplifie beaucoup le déploiement.
- **Communauté active** : documentation officielle complète et forums très actifs.

II.4.4 Tableau comparatif

Le Tableau II.2 compare les trois solutions selon les critères les plus importants pour notre contexte.

TABLEAU II.2 – Comparaison des solutions HCI open source : OpenStack, Harvester et Proxmox VE

Critère	OpenStack	Harvester	Proxmox VE
Légereté	Faible	Moyenne	Élevée
Facilité de déploiement	Difficile	Moyenne	Facile
Adapté au déploiement à 3 nœuds	Non	Partiel	Oui
Intégration stockage distribué	Via Cinder/Ceph	Via Longhorn	Ceph natif
Gestion des VMs classiques	Bonne	Moyenne	Excellente
Maturité	Très mature	En cours	Mature
Coût de licence	Gratuit	Gratuit	Gratuit (Enterprise payant)

Proxmox VE est la solution la mieux adaptée à ce projet : légère, rapide à déployer sur 3 nœuds, et extensible sans changement d'architecture. Elle sera retenue comme hyperviseur principal.

II.5 Présentation des Technologies Retenues

Cette section présente en détail les trois technologies open source retenues : Proxmox VE, Ceph et Open vSwitch.

II.5.1 Proxmox VE : L'hyperviseur

Présentation générale

Proxmox Virtual Environment (VE) est une plateforme de virtualisation open source basée sur un noyau Linux Debian modifié. Elle supporte deux types de virtualisation : **KVM** *Kernel – basedVirtualMachine* pour les machines virtuelles complètes compatibles avec Linux, Windows et BSD, et **LXC** (Linux Containers) pour les conteneurs légers. L'ensemble est administré via une interface web sur le port 8006.

La pile de virtualisation : KVM, QEMU et libvirt

La virtualisation dans Proxmox repose sur une pile logicielle à trois niveaux qui collaborent ensemble.

KVM : Kernel-based Virtual Machine

KVM est un module du noyau Linux (chargé via `kvm.ko` et `kvm_intel.ko` ou `kvm_amd.ko` selon le processeur) qui transforme Linux en hyperviseur de type 1 [?]. KVM exploite les extensions matérielles **Intel VT-x** ou **AMD-V** pour exécuter le code des VMs directement sur le CPU physique sans émulation. Les instructions non privilégiées s'exécutent à vitesse native, tandis que les instructions privilégiées (accès mémoire, I/O) sont interceptées par le noyau hôte. Le résultat est une performance CPU très proche du bare metal, entre 95% et 99% des performances natives.

QEMU : Quick EMUlator

QEMU est l'émulateur de machine qui accompagne KVM [?]. Il opère en espace utilisateur et assure plusieurs fonctions :

- Il **émule les périphériques** de la VM : carte réseau virtuelle (VirtIO, e1000, RTL8139), contrôleur de disque (VirtIO SCSI, IDE, SATA), carte graphique, USB *UniversalSerialBus*, BIOS *BasicInput/OutputSystem* ou UEFI *UnifiedExtensibleFirmwareInterface* via *OVMF OpenVirtualMachineFirmware*. Chaque VM correspond à un processus `qemu-system-x86_` sur l'hôte.
- Il gère le **CPU virtuel (vCPU)** : le nombre de cœurs, le modèle de CPU exposé à la VM (host-passthrough, kvm64, Haswell, Broadwell, etc.) et les flags CPU visibles par le système invité.
- Il assure la **gestion mémoire** : allocation de RAM, support du "Memory Ballooning" et des "Huge Pages" pour réduire la pression sur le TLB.
- Il fournit les **interfaces de migration** pour la live migration : QEMU transfère l'état complet d'une VM (mémoire, état CPU, état des périphériques) vers un autre hôte sans interruption de service.

Quand KVM est disponible, QEMU lui délègue l'exécution du code de la VM et ne s'occupe que des périphériques. C'est cette combinaison KVM+QEMU qui constitue l'hyperviseur réel.

libvirt : couche d'abstraction de la virtualisation Linux

libvirt est une bibliothèque open source qui offre une API unifiée pour gérer plusieurs hyperviseurs (KVM, QEMU, LXC, Xen) [?]. Elle est utilisée par des outils comme `virt-manager`, OpenStack Nova ou oVirt.

Proxmox ne l'utilise pas : il a sa propre couche de gestion en Perl (`PVE::QemuServer`) qui pilote QEMU directement. Ça lui donne un contrôle plus précis sur les paramètres QEMU et une meilleure intégration avec l'API REST *RepresentationalStateTransfer* et les mécanismes de cluster.




FIGURE II.1 – Pile de virtualisation KVM + QEMU dans Proxmox VE

La figure II.1 illustre les cinq niveaux de la pile de virtualisation Proxmox. KVM exploite les extensions VT-x et AMD-V pour exécuter le code des VMs directement sur le CPU. QEMU émule les périphériques en espace utilisateur. Proxmox orchestre l'ensemble via son API REST.

Les conteneurs Linux : LXC

LXC *LinuxContainers* est une virtualisation légère basée sur deux mécanismes du noyau Linux : les **namespaces** et les **cgroups**. Contrairement aux VMs KVM qui ont un noyau dédié, les conteneurs LXC partagent le noyau de l'hôte, ce qui réduit beaucoup la consommation de ressources : un conteneur démarre en quelques secondes avec un surcoût mémoire de quelques dizaines de mégaoctets.

Les **namespaces** isolent chaque conteneur (processus, réseau, points de montage, utilisateurs). Les **cgroups** *controlgroups* limitent et comptabilisent la consommation de ressources (CPU, mémoire, I/O) par conteneur.

Proxmox intègre LXC nativement avec des modèles pour Debian, Ubuntu et Alpine. LXC est adapté pour les services qui ne nécessitent pas de noyau spécifique : agents de supervision,

serveurs NTP, services PXE, intégration continue [?].

Le Tableau II.3 récapitule les principales différences entre une VM KVM et un conteneur LXC [?].

TABEAU II.3 – Comparaison entre une machine virtuelle KVM et un conteneur LXC

Critère	VM KVM	Conteneur LXC
Isolation	Matériel + noyau dédié	Noyau partagé (namespaces)
Temps de démarrage	20 à 60 secondes	1 à 5 secondes
Surcoût RAM	~512 MB	~50 MB
Systèmes supportés	Linux, Windows, BSD	Linux uniquement
Cas d'usage	Applications nécessitant un noyau spécifique	Services Linux standards

Gestion du cluster : Corosync et le quorum

La gestion du cluster Proxmox repose sur **Corosync**, un framework de communication qui assure le consensus entre les nœuds via un mécanisme de quorum [?]. Corosync envoie des messages “heartbeat” réguliers sur un réseau dédié pour détecter les défaillances. Un cluster Proxmox nécessite au minimum **3 nœuds** pour garantir un quorum stable.

Avec 3 nœuds, la majorité est de 2 : si un nœud tombe, les 2 restants gardent le quorum et le cluster continue. Si 2 nœuds tombent en même temps, le nœud restant se met en retrait pour éviter le “split-brain”, une situation où deux parties du cluster modifient les données en même temps sans le savoir.

Haute disponibilité (HA Manager)

Proxmox intègre un gestionnaire de haute disponibilité composé de deux services [?] :

- **pve-ha-crm** *ClusterResourceManager* : le cerveau centralisé du HA. Il surveille toutes les ressources protégées (VMs, conteneurs) et prend les décisions de basculement.
- **pve-ha-lrm** *LocalResourceManager* : l'agent local sur chaque nœud. Il exécute les ordres du CRM et remonte l'état des ressources locales.

Quand un nœud devient inaccessible, le CRM déclenche le **fencing** (isolation forcée via le watchdog), puis redémarre les VMs protégées sur les nœuds survivants. Le délai typique est de 60 à 120 secondes. Les VMs avec leurs disques sur Ceph RBD peuvent redémarrer sur n'importe quel nœud sans déplacer de données.

Live Migration

La migration à chaud *livemigration* déplace une VM en cours d'exécution d'un nœud vers un autre sans interruption perceptible. Proxmox l'implémente via QEMU en trois phases :

1. **Pré-copie mémoire** : QEMU copie les pages mémoire de la VM vers le nœud cible pendant que la VM tourne. Les pages modifiées *dirty pages* sont recopiées lors de passes successives.
2. **Basculement** : quand le volume de dirty pages devient assez faible, la VM est brièvement suspendue, les dernières pages sont transférées, puis la VM reprend sur le nœud cible.
3. **Nettoyage** : les ressources de la VM sont libérées sur le nœud source.

C'est ce mécanisme que le service CSLB utilise pour redistribuer la charge entre les nœuds. Le trafic de migration doit transiter sur un réseau dédié pour ne pas impacter les autres flux.

Interface de gestion et API REST

Proxmox expose une **API REST complète** sur le port 8006 (HTTPS), utilisée aussi bien par l'interface web que par des outils externes. Toutes les opérations disponibles graphiquement le sont aussi via l'API : création de VMs, gestion du stockage, déclenchement de migrations, consultation des métriques. Les appels sont authentifiés par ticket de session.

Récapitulatif de la pile technique Proxmox

Le Tableau II.4 récapitule les principaux composants de la pile Proxmox VE et leur rôle.

TABLEAU II.4 – Récapitulatif des composants de la pile technique Proxmox VE

Composant	Rôle
KVM (<code>kvm.ko</code>)	Hyperviseur noyau, exécution native du code VM via VT-x / AMD-V
QEMU (<code>qemu-system-x86_64</code>)	Émulation des périphériques, gestion mémoire, migration à chaud
LXC	Conteneurs Linux légers partageant le noyau hôte
Corosync	“heartbeat” du cluster, consensus, détection de panne
pve-ha-crm / lrm	Gestionnaire de haute disponibilité, isolation <i>fencing</i> , basculement automatique
API REST (port 8006)	Interface de pilotage programmatique et d'automatisation

II.5.2 Ceph : Le stockage distribué

Ceph est une solution de stockage distribué open source *Software – Defined Storage* qui fonctionne sur du matériel standard (serveurs x86) et qui se répare automatiquement en cas de panne [?]. C'est le choix retenu pour la couche de stockage de notre infrastructure.

Architecture de Ceph

Ceph repose sur un composant central appelé RADOS *Reliable Autonomic Distributed Object Store*, qui gère la réplication et la répartition des données sur le cluster. Autour de RADOS, plusieurs

types de démons travaillent ensemble :

- **Ceph Monitor (MON)** : Les Moniteurs maintiennent une carte du cluster *clustermap* et assurent le consensus entre les nœuds via un quorum. C'est eux qui décident de l'état du cluster en cas de désaccord.
- **Ceph Manager (MGR)** : Le Manager collecte les métriques du cluster en temps réel (utilisation, performances) et les expose via une interface web et des APIs externes.
- **Ceph OSD (Object Storage Daemon)** : L'OSD gère un disque physique et s'occupe de la lecture, de l'écriture, de la réplication et du rééquilibrage des données. Dans notre architecture hyperconvergée, chaque nœud héberge des OSDs en plus de l'hyperviseur.
- **Ceph Metadata Server (MDS)** : Ce démon est spécifique au système de fichiers CephFS. Pour un usage en mode bloc (disques de VMs), il n'est pas nécessaire.

La gestion intelligente des données : CRUSH et Placement Groups

Ceph utilise un algorithme appelé CRUSH *Controlled Replication Under Scalable Hashing* [?] pour déterminer où stocker chaque objet. Contrairement aux systèmes classiques, un client peut calculer directement l'emplacement d'un objet sans interroger un serveur central, ce qui évite un point de défaillance unique.

La carte CRUSH définit l'organisation physique du cluster avec des "domaines de défaillance" (nœuds, racks, salles). Ceph place les répliques sur des nœuds distincts pour qu'une panne matérielle n'entraîne pas de perte de données.

Pour gérer les milliers d'objets efficacement, Ceph les regroupe en unités logiques appelées Placement Groups (PGs), une couche intermédiaire entre les objets et les OSDs qui améliore l'équilibrage des données dans le cluster.

Les modes de protection des données

Ceph propose deux mécanismes pour protéger les données :

- **Réplication** : Chaque objet est dupliqué en N copies (généralement 3), chacune sur un OSD différent. En cas de panne, les données restent disponibles sur les autres répliques. C'est le mode utilisé dans ce projet : avec 3 nœuds et un facteur de réplication 3, le cluster tolère la perte d'un nœud complet.
- **Erase Coding (Codage d'effacement)** : Les données sont découpées en K fragments de données et M fragments de parité (K+M au total), répartis sur différents OSDs. On peut tolérer la perte de M fragments. Ce mode est plus économe en espace ($1,5\times$ contre $3\times$ pour la réplication) mais plus coûteux en calcul lors de la reconstruction. Il est surtout utilisé pour les données froides ou l'archivage.

Intégration de Ceph dans une architecture hyperconvergée

L'intégration entre Ceph et Proxmox VE est native : on peut créer et gérer un cluster Ceph directement depuis l'interface web de Proxmox.

Dans notre architecture, chaque nœud joue deux rôles en même temps : il exécute des VMs via KVM et contribue au stockage distribué via ses disques Ceph. Les volumes des VMs sont fournis via Ceph RBD *RADOSBlockDevice*, distribués et répliqués sur tout le cluster.

Les avantages de Ceph dans ce contexte sont :

1. **Évolutivité horizontale** : l'ajout d'un nœud apporte du calcul et du stockage en même temps, avec rééquilibrage automatique des données.
2. **Haute disponibilité** : pas de point de défaillance unique, les données restent accessibles même si un serveur tombe.
3. **Auto-réparation** : en cas de panne d'un disque ou d'un nœud, le cluster recrée automatiquement les répliques manquantes sur les autres nœuds.
4. **Coût maîtrisé** : Ceph est gratuit et fonctionne sur du matériel standard, bien moins coûteux que des SAN *StorageAreaNetwork* ou des appliances propriétaires.
5. **Gestion simplifiée** : l'outil `cephadm` permet un déploiement conteneurisé, et l'intégration avec Proxmox réduit la complexité administrative.

II.5.3 Open vSwitch (OVS) : La virtualisation réseau

Présentation générale

Open vSwitch (OVS) est un commutateur logiciel open source distribué sous licence Apache 2.0, conçu pour les environnements de virtualisation [?]. Il repose sur deux composants : `ovs-vswitchd`, le démon qui implémente le switch avec son module noyau, et `ovsdb-server`, une base de données de configuration persistante. Il supporte nativement les VLANs 802.1Q, le bonding LACP *LinkAggregationControlProtocol*, NetFlow, sFlow, QoS, et les tunnels GRE *GenericRoutingEncapsulation*, VXLAN et Geneve [?].

Dans notre cluster HCI, OVS joue le rôle de commutateur central sur chaque nœud et gère la segmentation de tout le trafic depuis un bridge virtuel unique.

Pourquoi segmenter le réseau dans un cluster HCI ?

Dans un cluster HCI, plusieurs types de trafic cohabitent sur la même infrastructure physique avec des profils très différents :

- La **réplication Ceph** génère un trafic continu à très haute bande passante qui peut saturer un réseau partagé.
- Les **heartbeats Corosync** sont très sensibles à la latence : un délai peut déclencher un basculement non voulu du cluster.
- Les **migrations à chaud** produisent des pics de transfert intenses lors du déplacement de la mémoire d'une VM entre deux nœuds.
- Les **charges de travail applicatives** génèrent un trafic imprévisible qui ne doit pas interférer avec les flux d'infrastructure.

Sans isolation, ces flux se dégradent mutuellement. C'est le même problème que Nutanix résout avec la séparation entre le trafic du contrôleur interne et celui des VMs. La solution est d'affecter à chaque type de trafic un segment réseau dédié géré par OVS.

La documentation Proxmox et les guides Ceph recommandent explicitement de séparer le réseau de réplication interne Ceph, le réseau d'accès des VMs au stockage et le réseau de synchronisation du cluster.

Les neuf types de trafic à isoler

On identifie neuf types de trafic aux profils distincts, chacun justifiant un segment dédié. Le plan d'adressage exact est défini dans le chapitre suivant ; ici on explique juste pourquoi chaque isolation est nécessaire :

- **Administration et gestion** : accès à l'interface web, SSH, API. Volume faible mais disponibilité permanente requise. Ce segment doit être isolé des réseaux applicatifs pour empêcher tout accès non autorisé depuis une VM compromise.
- **Synchronisation du cluster** : heartbeats et consensus Corosync. Très sensible à la latence : tout délai peut déclencher un basculement non souhaité.
- **Réplication interne du stockage distribué** : communications entre OSDs pour la réplication et la reconstruction des données. Flux continu à haute bande passante, ne doit pas être mélangé avec d'autres trafics.
- **Accès des machines virtuelles au stockage** : flux entre les VMs et le pool Ceph. Séparé du réseau de réplication interne pour que les opérations de rééquilibrage ne pénalisent pas les VMs.
- **Migrations à chaud** : transferts de mémoire entre nœuds lors des migrations. Flux ponctuel mais intense, isolé pour ne pas saturer les autres réseaux.
- **Machines virtuelles de production** : trafic applicatif exposé aux utilisateurs. Accessible uniquement via le répartiteur de charge, isolé des environnements de développement.
- **Machines virtuelles de test et de développement** : isolé de la production pour éviter toute interférence.
- **Zone exposée** : services accessibles depuis l'extérieur, protégés par le pare-feu et le répartiteur de charge.
- **Sauvegarde** : transferts de sauvegardes et d'instantanés. Flux soutenu, maintenu hors bande pour ne pas dégrader les performances en production.

Contrainte d'infrastructure rencontrée et adaptation : adoption de VXLAN

L'architecture initiale prévoyait une segmentation par **VLANs 802.1Q**, ce qui nécessite que le switch physique soit configuré en mode "trunk". Cette approche est standard et supportée par OVS.

Cependant, sur l'infrastructure de Sonatrach, les trois serveurs Dell R720 sont connectés à un switch administré par l'équipe réseau de l'entreprise. Ce switch a déjà des VLANs définis

(VLAN 10 pour le management, VLAN 20 pour un usage interne), et l'équipe projet n'a aucun droit d'administration dessus. Les serveurs sont connectés en mode access sur le VLAN de gestion uniquement.

Face à cette contrainte, on a remplacé les VLANs 802.1Q par des tunnels **VXLAN** ("Virtual eXtensible LAN", RFC 7348) [?].

VXLAN : principe de fonctionnement

VXLAN encapsule des trames Ethernet (niveau 2) dans des paquets UDP/IP (niveau 4), créant des réseaux virtuels superposés *overlaynetworks* sur un réseau physique existant sans le modifier.

Quand une VM sur le nœud A veut communiquer avec une VM sur le nœud B, OVS encapsule la trame dans un paquet UDP vers l'IP de B. Le switch physique voit juste du trafic UDP ordinaire. À la réception, OVS sur B désencapsule le paquet et restitue la trame à la VM destination.

Chaque réseau logique est identifié par un **VNI** *VXLANNetworkIdentifier*, un entier sur 24 bits, l'équivalent fonctionnel d'un tag VLAN. Chacun des neuf types de trafic correspond à un tunnel VXLAN avec son propre VNI. L'attribution précise des VNIs est détaillée dans le chapitre suivant.

Impact sur l'architecture et bilan

Le passage à VXLAN ne change pas l'architecture à neuf segments. Les neuf segments (management, Corosync, Ceph interne, Ceph public, migration, VMs prod, test/dev, DMZ, backup) sont conservés, chacun avec un VNI dédié à la place d'un tag VLAN. OVS gère tout ça de façon transparente, sans toucher au réseau physique de Sonatrach.

Cette approche apporte même quelques avantages : le cluster est indépendant du réseau physique sous-jacent et peut fonctionner sur n'importe quel réseau IP. VXLAN est d'ailleurs le protocole standard des grandes infrastructures cloud (AWS, Azure, GCP) [?], ce qui renforce la crédibilité technologique du projet. Et avec 16 millions de VNIs possibles contre 4 094 VLANs 802.1Q, la scalabilité future est largement couverte.

Le seul inconvénient est un surcoût d'encapsulation de 50 octets par paquet UDP, mais c'est négligeable sur des liaisons Gigabit ou 10 Gigabit Ethernet.

II.6 L'Équilibrage Dynamique de Charge dans les Clusters Virtualisés

Cette section expose la problématique du déséquilibre de charge, passe en revue les mécanismes existants, puis présente l'algorithme CSLB sur lequel s'appuie le CSLB développé dans ce projet.

II.6.1 Problématique du Déséquilibre de Charge

Dans un cluster de virtualisation, les VMs sont placées sur des nœuds lors de leur création et y restent sans mécanisme actif de redistribution. Avec le temps, la charge se répartit inégalement : certains nœuds peuvent être saturés à plus de 90 % de CPU tandis que d'autres restent à moins de 20 %. Ça dégrade les performances des VMs sur les nœuds chargés et gaspille les ressources des nœuds sous-chargés.

II.6.2 Mécanismes d'Équilibrage dans les Plateformes Existantes

VMware vSphere propose le **DRS** *DistributedResourceScheduler* [?], qui analyse en continu les métriques de charge et déclenche des migrations à chaud (vMotion) pour redistribuer les VMs. Le DRS ne migre que si le gain attendu dépasse un seuil configurable, pour éviter des déplacements inutiles.

D'autres plateformes proposent des mécanismes similaires : **Microsoft SCVMM** avec la "Dynamic Optimization" [?] pour Hyper-V, **oVirt** avec son planificateur de cluster via libvirt [?], et **OpenStack Nova** avec son planificateur distribué par filtres et pondérations [?].

Proxmox VE n'a pas de tel mécanisme natif. Ce projet développe un service équivalent, nommé CSLB, s'appuyant sur l'API REST Proxmox et le stockage partagé Ceph.

II.6.3 L'Algorithme CSLB : Base Théorique du CSLB

Le CSLB est fondé sur l'algorithme CSLB de Wilcox pour les environnements de virtualisation distribués [?]. L'algorithme repose sur un scheduler centralisé qui opère en cinq phases [?] :

1. **Évaluation de la charge** : lecture des métriques CPU et RAM de chaque nœud sur une fenêtre temporelle glissante, pour s'affranchir des pics instantanés.
2. **Détermination de rentabilité** : calcul d'une bande modérée autour de la moyenne du cluster. Les nœuds hors de cette bande sont candidats à une action.
3. **Calcul du vecteur de transfert** : quantité de ressources à migrer pour ramener le nœud surchargé dans la bande.
4. **Sélection de la VM** : la VM dont la charge correspond le mieux au vecteur de transfert.
5. **Exécution de la migration** : live migration vers le nœud avec la charge la plus faible.

La live migration n'est possible que si le stockage est partagé entre tous les nœuds. Avec Ceph RBD, le disque d'une VM est accessible depuis n'importe quel nœud [?].

II.7 Outils Complémentaires d'Infrastructure

En plus des trois technologies principales (Proxmox VE, Ceph, Open vSwitch), l'infrastructure utilise plusieurs outils complémentaires : répartition de charge applicative, supervision, automatisation, provisionnement réseau, pare-feu, synchronisation temporelle et intégration continue.

II.7.1 HAProxy : Équilibrage de Charge Applicatif

HAProxy *HighAvailabilityProxy* est un proxy TCP/HTTP open source pour la haute disponibilité et l'équilibrage de charge [?]. Il agit comme point d'entrée unique pour un ensemble de serveurs, distribue les requêtes selon différents algorithmes (round-robin, moins de connexions) et vérifie la disponibilité des backends via des contrôles de santé. Si un backend tombe, HAProxy redirige automatiquement le trafic sans interruption pour l'utilisateur.

II.7.2 Stack de Supervision : InfluxDB, Prometheus et Grafana

Pour superviser l'infrastructure, on a besoin d'outils qui collectent, stockent et visualisent les métriques en temps réel : charge des nœuds, état du stockage, historique des migrations et alertes. Trois outils complémentaires forment cette stack.

InfluxDB [?] est une base de données de séries temporelles optimisée pour les données horodatées. Elle collecte les métriques Proxmox (CPU, mémoire, réseau et stockage) via le mécanisme natif Metric Server. Ces données sont exploitées par Grafana pour la visualisation et par le CSLB pour les décisions de migration.

Prometheus [?] collecte les métriques par interrogation HTTP selon un modèle de données par étiquettes. Il surveille le cluster Ceph via son point d'accès natif et les métriques du service CSLB.

Grafana [?] est l'outil de visualisation connecté aux deux sources précédentes. Il affiche des tableaux de bord unifiés sur l'état des nœuds, du stockage et du CSLB.

II.7.3 Ansible : Automatisation d'Infrastructure

Ansible [?] est un outil d'automatisation *Infrastructure as Code* qui exécute des playbooks YAML via SSH, sans agent sur les machines cibles. Un playbook décrit l'état cible d'une machine et Ansible l'applique de façon **idempotente** : si c'est déjà configuré, rien ne se passe.

Les playbooks sont organisés en tâches séquentielles sur un inventaire YAML. Les seuls prérequis sont SSH et les droits **sudo**. On l'utilise pour intégrer de nouveaux nœuds au cluster, provisionner des VMs et des conteneurs, et promouvoir des environnements de développement vers la production.

II.7.4 PXE et TFTP : Provisionnement Réseau

PXE *PrebootExecutionEnvironment* permet à un serveur de démarrer depuis le réseau sans support local. Il repose sur trois protocoles :

- **DHCP** : attribution d'une adresse IP temporaire et indication du serveur de boot (options DHCP 66 et 67).
- **TFTP** ("Trivial File Transfer Protocol", UDP/69) : téléchargement du bootloader. C'est le seul protocole utilisable dans un firmware pre-OS.
- **HTTP** : téléchargement de l'image d'installation (plusieurs centaines de Mo). TFTP ne convient pas aux gros fichiers car il n'a pas de contrôle de flux.

Ce mécanisme a été utilisé pour l'installation automatique de Proxmox VE sur les serveurs physiques.

II.7.5 OPNsense : Pare-feu et Sécurité Périmétrique

OPNsense [?] est une distribution de pare-feu open source basée sur FreeBSD. Il assure le filtrage stateful des flux, la gestion des règles par interface et par VLAN, et des fonctionnalités avancées comme la détection d'intrusion (Suricata), le VPN *VirtualPrivateNetwork* et le portail captif. Dans notre infrastructure, OPNsense est le point de contrôle entre les segments internes et l'extérieur, notamment pour protéger la zone exposée (DMZ).

II.7.6 NTP : Synchronisation Temporelle

La synchronisation temporelle est critique dans un système distribué. Une dérive d'horloge entre les nœuds peut créer des incohérences dans les journaux, perturber Corosync et Ceph, et fausser les métriques de supervision. Le protocole NTP *NetworkTimeProtocol* [?] synchronise l'horloge de chaque nœud sur un serveur de référence. Un serveur NTP interne au cluster garantit une base de temps commune pour tous les composants.

II.7.7 GitLab CE : Intégration et Déploiement Continu

GitLab CE *CommunityEdition* [?] est une plateforme DevOps open source avec un gestionnaire Git, un système CI/CD *ContinuousIntegration/ContinuousDeployment* et des pipelines d'automatisation. Dans notre contexte, GitLab versionne les configurations d'infrastructure (playbooks Ansible, fichiers de configuration), déclenche les déploiements automatisés et maintient une traçabilité complète des modifications.

II.8 Conclusion

Ce chapitre a posé les bases théoriques du projet. On a défini l'hyperconvergence, comparé les solutions open source et justifié le choix de Proxmox VE, Ceph et Open vSwitch. On a présenté la pile de virtualisation, les mécanismes de clustering, de haute disponibilité et de migration à chaud, ainsi que la segmentation réseau par VXLAN comme réponse à la contrainte du switch Sonatrach. Les fondements de l'algorithme CSLB ont été établis, et les outils complémentaires ont été présentés. Le chapitre suivant détaille la conception de l'architecture proposée.

Chapitre III

Conception de la Solution Proposée

III.1 Introduction

Ce chapitre présente la conception détaillée de l'infrastructure Cloud privée hyperconvergente proposée. Sur la base des technologies retenues dans le chapitre précédent (Proxmox VE, Ceph et Open vSwitch), nous décrivons ici les choix architecturaux guidant la construction de chaque couche de l'infrastructure. Nous présentons également la conception du mécanisme d'équilibrage dynamique de charge CSLB, ainsi que les outils d'automatisation retenus pour le déploiement et le provisionnement.

L'objectif de ce chapitre est de fournir une vision complète et cohérente de l'architecture avant toute phase d'implémentation, en justifiant chaque décision par des contraintes techniques, des recommandations officielles ou des exigences fonctionnelles identifiées précédemment.

III.2 Vue Globale de l'Architecture

L'architecture proposée repose sur un modèle à trois couches superposées et interdépendantes, chacune apportant une dimension essentielle à l'infrastructure hyperconvergente.

La première couche est la **couche physique**, constituée de trois serveurs Dell PowerEdge R720 mis à disposition par le Centre d'innovation de Sonatrach. Proxmox VE sera installé directement en mode bare metal sur chacun de ces serveurs, sans couche de virtualisation intermédiaire, ce qui garantira des performances maximales.

La deuxième couche est la **couche de virtualisation et de cluster**, composée des trois nœuds Proxmox (PVE-01, PVE-02, PVE-03) interconnectés via le réseau Sonatrach. Ces nœuds formeront un cluster haute disponibilité géré par Corosync. Chaque nœud exécutera simultanément les daemons Ceph pour le stockage distribué et une instance Open vSwitch avec des tunnels VxLAN pour la segmentation réseau. Cette convergence des rôles est l'expression directe du principe HCI.

La troisième couche est la **couche applicative et de services**, hébergeant la VM OPN-sense pour le routage et le pare-feu, les VMs de démonstration Sona-Web, le mécanisme CSLB, la stack de monitoring, et les outils d'automatisation Ansible.




FIGURE III.1 – Architecture Globale de l'Infrastructure HCI

La figure III.1 représente les trois couches superposées de l'architecture HCI : la couche physique composée des serveurs Dell R720, la couche de virtualisation et de cluster portant Proxmox, Ceph et Open vSwitch, et la couche applicative hébergeant les services déployés. Elle met en évidence la convergence des rôles sur chaque noeud physique, principe fondateur de l'hyperconvergence.

III.3 Organisation de la Solution

La conception de l'infrastructure hyperconvergée a été structurée en trois parties complémentaires et interdépendantes : le **Calcul**, le **Stockage** et le **Réseau**. Cette partition reflète les trois piliers fondamentaux de tout système HCI, chacun apportant une dimension essentielle à l'ensemble. Les choix effectués dans chaque partie influencent directement les deux autres : le stockage distribué Ceph repose sur le réseau pour la réplication, le mécanisme CSLB dépend du stockage partagé pour les migrations à chaud, et la segmentation réseau conditionne la sécurité de l'ensemble. Le schéma ci-dessous illustre cette organisation ainsi que les interactions entre les trois parties.




FIGURE III.2 – Organisation de la Solution en Trois Parties et leurs Interactions

La figure III.2 met en évidence les flux entre les parties : la partie Calcul s'appuie sur le Stockage pour les volumes RBD des VMs et pour les migrations à chaud réalisées par CSLB, le Stockage utilise le Réseau pour transporter les flux de réplication Ceph sur les VxLAN 30 et 40, et le Réseau fournit la segmentation applicative qui conditionne l'isolation et la sécurité de toutes les couches. Les relations détaillées au niveau composant (CSLB vers VxLAN 50, VMs Sona-Web vers pool RBD, Monitoring vers endpoint Ceph, Ansible vers OPNsense) illustrent le niveau d'interdépendance réel entre les trois parties.

III.4 Partie I : Calcul

Cette partie traite de la couche de calcul de l'infrastructure. Elle présente les serveurs physiques constituant les nœuds du cluster, l'organisation du cluster Proxmox et ses mécanismes de haute disponibilité via Corosync, le mécanisme d'équilibrage de charge CSLB développé spécifiquement pour ce projet, l'application de démonstration Sona-Web, la stack de monitoring déployée pour superviser l'ensemble de la plateforme, et enfin les outils d'automatisation Ansible et PXE permettant le déploiement et le provisionnement sans intervention manuelle.

III.4.1 Infrastructure Physique

L'infrastructure physique est constituée de trois serveurs Dell PowerEdge R720. Ces serveurs forment les nœuds du cluster Proxmox : PVE-01, PVE-02 et PVE-03. Proxmox VE sera installé directement en mode bare metal sur chacun d'eux, sans couche de virtualisation intermédiaire. Le Dell PowerEdge R720 est un serveur rack 2U de la gamme Entreprise de Dell, équipé de processeurs Intel Xeon E5-2600, adapté aux charges de virtualisation intensive et au stockage distribué.

Chaque serveur dispose de cinq disques SAS répartis selon leurs rôles respectifs, conformément aux recommandations Proxmox concernant la séparation des entrées/sorties système et de stockage :

- **Disque système (sda, 1 × 300 GB SAS) :** dédié au système d'exploitation Proxmox VE. Cette séparation garantit que les opérations de réplication Ceph ne perturbent pas les I/O système du nœud.
- **Disques OSD Ceph (1 × 300 GB SAS + 3 × 600 GB SAS) :** les quatre disques restants sont affectés comme OSDs Ceph. Chaque nœud contribue ainsi avec quatre OSDs au cluster de stockage distribué, soit douze OSDs au total dans le cluster.

Le tableau III.1 récapitule le dimensionnement matériel de chaque serveur Dell PowerEdge R720 ainsi que les ressources totales du cluster.

TABEAU III.1 – Dimensionnement physique des serveurs Dell PowerEdge R720

Composant	Par nœud	Total cluster	Justification
Modèle serveur	Dell R720	3 serveurs	Fourni par Sonatrach
RAM	64 GB	192 GB	Proxmox + Ceph + VMs
Disque OS (sda)	1 × 300 GB SAS	3 × 300 GB	Isolation I/O hôte / Ceph
Disques OSD (sdb-sde)	1 × 300 GB + 3 × 600 GB SAS	12 OSDs (6,3 TB brut)	Stockage distribué Ceph
IP Management	voir tableau III.2		Réseau Sonatrach 192.168.10.0/24

III.4.2 Architecture du Cluster Proxmox

Le cluster Proxmox regroupera les trois nœuds physiques en une entité unique administrée de façon centralisée. Cette section en détaille l'organisation, le mécanisme de quorum assuré par Corosync, le fonctionnement de la haute disponibilité et les scénarios de défaillance pris en charge.

III.4.2.1 Organisation du Cluster

Le cluster Proxmox sera constitué de trois nœuds physiques identiques, interconnectés via le réseau Sonatrach. Le trafic Corosync sera transporté sur un réseau logique dédié (VxLAN ID 20) afin de garantir la stabilité du quorum indépendamment des autres flux. Cette organisation

à trois nœuds est le minimum requis pour garantir un quorum stable et éviter les situations de split-brain.

Le tableau III.2 indique les adresses IP de management attribuées à chacun des trois nœuds du cluster.

TABLEAU III.2 – Adresses IP de management des nœuds Proxmox

Nœud	Nom d'hôte	Adresse IP Management
Nœud 1	PVE-01	192.168.10.100
Nœud 2	PVE-02	192.168.10.213
Nœud 3	PVE-03	192.168.10.84

III.4.2.2 Mécanisme de Quorum et Corosync

Corosync est le framework de communication utilisé par Proxmox pour assurer le consensus entre les nœuds. Il envoie des messages de heartbeat à intervalles réguliers via le VxLAN 20. Le quorum dans un cluster de trois nœuds est atteint dès que deux nœuds sur trois sont opérationnels. La perte simultanée de deux nœuds entraîne le gel du cluster pour prévenir toute corruption des données.

III.4.2.3 Haute Disponibilité

Le mécanisme de haute disponibilité de Proxmox s'appuie sur Corosync pour la détection des pannes et sur le Resource Manager HA pour les décisions de basculement. Lorsqu'un nœud est déclaré défaillant, le HA Manager identifie les VMs concernées et déclenche leur redémarrage automatique sur un nœud survivant. Ce mécanisme est rendu possible par le stockage partagé Ceph : les disques des VMs étant accessibles depuis n'importe quel nœud, le redémarrage ne nécessite aucun transfert de données préalable. Le délai de basculement est typiquement compris entre 60 et 120 secondes.

Toutes les VMs de l'application Sona-Web seront configurées en mode HA, avec une priorité de basculement définie : HAProxy en premier, suivi des serveurs Flask, puis de la base PostgreSQL.

III.4.2.4 Matrice des Scénarios de Défaillance

Le tableau III.3 recense les principaux scénarios de défaillance envisagés, en précisant pour chacun le composant affecté, le comportement attendu de l'infrastructure et l'objectif de temps de rétablissement (RTO).

TABLEAU III.3 – Matrice des scénarios de défaillance et comportements attendus

Scénario	Composant affecté	Comportement	RTO
Panne d'un nœud physique	PVE-01, 02 ou 03	Corosync détecte la perte. HA redémarre les VMs sur les survivants. Ceph passe en degraded mais reste accessible.	60–120 s
Panne d'un OSD	Disque sdb	Ceph marque l'OSD down . Le pool passe en degraded (2/3 répliques). Backfill automatique après rétablissement.	Aucune coupure
Panne du MGR actif	PVE-02 (MGR)	Le MGR standby (PVE-03) prend le relais. Endpoint Prometheus disponible sans interruption.	< 30 s
Panne de deux nœuds	Deux des trois nœuds	Perte du quorum. Le nœud survivant se gèle. Intervention manuelle requise.	N/A
Panne VM OPNsense	VM routeur/pare-feu	Proxmox HA redémarre la VM sur un nœud survivant. Le trafic inter-réseaux est interrompu pendant la durée du redémarrage.	60–120 s
Split-brain	Réseau Vx-LAN 20	Le groupe minoritaire perd le quorum et se gèle. Le groupe majoritaire continue d'opérer.	Aucune coupure côté majoritaire
Panne CSLB	VM CSLB	Aucun impact applicatif. Le service redémarre automatiquement (Restart=always systemd).	Aucune coupure

III.4.3 Mécanisme d'Équilibrage Dynamique : CSLB

Cette section présente le mécanisme d'équilibrage dynamique de charge CSLB développé pour ce projet : le besoin auquel il répond, sa base algorithmique, les adaptations apportées à l'algorithme d'origine et sa logique de décision.

III.4.3.1 Contexte et Besoin

Proxmox VE intègre un mécanisme de haute disponibilité réactif : lorsqu'un nœud tombe en panne, les VMs sont redémarrées sur les nœuds survivants. Cependant, Proxmox ne dispose d'aucun mécanisme proactif d'équilibrage de charge, contrairement à VMware vSphere qui propose le DRS (Distributed Resource Scheduler). Sans équilibrage proactif, un nœud peut être saturé à 90% de CPU tandis qu'un autre reste à 20%, dégradant les performances et gaspillant les ressources disponibles.

III.4.3.2 Base Algorithmique : CSLB

Notre mécanisme, nommé **CSLB**, est une adaptation du CSLB [?]. L'algorithme original repose sur cinq phases : évaluation de charge, détermination de rentabilité, calcul du vecteur

de transfert, sélection de VM, et exécution de la migration [?]. La charge CPU de chaque nœud est évaluée par rapport à un seuil dynamique (moyenne des charges de tous les nœuds) :

$$\text{seuil} = \frac{\sum_{i=1}^n \alpha_i}{n} \dots (1), \quad \text{diff} = \left| \text{seuil} - \frac{\alpha_{\min} + \alpha_{\max}}{2} \dots (2) \right|$$

La bande modérée est définie, à partir des équations (1) et (2), à $\pm \max(\text{diff}, 10\%)$ autour du seuil. Les nœuds hors de cette bande sont candidats à une action d'équilibrage.

III.4.3.3 Modifications Apportées au CSLB

Notre adaptation introduit plusieurs modifications importantes par rapport à l'algorithme original.

- **Implémentation en Go** : retenu pour sa faible empreinte mémoire, sa gestion native de la concurrence via les goroutines, et la simplicité du déploiement sous forme de binaire statique dans un service systemd [?].
- **Extension à la RAM** : le CSLB original ne considère que le CPU. Notre implémentation calcule une bande modérée indépendante pour la RAM. Un nœud est surchargé si l'une ou l'autre dépasse sa bande respective.
- **Seuil minimum de migration** : une migration n'est déclenchée que si la charge dépasse un seuil absolu de 50% (CPU ou RAM), évitant des déplacements inutiles dans un cluster globalement sous-chargé.
- **Sélection du nœud destination pondérée** : le choix du nœud de destination se fonde sur un score pondéré :

$$\text{score} = \Delta_{CPU} \times 0.7 + \Delta_{RAM} \times 0.3 \dots (3)$$

Avant validation, CSLB simule l'état post-migration du nœud cible en appliquant le score pondéré défini par l'équation (3) pour s'assurer que l'ajout de la VM ne le fait pas dépasser la bande haute.

- **Exclusion des VMs système** : OPNsense, la VM monitoring et la VM CSLB sont explicitement exclues du périmètre de migration.
- **Cadence et unicité** : CSLB s'exécute toutes les 60 secondes et ne peut déclencher qu'une seule migration par cycle.
- **Cooldown post-migration** : une période de repos de 5 minutes est appliquée après chaque migration, le temps que les métriques InfluxDB intègrent l'impact du changement.
- **Mécanismes anti-oscillation** : si une même VM est migrée deux fois en moins de 10 minutes, elle est gelée 30 minutes et l'administrateur est notifié. Si 6 migrations ou plus sont enregistrées en 30 minutes, le service se suspend automatiquement pendant une heure (circuit breaker).
- **Collecte des métriques** : CSLB combine l'API REST Proxmox pour les métriques courantes, et InfluxDB via le client Go officiel pour les moyennes glissantes sur 5 minutes, garantissant des décisions fondées sur des données lissées plutôt que sur des pics instantanés.

III.4.3.4 Algorithme de Décision (Pseudocode)

```
toutes les 60 secondes :  
    recuperer metriques CPU et RAM moyenees (5 min) depuis InfluxDB  
    calculer seuil_cpu, bande_moderee_cpu  
    calculer seuil_ram, bande_moderee_ram  
  
    pour chaque noeud N :  
        si (cpu_N > bande_haute_cpu OU ram_N > bande_haute_ram)  
            ET (cpu_N > 50% OU ram_N > 50%) :  
  
                candidats_vm = VMs sur N non migrees recemment (cooldown 10 min)  
                vm_cible = VM dont la charge est la plus proche du  
                    vecteur de transfert calcule (phase 3 CSLB)  
  
                pour chaque noeud destination D (bande legere) :  
                    score_D = (cpu_N - cpu_D) * 0.7 + (ram_N - ram_D) * 0.3  
                noeud_dest = D avec score_D maximal  
  
                si noeud_dest trouve :  
                    declencher live migration vm_cible -> noeud_dest  
                    via API Proxmox (VxLAN 50)  
                    enregistrer migration dans InfluxDB  
                    appliquer cooldown anti-oscillation (10 min sur vm_cible)
```

Figure III.3 – Pseudocode de l'algorithme CSLB

La figure ?? présente le pseudocode de l'algorithme CSLB sous sa forme condensée. Chaque cycle commence par la récupération des métriques CPU et RAM lissées sur 5 minutes depuis InfluxDB, afin d'éviter les décisions basées sur des pics instantanés. Le double critère de déclenchement (dépassement de la bande modérée ET seuil absolu de 50%) garantit qu'aucune migration n'est effectuée dans un cluster globalement sous-chargé. La sélection de la VM cible repose sur le vecteur de transfert du CSLB, et le score pondéré 0.7/0.3 en faveur du CPU reflète le fait que la pression CPU est généralement plus contraignante que la RAM dans les charges de virtualisation.

FIGURE III.4 – Logique de Décision du Mécanisme CSLB

La figure ?? présente le cycle de décision complet du service CSLB. A chaque intervalle de 60 secondes, le service évalue la charge de chaque noeud par rapport aux bandes modérées calculées dynamiquement, sélectionne la VM la mieux adaptée au transfert selon le vecteur de charge, choisit le noeud destination en maximisant le score pondéré CPU/RAM, et déclenche la migration via l'API Proxmox si toutes les conditions sont réunies. Les mécanismes anti-oscillation et le circuit breaker sont également représentés.

III.4.4 Application de Démonstration : Sona-Web

L'application Sona-Web sert de cas d'usage pour valider les capacités de haute disponibilité et de migration à chaud de l'infrastructure. Cette section en décrit l'architecture applicative,

puis le scénario de validation associé.

III.4.4.1 Architecture Applicative

Sona-Web est une application web déployée sur le cluster pour démontrer les capacités de haute disponibilité et de live migration. Elle sera constituée de quatre VMs Debian 12 interconnectées :

- **HAProxy** : point d'entrée unique de l'application. Il distribue les requêtes HTTP entre les deux serveurs applicatifs selon l'algorithme round-robin et surveille leur disponibilité toutes les 200 ms (`GET /health`), basculant vers l'instance disponible en moins de 200 ms (`fall 1`) en cas d'indisponibilité [?].
- **Flask app-1 et app-2** : deux instances identiques de l'application Python Flask. Chaque instance enregistre de manière asynchrone en base de données toutes les requêtes reçues.
- **PostgreSQL** : base de données centralisée dont le disque est stocké sur un volume Ceph RBD, garantissant un historique cohérent.




FIGURE III.5 – Architecture Applicative Sona-Web

La figure ?? illustre l'architecture en quatre tiers de l'application Sona-Web. HAProxy constitue le point d'entrée unique et distribue le trafic entre les deux instances Flask selon un algorithme round-robin. Les deux serveurs applicatifs écrivent dans une base PostgreSQL centralisée dont le disque est stocké sur le pool Ceph RBD partagé, garantissant la cohérence des données quelle que soit la position des VMs dans le cluster.

III.4.4.2 Scénario de Validation HA

Le scénario de validation se déroule en plusieurs temps : affichage de l’alternance round-robin entre app-1 et app-2, puis déclenchement d’une live migration de VM-202 (**app-1**) vers un autre nœud. Pendant la migration, Proxmox transfère l’état mémoire de la VM sans l’arrêter. Lorsque la synchronisation atteint ~99%, la VM est suspendue quelques dizaines de millisecondes le temps de transférer le delta final, puis reprend sur le nœud cible.

HAProxy détecte l’indisponibilité transitoire en 200 ms maximum et redirige l’intégralité du trafic vers app-2. Une fois la migration terminée, app-1 est remise en service dès le premier health check réussi (**rise 1**).

III.4.5 Architecture du Monitoring

La stack de monitoring sera déployée dans un conteneur LXC dédié à l’adresse 192.168.10.99. Elle comprend trois composants complémentaires couvrant des périmètres de métriques distincts.

InfluxDB recevra les métriques générales de Proxmox (CPU, RAM, réseau, stockage des nœuds et des VMs) via le mécanisme natif “Metric Server”, sans agent supplémentaire. Cet historique sera utilisé à la fois par Grafana pour la visualisation et par le service CSLB pour ses décisions de migration.

Prometheus collectera les métriques détaillées du cluster Ceph via l’endpoint exposé par le nœud MGR actif sur le port 9283. Les métriques applicatives du service CSLB seront également exposées sur le port 9101 de la VM dédiée.

Grafana sera connecté à InfluxDB et à Prometheus comme sources de données, permettant de construire des tableaux de bord unifiés couvrant l’ensemble de l’infrastructure : utilisation des ressources par nœud, état du cluster Ceph, historique des migrations CSLB, et alertes de surcharge [?].

III.4.6 Automatisation

Le schéma suivant présente l’organisation du pipeline d’automatisation, composé de deux outils complémentaires : Ansible pour la configuration logicielle et l’intégration au cluster, et le pipeline PXE/TFTP pour l’installation système initiale des nœuds physiques. Ces deux mécanismes couvrent l’intégralité du cycle de vie d’un serveur, depuis la mise sous tension jusqu’à son intégration complète dans la plateforme.




FIGURE III.6 – Pipeline d'Automatisation : PXE/TFTP et Ansible

La figure ?? illustre le découpage en deux phases du pipeline d'automatisation. La Phase 1, entièrement automatique et opérant en environnement pre-OS, installe Proxmox VE sur le serveur via PXE, TFTP et HTTP sans aucune frappe clavier. La Phase 2 prend le relais dès que le système est démarré, en exécutant le Playbook 1 via SSH pour intégrer le nœud au cluster, configurer les VxLAN, rejoindre Ceph et enregistrer le monitoring. Les Playbooks 2 et 3, déclenchés à la demande, couvrent respectivement le provisionnement de nouvelles VMs depuis les templates cloud-init et la promotion d'environnements vers la production ou la DMZ.

III.4.6.1 Ansible : Périmètre et Playbooks

Ansible est l'outil d'automatisation principal, exécuté depuis les postes de travail des développeurs via SSH sur le réseau de management. Quatre playbooks couvrent les principaux besoins d'automatisation liés au cycle de vie des machines virtuelles.

- **Playbook 1 (Provisionnement d'une VM)** : automatise la création d'une VM à partir d'un template Debian préparé dans le pool Ceph. Il couvre le clonage du template, la configuration matérielle (CPU, RAM), l'attribution d'une adresse IP statique via cloud-init, le démarrage de la VM et sa mise à jour initiale.
- **Playbook 2 (Bootstrap d'une VM)** : initialise la gestion Ansible sur une machine fraîchement créée à partir de son adresse IP, sans qu'elle figure préalablement dans l'inventaire. Il installe les dépendances nécessaires, crée l'utilisateur dédié `ansible` avec les droits `sudo` appropriés et déploie la clé SSH de gestion.
- **Playbook 3 (Synchronisation NTP)** : configure `chrony` sur l'ensemble du cluster. Le nœud `pve-01` est désigné maître NTP interne — il se synchronise depuis `pool.ntp.org` et distribue le temps aux autres nœuds, qui le prennent comme source prioritaire avec `pool.ntp.org` en secours.
- **Playbook 4 (Provisionnement en lot)** : permet la création simultanée de plusieurs VMs à partir d'une liste de définitions YAML, en invoquant le playbook de provisionnement unitaire pour chaque entrée de la liste.

III.4.6.2 Pipeline PXE/TFTP

Dans une optique de scalabilité, l'intégration de tout nouveau serveur physique a été conçue autour d'un pipeline de provisionnement entièrement automatique, structuré en deux phases : une installation système initiale en environnement "pre-OS" via PXE/TFTP, puis une intégration logique au cluster pilotée par Ansible. L'objectif est d'enregistrer un serveur Dell PowerEdge R720 vierge dans l'infrastructure sans aucune intervention manuelle, en s'appuyant uniquement sur le démarrage réseau.

Pourquoi PXE et TFTP ? Le démarrage réseau PXE ("Preboot eXecution Environment") repose sur une contrainte fondamentale : au moment du boot, la machine ne dispose d'aucun système d'exploitation, d'aucune pile TCP complète, ni d'aucune bibliothèque logicielle. Le client PXE, intégré directement dans le firmware de la carte réseau, ne dispose que de quelques dizaines de kilo-octets de mémoire et d'une pile réseau UDP minimale. Cette contrainte exclut l'usage de protocoles comme FTP ("File Transfer Protocol"), SSH ou HTTP avec TLS ("Transport Layer Security"), qui nécessitent tous un OS opérationnel. TFTP ("Trivial File

Transfer Protocol”), défini par la RFC 1350 et opérant sur le port UDP/69, est le seul protocole compatible avec cet environnement “pre-OS” : son implémentation ne dépasse pas quelques kilo-octets et il ne requiert ni authentification ni connexion TCP.

En revanche, la limitation inhérente à TFTP (un mécanisme de transfert “stop-and-wait” d’un bloc de 512 octets à la fois) le rend inadapté au transfert de fichiers volumineux. Dans la conception retenue, TFTP est donc strictement réservé aux fichiers de démarrage (bootloader et kernel), dont la taille totale n’excède généralement pas 40 Mo. Les fichiers volumineux, comme l’image d’installation ISO (environ 800 Mo) ou le fichier de réponses automatiques (“preseed”), sont ensuite téléchargés via HTTP dès que le kernel Linux est en mémoire et dispose d’une pile TCP complète. Le tableau ?? compare les protocoles envisagés aux différentes étapes du pipeline de démarrage réseau.

TABLEAU III.4 – Comparaison des protocoles envisagés dans le pipeline PXE

Protocole	Transport	Nécessite un OS	Usage dans le pipeline
TFTP	UDP/69	Non	Bootloader + kernel (≤ 40 Mo)
HTTP	TCP	Oui (après kernel)	Image ISO + preseed (≈ 800 Mo)
FTP	TCP	Oui	Inutilisable en pre-OS
SSH/SFTP	TCP	Oui	Post-installation uniquement

Architecture du pipeline conçu. L’architecture retenue repose sur quatre composants principaux, hébergés dans des conteneurs LXC dédiés sur le cluster Proxmox. Le serveur DHCP (OPNsense) fournit une adresse IP au nœud en démarrage réseau et lui indique, via les options 66 et 67, l’adresse du serveur TFTP et le nom du fichier bootloader à télécharger. Un conteneur LXC dédié héberge le serveur TFTP (`tftpd-hpa`) ainsi que les fichiers de boot : le bootloader, les modules Syslinux, le kernel `vmlinux` et l’image `initrd.img`. Un second conteneur LXC héberge un serveur HTTP Nginx qui met à disposition l’image d’installation et le fichier “preseed”. Enfin, le nœud physique cible amorce la séquence depuis son firmware.

Phase 1 : Installation automatique via PXE. Lorsqu’un nouveau serveur est mis sous tension, la séquence de démarrage réseau se déroule en plusieurs étapes successives, sans aucune frappe clavier :

1. La machine envoie une requête DHCP en broadcast ; OPNsense lui attribue une adresse IP et lui indique, via les options 66 et 67, l’adresse du serveur TFTP et le nom du fichier bootloader à récupérer.
2. Le client PXE télécharge le bootloader (`pxelinux.0` en mode BIOS Legacy, `grubx64.efi` en mode UEFI) via TFTP (UDP/69), seul protocole utilisable dans un firmware pre-OS.
3. Le bootloader charge le menu de boot puis récupère via TFTP le kernel Linux (`vmlinux`) et l’image disque initiale (`initrd.img`).
4. Le kernel s’exécute en mémoire vive et prend le contrôle de la machine ; il télécharge ensuite l’image d’installation Proxmox VE (~ 800 Mo) et le fichier “preseed” via HTTP depuis le serveur Nginx, car TFTP est inadapté aux fichiers volumineux.
5. L’installateur Proxmox applique le fichier “preseed” (partitionnement, nom d’hôte, fuseau horaire, langue) et déroule l’installation de manière entièrement automatisée.

6. Le serveur redémarre automatiquement sur Proxmox VE fraîchement installé.

Phase 2 : Intégration au cluster via Ansible. À l'issue du redémarrage, le nœud dispose de Proxmox VE fonctionnel mais isolé. Un playbook Ansible prend le relais via SSH pour réaliser l'intégration complète :

- Adhésion au cluster **Corosync** ;
- Configuration des interfaces **Open vSwitch** et des tunnels **VxLAN** ;
- Intégration des disques physiques comme **OSDs** dans le cluster **Ceph** ;
- Rattachement au groupe HA Proxmox (**sona-ha-group**) ;
- Déclaration du nœud comme cible dans **Prometheus**.

Ce découpage en deux phases répond à une contrainte fondamentale : PXE et TFTP interviennent dans un environnement pre-OS où aucun client SSH ne peut fonctionner, tandis qu'Ansible nécessite un système d'exploitation opérationnel. Le pipeline ainsi conçu vise l'ajout d'un nouveau nœud en moins de 25 minutes sans intervention manuelle, et constitue le premier maillon de la chaîne d'automatisation de bout en bout, depuis un serveur vierge jusqu'à un nœud pleinement opérationnel. Sa validation expérimentale, qui requiert du matériel serveur dédié, est présentée parmi les perspectives de ce travail.

III.5 Partie II : Stockage

Cette partie détaille la couche de stockage distribuée de l'infrastructure, reposant entièrement sur Ceph. Elle expose l'architecture du cluster Ceph avec ses composants Monitors, Managers et OSDs, le dimensionnement du pool de stockage en tenant compte du facteur de réplication, et la configuration de l'algorithme CRUSH qui garantit la distribution des répliques sur des domaines de défaillance physiquement distincts.

III.5.1 Architecture du Cluster Ceph

Le cluster Ceph fournira la couche de stockage distribuée et partagée de l'infrastructure. Cette section en présente les composants, le dimensionnement du pool de stockage et la configuration de l'algorithme CRUSH.

III.5.1.1 Composants du Cluster

Le cluster Ceph sera composé des services suivants, répartis sur les trois nœuds physiques :

- **Monitors (MON)** : un monitor par nœud, soit trois au total. Les monitors maintiennent la carte du cluster ("cluster map") et assurent le consensus distribué. Trois monitors garantissent un quorum stable (2/3 suffisants).
- **Managers (MGR)** : PVE-02 hébergera le MGR actif, PVE-03 le MGR en standby. Le MGR exposera les métriques du cluster via un endpoint REST utilisé par Prometheus.

- **OSDs (Object Storage Daemons)** : quatre OSDs par nœud (disques `sdb`, `sdc`, `sdd` et `sde`), soit douze OSDs au total dans le cluster [?].

III.5.1.2 Dimensionnement du Pool

Avec un facteur de réplication de 3, la capacité utilisable est calculée ainsi :

$$\text{Capacité utilisable} = \frac{3 \times (300 + 3 \times 600) \text{ GB}}{3} = \frac{3 \times 2100 \text{ GB}}{3} = 2100 \text{ GB} \approx 2,05 \text{ TB} \dots (4)$$

L'algorithme CRUSH est configuré pour respecter les domaines de défaillance au niveau du nœud physique, garantissant que les trois répliques d'un même bloc ne se retrouvent jamais sur le même serveur. La capacité utilisable du pool, calculée par l'équation (4), s'établit à 2 100 GB, soit environ 2,05 TB. Le tableau suivant présente la répartition prévue :

TABLEAU III.5 – Répartition du stockage Ceph par usage

Usage	Stockage alloué
VM OPNsense	20 GB
HAProxy VM	16 GB
Flask VM 1	32 GB
Flask VM 2	32 GB
PostgreSQL VM	100 GB
VM Monitoring (InfluxDB + Prometheus + Grafana + Loki)	150 GB
VM CSLB	32 GB
LXC GitLab	200 GB
LXC Rundeck	16 GB
LXC OpenLDAP	16 GB
LXC NTP	8 GB
Marge, snapshots et templates	~300 GB
Total estimé	~922 GB (thin)

Le total estimé reste inférieur à la capacité utilisable de 2 100 GB car le thin provisioning de Ceph RBD ne consomme l'espace que proportionnellement aux données réellement écrites.

III.5.1.3 Configuration CRUSH et Domaines de Défaillance

Lors de la création du cluster Ceph via Proxmox VE, une règle CRUSH par défaut est générée automatiquement, organisant les OSDs selon la hiérarchie `root > host > osd` avec la politique `chooseleaf firstn 0 type host`. Cela garantit que les trois répliques d'un objet sont placées sur trois hôtes physiques distincts.

Le tableau ?? résume les principaux paramètres CRUSH appliqués automatiquement par Proxmox lors de la création du cluster Ceph.

TABLEAU III.6 – Paramètres CRUSH appliqués automatiquement par Proxmox

Paramètre	Valeur
Domaine de défaillance	host (généré automatiquement par Proxmox)
Facteur de réplication (size)	3 (une réplique par nœud physique)
min_size	2 (défaut Ceph), pool accessible avec 2 nœuds opérationnels

III.6 Partie III : Réseau

Cette partie décrit la couche réseau de l'infrastructure, conçue pour contourner les limitations du réseau physique Sonatrach. Elle présente les contraintes réseau du site et la solution retenue basée sur VxLAN et Open vSwitch, la topologie en deux niveaux de segmentation (réseaux d'infrastructure et réseaux applicatifs), le plan d'adressage complet, la VM OPNsense assurant le routage centralisé et le filtrage, et l'architecture de pare-feu à deux niveaux couvrant à la fois OPNsense et le pare-feu natif Proxmox.

III.6.1 Contexte et Contraintes Réseau

Le réseau Sonatrach met à disposition un sous-réseau 192.168.10.0/24 utilisé pour l'accès SSH et l'interface web Proxmox. La connectivité Internet des nœuds est assurée par un poste jouant le rôle de routeur externe à l'adresse 192.168.10.36, qui réalise du NAT et du forwarding IP.

Le switch Sonatrach n'autorise que le VLAN 10 natif et ne permet pas la configuration de VLANs supplémentaires. Pour créer les réseaux logiques nécessaires à l'infrastructure, VxLAN a été retenu comme technologie d'encapsulation. VxLAN permet de créer des réseaux logiques de niveau 2 tunnelisés au-dessus du réseau IP existant, sans modifier la configuration du switch. Open vSwitch gèrera la création et la terminaison de ces tunnels sur chaque nœud Proxmox.

III.6.2 Topologie Réseau

La topologie réseau repose sur deux niveaux de segmentation complémentaires, décrits ci-dessous, ainsi que sur les bridges Open vSwitch déployés sur chaque nœud.

III.6.2.1 Deux Niveaux de Segmentation

La topologie retenue s'articule autour de deux niveaux complémentaires.

Niveau 1 : Réseaux d'infrastructure (VxLAN inter-nœuds). Pour les réseaux de contrôle (Corosync, Ceph Cluster, Ceph Public, Live Migration), des tunnels VxLAN point-à-point en maillage complet sont établis entre les trois nœuds. Chaque nœud crée deux ports VxLAN vers chacun des deux autres, garantissant une connectivité directe sans point de transit central.

Niveau 2 : Réseaux applicatifs (OPNsense). Pour les réseaux Dev, Prod et DMZ, une architecture centralisée autour d'une VM OPNsense est utilisée. Trois bridges OVS internes sont configurés sur chaque nœud. OPNsense dispose de quatre interfaces virtuelles : WAN ("Wide Area Network") connectée au réseau de management (192.168.10.65, gateway 192.168.10.36), et trois interfaces LAN ("Local Area Network") connectées aux bridges Dev, Prod et DMZ.




FIGURE III.7 – Topologie Réseau et Plan VxLAN

La figure ?? présente les deux niveaux de segmentation réseau retenus. Le premier niveau repose sur des tunnels VxLAN point-à-point en maillage complet entre les trois nœuds physiques, dédiés aux flux de contrôle (Corosync, Ceph, migrations). Le second niveau utilise OPNsense comme routeur centralisé pour les réseaux applicatifs Dev, Prod et DMZ, chacun associé à un

bridge OVS distinct sur chaque nœud.

III.6.2.2 Bridges Open vSwitch par Nœud

Le tableau ?? décrit les bridges Open vSwitch configurés sur chaque nœud, le VxLAN associé, le sous-réseau correspondant et le rôle de chacun.

TABLEAU III.7 – Bridges OVS et tunnels VxLAN par nœud Proxmox

Bridge OVS	VxLAN associé	Sous-réseau	Rôle
vmbr0	Réseau physique natif	192.168.10.0/24	Bridge principal. Accès management, SSH, Web UI Proxmox, interface WAN d'OPNsense.
vmbr60	vxlan60-int	172.16.60.0/24	Réseau Dev.
vmbr70	vxlan70-int	172.16.70.0/24	Réseau Prod.
vmbr80	vxlan80-int	172.16.80.0/24	Réseau DMZ.

III.6.3 Plan d'Adressage

Le plan d'adressage est organisé en deux familles : les réseaux VxLAN d'infrastructure pour les flux de contrôle, et les réseaux applicatifs internes gérés par OPNsense.

Réseaux VxLAN d'infrastructure :

- **VxLAN 10, Management (192.168.10.0/24)** : Web UI Proxmox, SSH, API (réseau physique existant).
- **VxLAN 20, Corosync (192.168.20.0/24)** : Heartbeats et quorum cluster.
- **VxLAN 30, Ceph Cluster (10.10.30.0/24)** : Réplication OSD interne.
- **VxLAN 40, Ceph Public (10.10.40.0/24)** : Accès des VMs au stockage RBD.
- **VxLAN 50, Live Migration (10.10.50.0/24)** : Migrations à chaud et CSLB.

Réseaux applicatifs internes :

- **Réseau Dev (172.16.60.0/24, gateway 172.16.60.1)** : environnements de développement et de test.
- **Réseau Prod (172.16.70.0/24, gateway 172.16.70.1)** : environnements de production.
- **Réseau DMZ (172.16.80.0/24, gateway 172.16.80.1)** : services exposés, dont HA-Proxy.

Le tableau ?? détaille l'adressage IP statique attribué à chaque nœud Proxmox sur les différents réseaux logiques de l'infrastructure.

TABLEAU III.8 – Adressage IP statique des nœuds Proxmox par réseau logique

Nœud	Management	VxLAN 20	VxLAN 30	VxLAN 40	VxLAN 50
PVE-01	192.168.10.100	192.168.20.11	10.10.30.11	10.10.40.11	10.10.50.11
PVE-02	192.168.10.213	192.168.20.12	10.10.30.12	10.10.40.12	10.10.50.12
PVE-03	192.168.10.84	192.168.20.13	10.10.30.13	10.10.40.13	10.10.50.13

III.6.4 VM OPNsense : Routeur et Pare-feu Centralisé

La VM OPNsense centralise le routage et le filtrage des réseaux applicatifs. Cette section détaille ses interfaces et leurs rôles, puis les mécanismes assurant sa haute disponibilité.

III.6.4.1 Interfaces et Rôles

La VM OPNsense constitue le cœur du réseau applicatif. Il s'agit d'une distribution FreeBSD dédiée aux fonctions de routage et de sécurité réseau. Dans cette architecture, OPNsense sera déployée avec quatre interfaces réseau virtuelles :

- **Interface WAN (192.168.10.65/24)** : connectée au bridge OVS de management, avec gateway 192.168.10.36. Assure l'accès Internet sortant via NAT pour toutes les VMs internes.
- **Interface LAN1 (172.16.60.1/24)** : passerelle du réseau Dev.
- **Interface LAN2 (172.16.70.1/24)** : passerelle du réseau Prod.
- **Interface LAN3 (172.16.80.1/24)** : passerelle du réseau DMZ.

OPNsense intègre nativement dnsmasq, qui sera utilisé comme serveur DHCP pour les trois réseaux internes. L'attribution des adresses IP aux VMs sera ainsi automatisée dès leur connexion à l'un des bridges applicatifs, simplifiant le provisionnement via les playbooks Ansible.

III.6.5 Architecture du Pare-feu

La sécurité réseau de l'infrastructure repose sur deux niveaux de filtrage complémentaires : le pare-feu OPNsense pour les flux entre réseaux applicatifs, et le pare-feu natif de Proxmox au niveau de l'hyperviseur.

III.6.5.1 Pare-feu OPNsense : Filtrage Inter-réseaux

OPNsense applique les politiques de filtrage entre les réseaux applicatifs Dev, Prod et DMZ. Les règles de conception retenues sont les suivantes :

Règles autorisées :

- Dev → WAN : pour les mises à jour et les dépôts de paquets.
- DMZ → WAN : pour les services exposés nécessitant un accès sortant.

- Prod → DMZ : pour la communication entre production et services exposés.

Règles bloquées :

- Dev → Prod : pour isoler les environnements de développement de la production.
- Dev → DMZ : pour empêcher l'accès aux services exposés depuis le développement.
- Prod → WAN direct : le trafic de production passe obligatoirement par la DMZ.

III.6.5.2 Pare-feu Proxmox : Filtrage au Niveau Hyperviseur

Proxmox VE intègre nativement un mécanisme de pare-feu basé sur iptables, configurable aux niveaux cluster, nœud et VM individuelle. Les règles de conception retenues pour protéger la plateforme sont les suivantes :

- **Isolation des réseaux Ceph** : interdire tout trafic des réseaux applicatifs (172.16.x.0/24) vers les réseaux Ceph Cluster (VxLAN 30) et Ceph Public (VxLAN 40).
- **Isolation du réseau Corosync** : interdire tout accès extérieur au VxLAN 20. Seuls les nœuds Proxmox communiquent sur ce réseau.
- **Protection du management** : restreindre l'accès à l'interface web Proxmox (port 8006) et SSH (port 22) aux seules adresses du sous-réseau 192.168.10.0/24.
- **Moindre privilège par VM** : n'autoriser que les ports applicatifs strictement nécessaires sur chaque VM.

Architecture du pare-feu : deux niveaux de filtrage




FIGURE III.8 – Architecture du Pare-feu : OPNsense et Proxmox Firewall

La figure ?? représente les deux niveaux de filtrage coexistant dans l'infrastructure. OPN-sense assure le filtrage inter-réseaux entre Dev, Prod et DMZ selon des politiques d'isolation applicative. Le pare-feu Proxmox, basé sur iptables, opère au niveau de l'hyperviseur pour protéger les réseaux d'infrastructure (Ceph, Corosync) et restreindre l'accès à l'interface de management. Cette défense en profondeur garantit qu'aucune VM applicative ne puisse atteindre les réseaux de contrôle du cluster.

III.7 Services Complémentaires d'Infrastructure

Cette section présente les services transverses qui complètent les trois couches de base (calcul, stockage, réseau). Ils sont déployés sous forme de conteneurs LXC sur le cluster Proxmox et couvrent la supervision avancée, la synchronisation temporelle, la gestion des identités, la gestion du code source et l'automatisation opérationnelle.




FIGURE III.9 – Diagramme de déploiement : répartition des services sur les trois nœuds physiques

La figure ?? présente la répartition des services virtualisés sur les trois nœuds physiques du cluster. PVE-01 concentrera les services réseau et de monitoring. PVE-02 hébergera les services applicatifs de développement (GitLab, Rundeck, OpenLDAP) et le service CSLB. PVE-03 prendra en charge les instances de l'application de démonstration et le GitLab Runner. Chaque nœud contribuera avec quatre OSDs au pool Ceph partagé et hébergera un Monitor Ceph. Les Managers actif et standby seront respectivement sur PVE-02 et PVE-03.

III.7.1 Système de Notification : Grafana Alertmanager

Grafana intègre nativement un système d'alerte permettant de définir des règles de déclenchement directement sur les tableaux de bord existants. Lorsqu'une condition est vérifiée, Grafana génère une alerte et la transmet via un contact point configuré. Dans notre infrastructure, les notifications seront acheminées vers une adresse Gmail via le protocole SMTP [?].

Les alertes couvrent les métriques critiques suivantes :

- **Cluster Ceph** : OSD en état down, pool en état degraded, espace disponible inférieur à 20 %.
- **Nœuds Proxmox** : charge CPU supérieure à 85 %, mémoire disponible inférieure à 10 %, perte de quorum Corosync.
- **Service CSLB** : nombre de migrations excessif déclenchant le circuit breaker, impossibilité de contacter l'API Proxmox ou InfluxDB.
- **Application Sona-Web** : backend HAProxy hors service, taux d'erreurs HTTP 5xx anormal.

À terme, Apprise est envisagé comme couche d'abstraction de notification, permettant d'acheminer les alertes vers plusieurs canaux (email, Discord, Slack) sans dépendre d'un serveur SMTP dédié.




FIGURE III.10 – Pipeline de notification Grafana Alertmanager

La figure ?? présente le pipeline de notification. Grafana évalue les règles d'alerte définies sur les tableaux de bord et transmet les déclenchements à l'Alertmanager intégré, qui les achemine vers le contact point configuré (Gmail via SMTP). La liaison vers Apprise est prévue en extension pour supporter plusieurs canaux de notification sans serveur SMTP dédié.

III.7.2 Centralisation des Journaux : Loki, Alloy et Grafana

La centralisation des journaux reposera sur la pile Loki, Alloy et Grafana. Loki est une solution de stockage de logs qui indexe uniquement les métadonnées (labels) et stocke les messages compressés, ce qui lui confère une empreinte en ressources nettement inférieure à celle d'Elasticsearch. Grafana Alloy (anciennement Grafana Agent) est l'agent de collecte déployé sur chaque nœud et VM ; il transmet les logs vers Loki. Grafana permet ensuite d'interroger et de visualiser ces journaux via le langage LogQL.

Alloy sera installé sur chaque nœud Proxmox et sur les VMs à superviser. Loki sera hébergé dans le conteneur LXC monitoring, aux côtés d'InfluxDB et de Prometheus.

Les services retenus pour la collecte des journaux sont les suivants :

- **Nœuds Proxmox** : journaux système (auth.log, syslog, kern.log) pour la sécurité et le diagnostic matériel.
- **Cluster Ceph** : journaux des démons OSD et MON pour le suivi des événements de santé, de récupération et de rebalancing.
- **OPNsense** : journaux du pare-feu (connexions bloquées, règles déclenchées) et du service DHCP.
- **Authentification SSH** : tentatives de connexion et échecs d'authentification sur les nœuds et VMs (sécurité).




FIGURE III.11 – Architecture de centralisation des journaux : Alloy, Loki et Grafana

La figure ?? présente l'architecture de collecte centralisée des journaux. Les agents Alloy, déployés sur chaque nœud Proxmox et sur les VMs, collectent les journaux et les transmettent vers Loki par push. Loki stocke les messages compressés en indexant uniquement leurs labels. Grafana interroge Loki via LogQL et affiche les journaux dans les mêmes tableaux de bord que les métriques, offrant une vue unifiée de l'infrastructure.

III.7.3 Synchronisation Temporelle : Serveur NTP

La synchronisation temporelle est un prérequis pour tout système distribué. Dans notre infrastructure, Ceph et Corosync dépendent de l'horloge système de chaque nœud : un écart supérieur à quelques secondes peut provoquer des erreurs de quorum Ceph, des incohérences dans les journaux distribués ou des refus d'authentification.

Plutôt que de dédier un conteneur LXC à ce rôle, le serveur NTP sera hébergé directement sur le nœud physique **PVE-01** (192.168.10.100). L'implémentation retenue est **Chrony**, plus réactif que ntpd classique pour les corrections de dérive d'horloge. PVE-01 se synchronisera sur **pool.ntp.org** et constituera la référence temporelle unique pour l'ensemble des nœuds Proxmox ainsi que pour les machines virtuelles et conteneurs LXC de l'infrastructure.

Plutôt que de dédier un conteneur LXC à ce rôle, le serveur NTP sera hébergé directement sur les nœuds physiques Proxmox. **PVE-01** (192.168.10.100) constitue la référence temporelle principale et se synchronise sur **pool.ntp.org** ; en cas d'indisponibilité, les clients basculent successivement vers **PVE-02**, puis **PVE-03**, ensuite vers **pool.ntp.org** directement, et enfin sur l'horloge locale en dernier recours. L'implémentation retenue est **Chrony**, dont l'algorithme de sélection de source gère ce basculement nativement. Les VMs hébergées sur des VLANs distincts (172.16.60/70/80.0/24) atteignent les nœuds PVE via **OPNsense**.




FIGURE III.12 – Hiérarchie NTP : synchronisation temporelle de l'infrastructure

La figure ?? illustre la hiérarchie de synchronisation temporelle. PVE-01 joue le rôle de référence interne (Stratum 3) en se synchronisant sur `pool.ntp.org`. Les autres nœuds et VMs interrogent PVE-01 en priorité, et basculent vers `pool.ntp.org` directement si PVE-01 est indisponible. Cette architecture garantit la cohérence temporelle requise par Ceph et Corosync.

III.7.4 Gestion des Identités : Proxmox et Perspectives

La gestion des identités de l'infrastructure repose sur le système de gestion des utilisateurs et des permissions intégré à Proxmox. Cette solution native permet de définir des comptes utilisateurs, d'attribuer des rôles granulaires et d'appliquer des politiques d'accès adaptées aux différents profils (administrateur, opérateur, lecture seule), sans nécessiter de composant externe.

À titre de perspective, le déploiement d'un annuaire OpenLDAP pourrait être envisagé dans une phase ultérieure du projet afin de centraliser l'authentification sur l'ensemble des services de l'infrastructure, notamment Grafana, GitLab et Rundeck. Cette évolution permettrait d'unifier la gestion des accès depuis un point unique et d'assurer une cohérence des politiques de contrôle d'accès à l'échelle de la plateforme.


III.7.5 Gestion du Code Source et CI/CD : GitLab

GitLab sera déployé sous forme de conteneur LXC Turnkey Linux sur le cluster Proxmox. Le template Turnkey GitLab repose sur Debian 12 et intègre GitLab Community Edition version 17, antérieure à la dernière version disponible (18.x au moment de la rédaction). Une mise à jour vers la dernière version sera réalisée après le déploiement initial, en suivant la procédure officielle de mise à niveau par paliers [?].

Les projets hébergés sur cette instance GitLab seront les suivants :

- **CSLB** : code source du service d'équilibrage de charge en Go.
- **ansible-infra** : ensemble des playbooks Ansible d'automatisation de l'infrastructure.

Des pipelines CI/CD GitLab seront configurés pour automatiser les vérifications de qualité de code et les tests unitaires du service CSLB, ainsi que la validation des syntaxes des playbooks Ansible. Les GitLab Runners seront déployés sous forme de conteneurs LXC sur le cluster et enregistrés dans l'instance GitLab.

FIGURE III.13 – Pipeline CI/CD GitLab pour les projets CSLB et `ansible-infra`

La figure ?? présente le pipeline CI/CD configuré pour les deux projets hébergés sur l'instance GitLab. À chaque push, GitLab déclenche automatiquement le pipeline. Les trois stages (Lint, Tests, Build) s'exécutent sur le GitLab Runner déployé en LXC sur le cluster. Le stage de déploiement met à jour le service `systemd` correspondant sur la VM cible.

III.7.6 Automatisation Opérationnelle : Rundeck

Rundeck est un outil d'automatisation opérationnelle qui expose les playbooks Ansible via une interface web. Il permet aux administrateurs d'exécuter des jobs prédéfinis sans accès direct à la ligne de commande, d'historiser les exécutions avec leurs journaux complets, et de contrôler les permissions d'exécution par utilisateur ou groupe.

Dans notre infrastructure, Rundeck sera déployé dans un conteneur LXC et connecté au dépôt `ansible-infra` hébergé sur GitLab. Les playbooks de provisionnement de VMs, d'intégration de nœuds et de promotion d'environnements sont ainsi accessibles via une interface graphique, sans nécessiter d'accès SSH direct aux nœuds Proxmox.

III.8 Conclusion

Ce chapitre a présenté la conception complète de l'infrastructure Cloud privée hyperconvergée. La partie Calcul couvre les serveurs physiques (5 disques SAS par nœud), le cluster Proxmox avec Corosync et HA, le mécanisme CSLB, l'application Sona-Web, la stack de monitoring et l'automatisation via Ansible et PXE. La partie Stockage détaille le cluster Ceph avec ses douze OSDs, la capacité utilisable de 2,05 TB et la politique CRUSH. La partie Réseau expose l'architecture VxLAN gérée par Open vSwitch, le plan d'adressage complet, le routage centralisé via OPNsense et le plan de pare-feu à deux niveaux. Enfin, les services complémentaires (Alertmanager, Loki, NTP, GitLab, Rundeck) complètent l'infrastructure pour en assurer la supervision, la sécurité et la gestion unifiée.

L'ensemble de ces choix de conception constitue une base cohérente et documentée pour la phase d'implémentation présentée dans le chapitre suivant.

Chapitre IV

Implémentation de la Solution Proposée

IV.1 Introduction

Ce chapitre présente la mise en œuvre concrète de la solution proposée dans le chapitre précédent. L'objectif est de montrer les étapes réelles de déploiement de l'infrastructure hyperconvergée, depuis l'installation de la plateforme de virtualisation jusqu'aux services applicatifs et aux mécanismes d'automatisation. Pour améliorer la lisibilité, l'implémentation est organisée en trois grandes parties : la couche calcul, la couche stockage, puis la couche réseau.

Les opérations ont été réalisées avec plusieurs outils complémentaires : l'interface web Proxmox VE, la ligne de commande Linux, les fichiers de configuration système, OPNsense, Ceph, ainsi que des playbooks Ansible pour automatiser certaines tâches répétitives. Des captures d'écran sont prévues aux points importants afin d'illustrer visuellement les résultats obtenus.

IV.2 Partie I : Couche Calcul

Cette partie couvre l'ensemble des opérations réalisées au niveau de la couche de calcul de l'infrastructure : installation de Proxmox VE, formation du cluster, déploiement du monitoring, implémentation du mécanisme CSLB, et déploiement des services applicatifs.

IV.2.1 Préparation de l'Infrastructure Physique

La préparation de l'infrastructure physique constitue la première étape du déploiement. Elle comprend l'installation de Proxmox VE sur chaque nœud ainsi que la configuration de la connectivité réseau nécessaire au bon fonctionnement du cluster.

IV.2.1.1 Installation de Proxmox VE sur les nœuds

L'installation de la plateforme de virtualisation a commencé par le téléchargement de l'image ISO de Proxmox VE version 9.1.1. Cette image a ensuite été copiée sur une clé USB bootable utilisée pour démarrer chaque serveur Dell PowerEdge R720. Une installation séparée a été réalisée sur chacun des trois nœuds du cluster.

Pendant l'installation, le disque système `sda` a été utilisé pour héberger Proxmox VE. Une configuration réseau statique a aussi été appliquée afin de donner à chaque nœud une adresse de management fixe sur le réseau physique `192.168.10.0/24`. Les adresses retenues sont `192.168.10.100` pour PVE-01, `192.168.10.213` pour PVE-02 et `192.168.10.84` pour PVE-03.

Une fois l'installation terminée, la vérification a été effectuée à travers l'interface web de Proxmox, accessible sur le port `8006`. Comme le montre la Figure ??, cette étape a permis de confirmer que chaque nœud était opérationnel et prêt pour la suite du déploiement.




FIGURE IV.1 – Interface web Proxmox au premier login sur PVE-01.

La Figure ?? montre l'interface web de Proxmox VE après le premier démarrage sur PVE-01. On y retrouve l'écran de connexion avec les champs d'authentification, confirmant que le service web est actif et accessible sur le port 8006 du réseau de management.

IV.2.1.2 Configuration de la connectivité Internet via le laptop gateway

Dans l'environnement de laboratoire, aucun routeur physique dédié n'était disponible pour fournir l'accès Internet aux nœuds Proxmox. Pour cette raison, un laptop a été configuré pour jouer le rôle de passerelle NAT entre le réseau interne de l'infrastructure et Internet. Il possède deux interfaces : `enp0s20f0u4c2` côté infrastructure avec l'adresse `192.168.10.36/24`, et `wlan0` côté Internet avec l'adresse `10.247.78.8/24`.

La première étape consiste à activer le routage IP afin que le système puisse transférer les paquets d'une interface à l'autre. Cette activation doit être faite de manière immédiate puis rendue permanente.

```
sudo sysctl -w net.ipv4.ip_forward=1
sudo vim /etc/sysctl.d/99-ipforward.conf
# Ajouter :
net.ipv4.ip_forward=1
```

Figure IV.2 – Activation du routage IP sur le laptop

Les commandes de la Figure ?? activent le forwarding IP : la première l'active immédiatement, la seconde le rend permanent via le fichier `99-ipforward.conf`. Sans cette étape, le laptop ne peut pas transmettre les paquets entre ses deux interfaces réseau.

Ensuite, des règles `iptables` ont été ajoutées pour réaliser la translation d'adresses NAT et autoriser le forwarding du trafic entre les interfaces du laptop.

```
sudo iptables -t nat -A POSTROUTING -o wlan0 -j MASQUERADE
sudo iptables -A FORWARD -i enp0s20f0u4c2 -o wlan0 -j ACCEPT
sudo iptables -A FORWARD -i wlan0 -o enp0s20f0u4c2 -m state --state
    RELATED,ESTABLISHED -j ACCEPT
```

Figure IV.3 – Configuration NAT avec iptables

Les trois règles de la Figure ?? assurent respectivement : le masquage des adresses sources sur l'interface Internet, l'autorisation du trafic sortant, et l'autorisation des réponses correspondant à des connexions établies. Ensemble, elles permettent aux nœuds Proxmox d'atteindre Internet à travers le laptop.

Pour éviter de perdre ces règles après redémarrage, elles ont été sauvegardées puis activées automatiquement au boot du laptop.

```
sudo pacman -S iptables-nft
sudo iptables-save | sudo tee /etc/iptables/iptables.rules
sudo systemctl enable iptables
```

Figure IV.4 – Persistance des règles iptables

Les commandes de la Figure ?? garantissent la persistance du NAT : la sauvegarde dans `/etc/iptables/iptables.rules` combinée à l'activation du service assure que le NAT sera opérationnel dès le démarrage du laptop, sans intervention manuelle à chaque redémarrage.

Sur chaque nœud Proxmox, la passerelle par défaut a été définie vers `192.168.10.36`, avec des serveurs DNS publics.

Cette configuration a été ajoutée dans le fichier `/etc/network/interfaces`.

```
auto vmbr0
iface vmbr0 inet static
    address 192.168.10.XX/24
    gateway 192.168.10.36
    dns-nameservers 8.8.8.8 8.8.4.4
```

Figure IV.5 – Configuration réseau de base d'un nœud Proxmox

La configuration de la Figure ?? attribue une adresse IP statique à chaque nœud, définit le laptop comme passerelle par défaut et utilise les DNS publics de Google. Le paramètre `XX` est remplacé par la valeur spécifique à chaque nœud (100, 213 ou 84).

Enfin, des routes statiques ont été ajoutées sur le laptop afin de rediriger les réseaux internes `172.16.60.0/24`, `172.16.70.0/24` et `172.16.80.0/24` vers la VM OPNsense, qui assure ensuite le routage vers ces sous-réseaux.

```
nmcli connection modify "Wired connection 1" \
+ipv4.routes "172.16.60.0/24 192.168.10.65" \
+ipv4.routes "172.16.70.0/24 192.168.10.65" \
+ipv4.routes "172.16.80.0/24 192.168.10.65"

nmcli connection up "Wired connection 1"
```

Figure IV.6 – Ajout des routes statiques vers OPNsense

Les routes de la Figure ?? indiquent au laptop que tout trafic destiné aux réseaux internes (172.16.x.0/24) doit être transmis vers l'adresse IP d'OPNsense (192.168.10.65), qui se charge du routage vers la zone applicative appropriée.

Des tests simples comme `ping 8.8.8.8`, `ping google.com` et `apt update` ont confirmé que les nœuds disposaient correctement d'un accès Internet.

IV.2.2 Formation du cluster Proxmox et haute disponibilité

Après avoir installé et connecté les trois nœuds à Internet, l'étape suivante a consisté à les regrouper en un cluster unifié et à configurer les mécanismes de haute disponibilité.

IV.2.2.1 Création et jonction au cluster

Après l'installation de Proxmox VE sur les trois serveurs, la phase suivante a consisté à former un cluster unique. Cette opération a été lancée depuis le premier nœud PVE-01, qui devient le nœud initial du cluster.

```
pvecm create Cluster-Proxmox-VE
```

Figure IV.7 – Création du cluster Proxmox

La commande de la Figure ?? initialise le cluster sur PVE-01, configure automatiquement Corosync pour le mécanisme de heartbeat et génère les fichiers de configuration dans `/etc/pve/`. PVE-01 devient le nœud de référence pour les adhésions suivantes.

Les deux autres nœuds ont ensuite rejoint ce cluster en utilisant l'adresse IP du nœud principal.

```
pvecm add 192.168.10.100
```

Figure IV.8 – Jonction de PVE-02 et PVE-03 au cluster

La commande de la Figure ??, exécutée successivement sur PVE-02 et PVE-03, contacte le nœud initial, échange les certificats d'authentification et intègre le nœud au cluster Corosync existant.

Le réseau Corosync, utilisé pour le heartbeat entre les nœuds, a été isolé sur le VxLAN 20 afin de séparer le trafic de cluster du reste du trafic d'administration ou de production. Une fois la configuration terminée, la commande de vérification a confirmé la présence des trois nœuds avec quorum atteint.

```
pvecm status
```

Figure IV.9 – Vérification de l'état du cluster

La commande `pvecm status` de la Figure ?? affiche l'état du cluster Corosync : nombre de membres actifs, version du quorum, et confirmation de l'atteinte du quorum. Une sortie avec **Quorum: Yes** et trois membres confirme que le cluster est correctement formé. Comme l'illustre la Figure ??, ce résultat est également visible dans l'interface web.




FIGURE IV.10 – Vue du cluster Proxmox montrant les trois nœuds en ligne.

La Figure ?? affiche la vue d'ensemble du datacenter dans l'interface web Proxmox, où les trois nœuds PVE-01, PVE-02 et PVE-03 apparaissent simultanément en ligne. Le tableau de bord indique également l'état de santé du cluster Ceph et le nombre de VMs en cours d'exécution. L'avertissement affiché dans l'interface ("*No valid subscription*") est lié à la tentative d'accès au dépôt `pve-enterprise` de Proxmox, qui nécessite une licence commerciale. Dans le cadre de ce projet, la version communautaire est utilisée; la configuration du fichier `/etc/apt/sources.list.d/` a été modifiée pour pointer vers le dépôt `pve-no-subscription` afin d'éliminer cet avertissement sans impacter le fonctionnement du cluster.

IV.2.2.2 Configuration de la migration à chaud

La migration à chaud des machines virtuelles a été configurée pour utiliser le réseau dédié VxLAN 50. Ce choix permet de ne pas mélanger le trafic de migration avec le trafic utilisateur ou le trafic de stockage.

Dans la configuration du datacenter Proxmox, les paramètres de migration ont été ajustés pour utiliser un réseau spécifique et garder un niveau de sécurité acceptable. Une migration manuelle de test a ensuite été réalisée depuis l'interface web afin de vérifier le déplacement transparent d'une VM d'un nœud à un autre sans interruption notable du service. Les figures ?? et ?? illustrent respectivement l'état avant et après cette opération.




FIGURE IV.11 – Avant la migration live d’une machine virtuelle.

La Figure ?? montre l’état de la VM avant la migration, hébergée sur le nœud PVE-02. On peut observer les métriques de consommation CPU et mémoire ainsi que le nœud d’hébergement actuel dans le panneau de résumé.




FIGURE IV.12 – Après la migration live d’une machine virtuelle.

La Figure ?? confirme que la VM a été déplacée avec succès vers le nœud PVE-03 sans interruption du service. Le journal de tâches affiche les étapes successives de la migration, incluant le transfert de l’état mémoire et la commutation finale.

IV.2.3 Déploiement de la stack de monitoring

Afin de superviser l'état global de l'infrastructure, une stack de monitoring a été déployée dans un conteneur LXC dédié appelé **monitoring**, avec l'adresse **192.168.10.99**. Ce conteneur centralise InfluxDB, Prometheus et Grafana.

IV.2.3.1 Déploiement d'InfluxDB

InfluxDB a été installé pour recevoir les métriques envoyées directement par Proxmox à travers le système natif "Metric Server". Un bucket nommé **proxmox** a été créé afin de stocker les mesures CPU, mémoire, réseau et stockage de chaque nœud du cluster.

Une fois la configuration validée dans l'interface web Proxmox, les métriques ont commencé à être transmises automatiquement sans agent supplémentaire. Comme le montre la Figure ??, la présence des séries temporelles dans l'interface InfluxDB a confirmé le bon fonctionnement de ce mécanisme.



FIGURE IV.13 – Explorateur InfluxDB montrant les métriques reçues depuis Proxmox.

La Figure ?? présente l'interface Data Explorer d'InfluxDB avec les séries temporelles reçues depuis Proxmox. On y distingue les différentes mesures disponibles (CPU, mémoire, réseau) regroupées par nœud dans le bucket **proxmox**, confirmant que le pipeline de collecte fonctionne correctement.

IV.2.3.2 Déploiement de Prometheus

Prometheus a été installé dans le même conteneur afin de collecter les métriques exposées par Ceph et par le service applicatif CSLB. La configuration du fichier **prometheus.yml** contient deux jobs principaux : un job pour les métriques Ceph via le module MGR Prometheus, et un

job pour l'application CSLB développée en Go.

Avant de configurer Prometheus, le module MGR Prometheus de Ceph a été activé sur les nœuds PVE-02 et PVE-03 via la commande suivante, exécutée une seule fois sur le cluster :

```
ceph mgr module enable prometheus
```

Figure IV.14 – Activation du module Prometheus sur les nœuds Ceph

Cette commande expose les métriques du cluster Ceph sur le port 9283 de chaque nœud hébergeant un MGR actif, permettant à Prometheus de les récupérer sans configuration supplémentaire côté Ceph.

```
global:
  scrape_interval: 30s
  evaluation_interval: 30s

scrape_configs:
- job_name: ceph
  static_configs:
    - targets:
      - "192.168.10.213:9283"
      - "192.168.10.83:9283"
      - "192.168.10.100:9283"
    labels:
      cluster: "proxmox-lab"

- job_name: "CSLB"
  static_configs:
    - targets: ["192.168.10.104:9101"]
      scrape_interval: 30s
      scrape_timeout: 10s
```

Figure IV.15 – Extrait du fichier prometheus.yml

la Figure ?? définit deux jobs de collecte : le premier interroge les endpoints Ceph MGR des trois nœuds sur le port 9283, le second scrute le service CSLB sur le port 9101. L'intervalle de 30 secondes constitue un bon compromis entre fraîcheur des données et charge générée sur les cibles.

Après déploiement, l'interface web Prometheus a permis de confirmer que l'ensemble des cibles déclarées apparaissaient avec l'état UP, comme l'illustre la Figure ??.




FIGURE IV.16 – Interface Prometheus montrant les cibles Ceph et CSLB avec l’état UP.

La Figure ?? présente la page “Targets” de l’interface web Prometheus. On observe que deux des trois endpoints Ceph MGR affichent l’état UP (PVE-02 et PVE-03), tandis que celui de PVE-01 apparaît en état DOWN. Ce comportement est tout à fait normal : le module MGR Prometheus n’expose ses métriques sur le port 9283 que lorsque le manager Ceph est en rôle *actif* sur le nœud concerné. PVE-01 héberge un MGR en mode *standby*, c’est-à-dire qu’il ne devient actif qu’en cas de défaillance simultanée des managers de PVE-02 et PVE-03 ; en fonctionnement nominal, son endpoint reste donc inaccessible. Le service CSLB, quant à lui, affiche bien l’état UP, confirmant que la collecte des métriques applicatives est opérationnelle.

IV.2.3.3 Déploiement de Grafana

Grafana a été ajouté comme couche de visualisation unifiée pour les métriques de Proxmox, Ceph et CSLB. Deux sources de données ont été configurées : InfluxDB pour les métriques de Proxmox, et Prometheus pour les métriques Ceph et applicatives. Le tableau ?? récapitule les tableaux de bord configurés ainsi que leur source de données respective.

TABEAU IV.1 – Tableaux de bord Grafana configurés.

Tableau de bord	Source	Métriques principales
Proxmox Cluster	InfluxDB	CPU, RAM, réseau par nœud
Ceph	Prometheus	Santé cluster, pools, latence OSD
CSLB	Prometheus	Historique des migrations

Trois dashboards principaux ont ainsi été utilisés : un dashboard infrastructure Proxmox, un dashboard Ceph, et un dashboard personnalisé pour le service CSLB. La Figure ?? présente le dashboard dédié à l’infrastructure Proxmox, tandis que la Figure ?? illustre celui consacré au cluster Ceph.




FIGURE IV.17 – Dashboard Grafana Infrastructure pour les nœuds Proxmox.

La Figure ?? présente le dashboard Grafana dédié à l'infrastructure Proxmox. Il affiche en temps réel les métriques CPU, mémoire et charge des trois nœuds, ainsi qu'un récapitulatif des VMs en cours d'exécution et des ressources disponibles dans le cluster. La vue complète du dashboard est disponible en Annexe ??.




FIGURE IV.18 – Dashboard Grafana Ceph affichant l'état du cluster, des pools et la latence des OSDs.

La Figure ?? présente le dashboard Grafana dédié au cluster Ceph. On y retrouve l'état global de santé du cluster, les métriques I/O par pool, la latence des OSDs et le taux de répliqua-tion en temps réel, permettant de superviser en continu la couche stockage depuis la même interface unifiée. La vue complète du dashboard est disponible en Annexe ??.

IV.2.4 Implémentation du mécanisme CSLB

Le mécanisme CSLB constitue l'une des contributions principales de ce projet. Il s'agit d'un service d'équilibrage proactif développé spécifiquement pour pallier l'absence de DRS natif dans Proxmox VE.

IV.2.4.1 Structure du service

Le service CSLB est développé en Go et tourne dans une VM dédiée sur le réseau de management. Il analyse périodiquement la charge CPU du cluster et déclenche des migrations live si nécessaire.

Le code se compose de quatre éléments principaux : un lecteur InfluxDB, un client API Proxmox, un calculateur de charge, et un moteur de décision. La configuration est chargée depuis un fichier `.env` au démarrage.

IV.2.4.2 Logique de décision

À chaque cycle, le service récupère la charge des nœuds et les classe en trois catégories : *heavy*, *moderate* ou *light*. En cas de déséquilibre, le moteur sélectionne la VM la plus adaptée à migrer.

Pour éviter les migrations excessives, plusieurs garde-fous sont en place : un cooldown global, un cooldown par VM, et une suspension temporaire si la fréquence de migration devient trop élevée.

IV.2.4.3 Déploiement comme service systemd

Une fois compilé, le binaire Go a été déployé sur la VM CSLB puis intégré comme service `systemd` afin d'assurer un démarrage automatique et une relance en cas de panne.

```
systemctl enable CSLB
systemctl start CSLB
journalctl -u CSLB.service -f -o cat
```

Figure IV.19 – Gestion du service CSLB avec systemd

Les trois commandes de la Figure ?? activent le démarrage automatique du service au boot, le démarrent immédiatement, et affichent les journaux en temps réel. Comme le montre la Figure ??, ces journaux permettent de suivre en direct les décisions de migration et les éventuelles erreurs de connexion à l'API Proxmox ou à InfluxDB.



image/ch4/CSLB_logs.png

FIGURE IV.20 – Journaux systemd du service CSLB lors d’un cycle de détection et de migration.

La Figure ?? présente la sortie de la commande `journalctl` pour le service CSLB pendant un cycle de détection actif. On y observe la classification des nœuds par bande de charge (heavy/moderate/light), la sélection de la VM candidate à la migration, le déclenchement de l’opération via l’API Proxmox et l’activation du cooldown post-migration.


IV.2.4.4 Validation du mécanisme

Pour valider le comportement du service, deux VMs de test ont été créées puis soumises à une charge CPU artificielle avec l’outil `stress-ng`. Le service CSLB a détecté la surcharge et a déclenché une migration live vers un nœud moins chargé.

```
stress-ng --cpu 8 --timeout 10m
```

Figure IV.21 – Génération d’une charge CPU de test

La commande de la Figure ?? lance 8 workers saturant les cœurs CPU disponibles. Cette surcharge artificielle déclenche la logique de détection du service CSLB qui, après vérification des seuils, sélectionne la VM candidate et initie sa migration vers un nœud moins chargé. Comme l’illustre la Figure ??, le résultat est directement visible dans le dashboard dédié.



image/ch4/CSLB dashboard.png

FIGURE IV.22 – Dashboard CSLB montrant une migration déclenchée automatiquement.

La Figure ?? présente le dashboard Grafana du service CSLB après le déclenchement d’une migration automatique. On y observe l’historique de charge des nœuds par bande (heavy/moderate/light), la migration enregistrée dans la section “Migration Activity”, ainsi que le cooldown restant avant le prochain cycle d’évaluation.

IV.2.5 Déploiement de l'application Sona-Web

L'application Sona-Web a été déployée sur l'infrastructure pour démontrer concrètement les capacités de haute disponibilité et de répartition de charge offertes par la plateforme hyperconvergée.

IV.2.5.1 Création des machines virtuelles

L'application Sona-Web a été déployée sous la forme de plusieurs VMs créées à partir d'un template Debian stocké dans le pool Ceph. Cette architecture comprend une VM HAProxy en frontal, deux VMs Flask pour la couche applicative, et une VM PostgreSQL pour la base de données.

Les VMs ont été déployées sur les réseaux internes appropriés, avec attribution d'adresse IP par DHCP selon la zone de sécurité visée. Cette organisation permet de séparer la partie exposée, la partie applicative et la base de données.

IV.2.5.2 Résultats de l'application Sona-Web

Afin de présenter concrètement les fonctionnalités de l'application déployée, des captures de l'interface Sona-Web ont été réalisées en conditions réelles d'utilisation. La Figure ?? en présente le tableau de bord principal.




FIGURE IV.23 – Interface principale de l'application Sona-Web.

La Figure ?? présente le tableau de bord principal de Sona-Web, accessible via HAProxy sur le port 8080. L'interface affiche en temps réel l'instance Flask ayant traité la requête courante, le nombre total de requêtes enregistrées en base de données, ainsi que l'état de disponibilité des deux serveurs applicatifs.

IV.2.6 Automatisation avec Ansible

L'automatisation est un élément clé de la reproductibilité de l'infrastructure. Les playbooks Ansible développés permettent de provisionner de nouvelles VMs en quelques minutes et d'assurer leur intégration complète dans le cluster sans intervention manuelle.

IV.2.6.1 Environnement et structure du projet

Afin de simplifier le provisionnement des machines virtuelles et de rendre l'infrastructure plus reproductible, un environnement Ansible a été mis en place. Les connexions se font via SSH depuis les postes des développeurs vers le réseau de management, sans installation d'agent sur les nœuds cibles.

```
ansible-infra/
├── ansible.cfg
├── secrets.yml
├── inventory/
│   ├── hosts.yml
│   └── proxmox_nodes.yml
└── playbooks/
    ├── bootstrap.yml
    ├── ntp_sync.yml
    ├── provision_vm.yml
    └── provision_vm_batch.yml
```

Figure IV.24 – Structure du projet Ansible

L'arborescence de la Figure ?? organise le projet en trois parties : les fichiers de configuration globaux à la racine, le répertoire `inventory/` définissant les hôtes cibles, et le répertoire `playbooks/` contenant les scripts d'automatisation. Le fichier `secrets.yml` est chiffré avec Ansible Vault pour protéger les identifiants sensibles.

```
[defaults]
inventory          = inventory/hosts.yml
remote_user        = ansible
private_key_file    = ~/.ssh/ansible_ed25519
host_key_checking   = False
interpreter_python   = /usr/bin/python3

[privilege_escalation]
become              = True
become_user          = root
```

Figure IV.25 – Fichier `ansible.cfg`

Le fichier de configuration de la Figure ?? définit l'utilisateur distant `ansible`, la clé SSH privée `Ed25519` et l'élévation automatique de privilèges vers `root`. La désactivation de `host_key_checking` simplifie le déploiement en environnement de laboratoire où les hôtes changent fréquemment.

IV.2.6.2 Inventaire

L'inventaire regroupe les nœuds Proxmox, les VMs permanentes administrées manuellement, ainsi qu'un groupe dynamique destiné aux nouvelles VMs provisionnées à chaud par les playbooks.

```
all:
  children:
    proxmox_nodes:
      hosts:
        pve-01: {ansible_host: 192.168.10.100}
        pve-02: {ansible_host: 192.168.10.213}
        pve-03: {ansible_host: 192.168.10.84}
    managed_vms:
      hosts:
        ha-proxy: {ansible_host: 192.168.10.111}
        app-1:    {ansible_host: 192.168.10.112}
        postgres: {ansible_host: 192.168.10.115}
    provisioned_vms:
      hosts: {}
```

Figure IV.26 – Extrait de l'inventaire hosts.yml

L'inventaire de la Figure ?? est structuré en trois groupes : `proxmox_nodes` pour les nœuds physiques, `managed_vms` pour les VMs permanentes, et `provisioned_vms` initialement vide, alimenté dynamiquement via `add_host` au moment de la création de nouvelles machines.

IV.2.6.3 Playbook de provisionnement

Le playbook `provision_vm.yml` automatise la création d'une VM à partir d'un template Debian stocké dans le pool Ceph. Il configure les ressources matérielles, le réseau via `cloud-init`, démarre la VM, puis la valide après boot.

```
ansible-playbook playbooks/provision_vm.yml \
-e "vm_id=110 vm_name=web-01"

ansible-playbook playbooks/provision_vm.yml \
-e "vm_id=115 vm_name=db-01 vm_cores=4 vm_memory=8192"
```

Figure IV.27 – Exemples d'utilisation du playbook `provision_vm.yml`

Les deux exemples de la Figure ?? montrent la flexibilité du playbook : le premier crée une VM web avec les ressources par défaut, le second provisionne une VM base de données avec 4 vCPUs et 8 Go de RAM. L'adresse IP est calculée automatiquement à partir du VMID.

```
vm_ip: "172.16.60.{{ vm_id | int - 90 }}"
```

Figure IV.28 – Formule d'attribution automatique de l'adresse IP

La formule de la Figure ?? génère automatiquement une adresse IP cohérente à partir du VMID, évitant les conflits d'adressage. Par exemple, la VM avec l'identifiant 110 reçoit l'adresse 172.16.60.20.

La configuration cloud-init repose sur trois commandes successives : attachement du disque cloud-init, injection de la configuration réseau, puis régénération de l'ISO cloud-init.

```
qm set {{ vm_id }} --ide2 {{ ceph_pool }}:cloudinit
qm set {{ vm_id }} --ipconfig0 ip={{ vm_cidr }},gw={{ vm_gw }} \
    --nameserver {{ vm_dns }}
qm cloudinit update {{ vm_id }}
```

Figure IV.29 – Configuration cloud-init d'une VM Proxmox

Les trois commandes de la Figure ?? attachent le disque cloud-init, injectent la configuration réseau (adresse IP, passerelle, DNS) et régénèrent l'ISO afin que la VM applique ces paramètres dès son premier démarrage. Un second play se connecte ensuite directement à la VM pour vérifier l'adresse IP configurée et effectuer une mise à jour complète des paquets.

IV.2.6.4 Playbook de bootstrap

Une VM fraîchement créée ne possède pas encore l'utilisateur **ansible** ni sa clé SSH : elle ne peut donc pas être prise en charge par les autres playbooks. Le playbook **bootstrap.yml** résout ce problème en prenant l'adresse IP de la cible en paramètre, sans qu'elle figure préalablement dans l'inventaire.

```
ansible-playbook playbooks/bootstrap.yml \
-e "target_hosts=192.168.10.120" \
-e "bootstrap_password=ROOT_PASS"
```

Figure IV.30 – Exemple d'utilisation du playbook bootstrap.yml

La commande de la Figure ?? montre comment appeler ce playbook. Celui-ci se connecte en **root** avec le mot de passe fourni, installe **python3** et **sudo**, crée l'utilisateur **ansible** avec les droits **sudo** sans mot de passe, puis déploie la clé publique SSH de gestion. À l'issue de ce playbook, la VM est prête à être ajoutée à l'inventaire et prise en charge par les autres playbooks.

IV.2.6.5 Playbook de synchronisation NTP

La cohérence temporelle entre les nœuds du cluster est indispensable pour Ceph et Corosync. Le playbook **ntp_sync.yml** configure **chrony** sur l'ensemble du parc en deux plays distincts.

Le premier play désigne **pve-01** comme maître NTP interne : il synchronise son horloge depuis **pool.ntp.org** et la distribue aux sous-réseaux du cluster (192.168.0.0/16 et 172.16.0.0/12). Le second play configure tous les autres nœuds en clients, avec **pve-01** comme source préférée et **pool.ntp.org** en secours. Chaque play se termine par un appel à **chronyc tracking** pour vérifier l'état de synchronisation.

```
# Configurer tout le cluster
ansible-playbook playbooks/ntp_sync.yml

# Reconfigurer uniquement pve-02
ansible-playbook playbooks/ntp_sync.yml --limit "pve-02"
```

```
# Configurer des n uds sp cifiques uniquement
ansible-playbook playbooks/ntp_sync.yml --limit "app-1,postgres"
```

Figure IV.31 – Exemples d'utilisation du playbook ntp_sync.yml

Les exemples de la Figure ?? illustrent la flexibilité du playbook : la première invocation configure l'ensemble du cluster, la deuxième reconfigure uniquement PVE-02, et la troisième applique la configuration NTP à des nœuds spécifiques de l'inventaire sans impacter le reste du parc.

IV.2.6.6 Provisionnement en lot de VMs

Le playbook `provision_vm_batch.yml` permet le provisionnement en lot de plusieurs VMs à partir d'une liste de définitions YAML. Il itère sur cette liste via `include_playbook` et invoque `provision_vm.yml` pour chaque entrée, en propageant les paramètres propres à chaque VM (identifiant, nom, ressources).

```
vms :
- id: 110
  name: web-01
- id: 111
  name: db-01
  cores: 4
  memory: 8192
```

Figure IV.32 – Exemple de liste de VMs pour `provision_vm_batch.yml`

L'exemple de la Figure ?? illustre le provisionnement en lot de plusieurs machines virtuelles à partir d'une liste YAML. Cette automatisation porte sur le provisionnement des machines virtuelles au-dessus d'un cluster déjà opérationnel. L'extension de cette même logique à l'amorçage des nœuds physiques eux-mêmes, c'est-à-dire l'installation initiale du système d'exploitation via un pipeline PXE/TFTP, a fait l'objet d'une conception détaillée dans le chapitre précédent. Sa mise en œuvre nécessitant toutefois du matériel serveur dédié, indisponible dans le cadre de ce projet, sa validation expérimentale est présentée parmi les perspectives d'évolution de l'infrastructure.

IV.3 Partie II : Couche Stockage

La couche stockage repose entièrement sur Ceph, déployé directement en intégration native avec Proxmox VE. Cette section présente le déploiement du cluster Ceph et la validation de sa tolérance aux pannes.

IV.3.1 Déploiement du cluster Ceph

Le déploiement du cluster Ceph suit une séquence bien définie : initialisation du réseau cluster, création des monitors et managers, ajout des OSDs, puis configuration du pool de stockage utilisé par les VMs.

IV.3.1.1 Initialisation de Ceph

La couche stockage repose sur un cluster Ceph intégré directement à Proxmox. L'initialisation a été effectuée depuis l'interface web ou via la ligne de commande, en définissant un réseau cluster dédié et un réseau public séparé.

```
pveceph init --network 10.10.30.0/24
```

Figure IV.33 – Initialisation du cluster Ceph

La commande de la Figure ?? initialise Ceph en spécifiant le réseau dédié aux échanges internes entre OSDs (10.10.30.0/24), transporté sur le VxLAN 30. Ce réseau est physiquement séparé du réseau public Ceph (10.10.40.0/24) pour isoler le trafic de réplication interne.

Le réseau 10.10.30.0/24 a été réservé aux échanges internes Ceph, tandis que le réseau 10.10.40.0/24 a été utilisé comme réseau public.

IV.3.1.2 Déploiement des MON et MGR

Un moniteur Ceph a été créé sur chaque nœud du cluster afin d'assurer le quorum et la haute disponibilité des métadonnées du cluster.

```
pveceph mon create
```

Figure IV.34 – Création d'un monitor Ceph

La commande de la Figure ?? est exécutée successivement sur chacun des trois nœuds. Avec trois monitors, le quorum Ceph est atteint dès que deux d'entre eux sont opérationnels, garantissant la disponibilité même en cas de panne d'un nœud.

Des managers Ceph ont aussi été déployés pour fournir les fonctions d'administration avancée et l'export des métriques vers Prometheus. Comme le montre la Figure ??, l'interface Proxmox permet de vérifier l'état de l'ensemble des monitors et managers déployés.




FIGURE IV.35 – Interface Proxmox affichant les monitors et managers Ceph actifs sur les trois nœuds.

La Figure ?? présente la vue Ceph de l'interface Proxmox après le déploiement des monitors et managers. Les trois MON apparaissent avec l'état **online** et le quorum est atteint, tandis que les MGR affichent leur rôle actif ou en veille selon le nœud, confirmant la redondance complète de la couche de contrôle Ceph.

```
ceph mgr module enable prometheus
```

Figure IV.36 – Activation du module Prometheus pour Ceph

L'activation du module via la Figure ?? expose les métriques du cluster (état des OSDs, pools, latence, I/O) sur le port 9283 de chaque nœud, permettant à Prometheus de les collecter sans configuration supplémentaire côté Ceph.

IV.3.1.3 Déploiement des OSDs

Sur chaque nœud, les quatre disques restants ont été intégrés comme OSDs Ceph. Le disque /dev/sdb (300 Go SAS) et les trois disques /dev/sdc, /dev/sdd et /dev/sde (600 Go SAS chacun) ont été provisionnés successivement via la commande suivante, exécutée pour chacun d'eux.

```
pveceph osd create /dev/sdb
pveceph osd create /dev/sdc
pveceph osd create /dev/sdd
pveceph osd create /dev/sde
```

Figure IV.37 – Création des OSDs Ceph sur chaque nœud

Chaque appel à la Figure ?? formate le disque avec le système BlueStore et l'intègre comme OSD dans le cluster. La même séquence a été exécutée sur PVE-01, PVE-02 et PVE-03, portant le total à **douze OSDs** répartis équitablement sur les trois nœuds physiques.




FIGURE IV.38 – État du cluster Ceph montrant les douze OSDs actifs sur les trois nœuds.

La Figure ?? affiche la vue OSD de l'interface Proxmox. Les douze OSDs apparaissent avec le statut `up/in`, leur type de stockage BlueStore et leur poids dans la hiérarchie CRUSH, confirmant que l'ensemble des disques est actif et correctement intégré au cluster.

```
ceph osd tree
```

Figure IV.39 – Affichage de l'arbre CRUSH

La commande de la Figure ?? affiche la hiérarchie CRUSH avec les trois nœuds physiques et leurs quatre OSDs respectifs. Cette structure garantit que les trois répliques d'un même bloc seront toujours placées sur des serveurs physiques distincts, conformément à la politique de domaines de défaillance.

IV.3.1.4 Création du pool de stockage

Un pool RBD a été créé avec une réplication de taille 3 et une taille minimale de 2, ce qui garantit la disponibilité des données même en cas de perte d'un nœud.

```
pveceph pool create ceph-pool --size 3 --min-size 2
```

Figure IV.40 – Création du pool Ceph

Dans la Figure ??, le paramètre `-size 3` impose trois répliques par objet, une par nœud physique. Le paramètre `-min-size 2` maintient le pool accessible tant qu'au moins deux répliques sont disponibles, offrant une tolérance à la panne d'un nœud sans coupure de service.

Ce pool a ensuite été intégré comme stockage partagé dans Proxmox pour héberger les disques des VMs et des conteneurs.

```
ceph -s
ceph df
```

Figure IV.41 – État global du cluster Ceph

Les commandes de la Figure ?? permettent de vérifier l'état du cluster : `ceph -s` affiche un résumé de l'état de santé, tandis que `ceph df` donne la capacité totale, utilisée et disponible par pool. Ces deux commandes constituent la vérification de base après chaque modification de la configuration Ceph. La Figure ?? illustre l'état du pool obtenu après ce déploiement.




FIGURE IV.42 – État du cluster Ceph montrant le pool RBD.

La Figure ?? montre la vue des pools Ceph dans l'interface Proxmox. Le pool `ceph-pool` apparaît avec l'état `HEALTH_OK`, le facteur de réplication à 3 et les métriques d'I/O en temps réel, confirmant le bon fonctionnement de la couche stockage.

IV.3.2 Validation de la tolérance aux pannes

La tolérance aux pannes de la couche stockage a été vérifiée par un scénario de panne simulée. Lors de l'extinction d'un nœud, le cluster Ceph est passé temporairement à l'état `HEALTH_WARN`, mais les données sont restées accessibles grâce au facteur de réplication.

Après le retour du nœud défaillant, Ceph a automatiquement lancé la resynchronisation des données et l'état du cluster est revenu à `HEALTH_OK`. Ce test valide le bon comportement de la couche stockage distribuée.

IV.4 Partie III : Couche Réseau

La couche réseau est construite autour d'Open vSwitch et des tunnels VxLAN, permettant de créer plusieurs réseaux logiques isolés sur le même réseau physique Sonatrach. OPNsense assure le routage centralisé et le filtrage entre les différents segments.

IV.4.1 Configuration Open vSwitch et tunnels VxLAN

La configuration réseau s'appuie sur Open vSwitch pour la création des bridges et des tunnels VxLAN, et sur les fichiers d'interfaces Linux pour la persistance de la configuration.

IV.4.1.1 Installation d'Open vSwitch

Open vSwitch a été installé sur chaque nœud Proxmox afin de construire une couche réseau virtuelle flexible, adaptée au transport de plusieurs flux logiques sur le même réseau physique.

```
apt install openvswitch-switch
```

Figure IV.43 – Installation d'Open vSwitch

La commande de la Figure ?? installe le daemon OVS et les outils de gestion en ligne de commande (`ovs-vsctl`, `ovs-ofctl`). Elle doit être exécutée sur chacun des trois nœuds Proxmox avant toute configuration des bridges et des tunnels.

Un bridge principal a été créé sur chaque nœud, puis l'interface physique principale y a été attachée pour servir de point de transit à tous les tunnels VxLAN.

```
ovs-vsctl add-br vbr0  
ovs-vsctl add-port vbr0 nic0
```

Figure IV.44 – Création du bridge OVS principal

Les commandes de la Figure ?? configurent le bridge principal : la première crée le bridge OVS `vbr0`, la seconde y attache l'interface physique `nic0` comme port de transit. Tous les tunnels VxLAN créés ultérieurement utilisent ce bridge, permettant de transporter plusieurs réseaux logiques sur une seule interface physique.

IV.4.1.2 Configuration complète des interfaces (exemple sur PVE-01)

Le fichier `/etc/network/interfaces` est presque le même sur les trois nœuds. La seule différence est l'adresse IP du bridge de management. La configuration présentée ici correspond à PVE-01 et sert d'exemple pour tout le cluster.

Chaque nœud doit connaître les adresses IP des autres car les tunnels VxLAN fonctionnent en mode point-à-point et ne disposent pas de découverte automatique. Avec une architecture VLAN, cette contrainte n'existerait pas, car Proxmox SDN permet de gérer et de distribuer automatiquement la configuration réseau depuis l'interface web.

Pour rendre la configuration plus facile à comprendre, elle est organisée en plusieurs parties selon le rôle des interfaces : réseau physique, réseaux Ceph et Corosync, migration et sauvegarde, puis réseaux applicatifs. La Figure ?? présente une vue d'ensemble avant le détail de chaque partie.




FIGURE IV.45 – Vue d’ensemble de la configuration réseau de PVE-01 : quatre parties logiques

La Figure ?? illustre l’organisation en quatre couches de la configuration réseau de PVE-01 : le bridge de management (Partie 1), les VxLAN d’infrastructure Corosync et Ceph interne (Partie 2), les VxLAN de migration, Ceph public et sauvegarde (Partie 3), et enfin les VxLAN applicatifs avec leurs bridges Linux (Partie 4).

Partie 1 : Interface physique et bridge de management Cette première partie définit l’interface physique **nic0** ainsi que le bridge OVS principal **vmbr0**, qui sert de point d’ancrage à l’ensemble des tunnels VxLAN. L’adresse de management **192.168.10.100/24** est attribuée directement sur ce bridge.

```
auto lo
iface lo inet loopback

iface nic0 inet manual

auto vmbr0
iface vmbr0 inet static
    address 192.168.10.100/24
    gateway 192.168.10.36
    ovs_type OVSBridge
```

```
    ovs_ports nic0

auto nic0
iface nic0 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0

iface nic1 inet manual
iface nic2 inet manual
iface nic3 inet manual
```

Figure IV.46 – Interfaces de base et bridge OVS de management

Dans la Figure ??, le bridge `vmbr0` est de type `OVSBridge` et encapsule `nic0` comme port physique de sortie. C'est sur ce même bridge que tous les tunnels VxLAN seront connectés, ce qui permet de les transporter sur l'unique interface physique disponible.

Partie 2 : VxLAN Corosync (clé 20) et stockage Ceph interne (clé 30) Ces deux VxLAN transportent respectivement le trafic de heartbeat Corosync entre les nœuds du cluster, et le trafic de réplication interne Ceph entre les OSDs. Chaque tunnel est créé en mode point-à-point, avec une interface interne OVS associée pour l'adressage IP local.

```
# ===== COROSYNC VXLAN (key=20) =====
auto vxlan20-int
iface vxlan20-int inet static
    address 10.10.20.1/24
    ovs_type OVSIIntPort
    ovs_bridge vmbr0

# ===== CEPH INTERNE VXLAN (key=30) =====
auto vxlan30-int
iface vxlan30-int inet static
    address 10.10.30.1/24
    ovs_type OVSIIntPort
    ovs_bridge vmbr0
```

Figure IV.47 – VxLAN Corosync (clé 20) et Ceph interne (clé 30) - interfaces internes PVE-01

Dans la Figure ??, seules les interfaces internes (`OVSIIntPort`) des VxLAN 20 et 30 sont représentées. Chaque interface interne porte l'adresse IP locale du nœud sur le réseau logique correspondant. Le VxLAN 20 isole le trafic Corosync du reste du réseau, garantissant que les heartbeats entre nœuds ne soient jamais perturbés par le trafic applicatif. Le VxLAN 30 isole quant à lui le trafic de réplication Ceph, dont la bande passante peut être importante lors de la resynchronisation d'un OSD. La configuration complète incluant les ports tunnels VxLAN vers PVE-02 et PVE-03, ainsi que les fichiers des deux autres nœuds, est disponible en Annexe ??.

Partie 3 : Ceph public (clé 40), migration live (clé 50) et sauvegarde (clé 90) Ces trois VxLAN couvrent respectivement le réseau public Ceph utilisé pour les accès RBD des VMs, le réseau dédié aux migrations live de VMs entre nœuds, et le réseau de sauvegarde. Leur séparation évite toute interférence entre ces flux lors des opérations intensives.

```
# ===== CEPH PUBLIC VXLAN (key=40) =====
auto vxlan40-int
iface vxlan40-int inet static
    address 10.10.40.1/24
    ovs_type OVSIntPort
    ovs_bridge vmbr0

# ===== MIGRATION LIVE VXLAN (key=50) =====
auto vxlan50-int
iface vxlan50-int inet static
    address 10.10.50.1/24
    ovs_type OVSIntPort
    ovs_bridge vmbr0

# ===== SAUVEGARDE VXLAN (key=90) =====
auto vxlan90-int
iface vxlan90-int inet static
    address 10.10.90.1/24
    ovs_type OVSIntPort
    ovs_bridge vmbr0
```

Figure IV.48 – Ceph public (clé 40), migration (clé 50) et sauvegarde (clé 90) - interfaces internes PVE-01

La Figure ?? présente les interfaces internes des VxLAN 40, 50 et 90 sur PVE-01. La séparation du réseau public Ceph (VxLAN 40) du réseau de réplication interne (VxLAN 30) suit les recommandations de Ceph : le trafic client et le trafic OSD-OSD n'entrent pas en contention. Le VxLAN 50, dédié aux migrations live, préserve la qualité de service lors des déplacements de VMs par le mécanisme CSLB. La configuration complète des trois nœuds est disponible en Annexe ??.

Partie 4 : Réseaux applicatifs (clés 60, 70, 80) et bridges Linux Les trois derniers VxLAN portent le trafic des zones applicatives Dev (clé 60), Prod (clé 70) et DMZ (clé 80). Chacun dispose d'une interface interne OVS et d'un bridge Linux associé (*vmbr60*, *vmbr70*, *vmbr80*), qui constitue le point de connexion effectif pour les interfaces réseau des VMs applicatives.

```
# ===== VXLAN 60 (Dev) =====
auto vxlan60-int
iface vxlan60-int inet static
    ovs_type OVSIntPort
    ovs_bridge vmbr0

# ===== VXLAN 70 (Prod) =====
auto vxlan70-int
iface vxlan70-int inet static
    ovs_type OVSIntPort
    ovs_bridge vmbr0

# ===== VXLAN 80 (DMZ) =====
auto vxlan80-int
```

```
iface vxlan80-int inet static
    ovs_type OVSIntPort
    ovs_bridge vmbr0

# ===== VM Bridges =====
auto vmbr60
iface vmbr60 inet manual
    bridge_ports vxlan60-int
    bridge_stp off
    bridge_fd 0

auto vmbr70
iface vmbr70 inet manual
    bridge_ports vxlan70-int
    bridge_stp off
    bridge_fd 0

auto vmbr80
iface vmbr80 inet manual
    bridge_ports vxlan80-int
    bridge_stp off
    bridge_fd 0

source /etc/network/interfaces.d/*
```

Figure IV.49 – VxLAN applicatifs (clés 60, 70, 80) et bridges Linux - PVE-01

La Figure ?? présente les interfaces internes et les bridges Linux des réseaux applicatifs sur PVE-01. Les bridges `vmbr60`, `vmbr70` et `vmbr80` constituent la jonction entre le plan de données OVS et les interfaces réseau des VMs Proxmox. Chaque bridge est relié à l'interface interne OVS du VxLAN correspondant, formant un chemin de commutation continu depuis la VM applicative jusqu'à l'interface physique du nœud, à travers le tunnel VxLAN vers les autres nœuds du cluster. Cette architecture permet de transporter plusieurs réseaux logiques isolés sur le même réseau physique, sans dépendre d'un switch physique configuré en VLAN. La configuration complète des trois nœuds (avec les ports tunnels vers PVE-02 et PVE-03) est disponible en Annexe ??.

IV.4.2 Déploiement de la VM OPNsense

OPNsense est au cœur du réseau : c'est lui qui s'occupe du routage entre les zones, du NAT sortant et du DHCP pour les trois réseaux applicatifs.

IV.4.2.1 Création et interfaces réseau

Comme les autres VMs, OPNsense a été créée sur le cluster Proxmox avec son disque stocké sur le pool Ceph, pour profiter du stockage distribué.

Elle est configurée avec 4 Go de RAM, 2 vCPUs et 20 Go de disque, et possède quatre interfaces réseau pour faire office de routeur et de pare-feu entre les différents segments. Le tableau ?? liste ces interfaces avec leur bridge Proxmox, leur rôle et leur adresse IP.

TABLEAU IV.2 – Interfaces de la VM OPNsense.

Interface VM	Bridge Proxmox	Rôle	Adresse IP
net0 (em0)	vmbr0	WAN	192.168.10.65/24
net1 (em1)	vmbr60	LAN Dev	172.16.60.1/24
net2 (em2)	vmbr70	LAN Prod	172.16.70.1/24
net3 (em3)	vmbr80	LAN DMZ	172.16.80.1/24

Comme le montre la Figure ??, la console de gestion OPNsense permet de vérifier l'assignation correcte de ces quatre interfaces.

```

Enter a host name or IP address: 8.8.8.8

PING 8.8.8.8 (8.8.8.8): 56 data bytes
64 bytes from 8.8.8.8: icmp_seq=0 ttl=111 time=79.301 ms
^C
*** OPNsense.internal: OPNsense 26.1.2_5 (amd64) ***

LAN (em1)      -> v4: 172.16.60.1/24
OPT1 (em2)     -> v4: 172.16.70.1/24
OPT2 (em3)     -> v4: 172.16.80.1/24
WAN (em0)      -> v4: 192.168.10.65/24

HTTPS: SHA256 DD D5 15 E5 28 38 7B A1 9B E2 1D 5B D4 9C 5D F5
          08 23 37 EC F7 A8 97 9D F6 CA CE 29 E9 BF 31 D5

0) Logout                7) Ping host
1) Assign interfaces      8) Shell
2) Set interface IP address 9) pfTop
3) Reset the root password 10) Firewall log
4) Reset to factory defaults 11) Reload all services
5) Power off system        12) Update from console
6) Reboot system           13) Restore a backup

Enter an option:

```

FIGURE IV.50 – Configuration des interfaces de la VM OPNsense.

La Figure ?? montre la console de gestion OPNsense affichant les quatre interfaces réseau avec leurs adresses IP respectives, confirmant que le routeur virtuel est opérationnel avec ses interfaces WAN et LAN correctement assignées.

IV.4.2.2 NAT sortant

Le NAT sortant automatique a été activé dans OPNsense afin de permettre aux réseaux internes de sortir vers Internet via l'interface WAN. Cette configuration a simplifié le routage pour les VMs hébergées sur les réseaux Dev, Prod et DMZ.

IV.4.3 Configuration du service DHCP

Le service DHCP a été activé via `dnsmasq` sur les interfaces LAN internes. Ce choix a été retenu car il est simple à configurer et convient bien à un environnement de laboratoire. Le tableau ?? présente les plages d'adresses DHCP configurées pour chacun des réseaux internes.

TABLEAU IV.3 – Plages DHCP configurées sur OPNsense.

Interface	Plage début	Plage fin	Gateway
LAN (Dev)	172.16.60.10	172.16.60.250	172.16.60.1
OPT1 (Prod)	172.16.70.10	172.16.70.250	172.16.70.1
OPT2 (DMZ)	172.16.80.10	172.16.80.250	172.16.80.1

Le bon fonctionnement de DHCP a été vérifié par une capture réseau sur l'interface LAN d'OPNsense pendant le démarrage d'une VM de test.

```
tcpdump -i em1 port 67 or port 68
```

Figure IV.51 – Capture du trafic DHCP avec tcpdump

La commande de la Figure ?? capture les échanges DHCP sur l'interface **em1** d'OPNsense. La sortie affiche successivement les messages Discover, Offer, Request et Acknowledge, validant le cycle complet d'attribution d'adresse IP à la machine virtuelle de test.

Cette vérification a montré le cycle normal des échanges DHCP, depuis le “Discover” jusqu'au “Offer”, puis l'attribution effective de l'adresse IP à la machine virtuelle.

IV.4.4 Configuration du Pare-feu

La sécurité réseau de l'infrastructure repose sur deux niveaux de filtrage complémentaires et indépendants. Le premier est le pare-feu OPNsense, qui assure le contrôle des flux entre les zones applicatives et constitue la passerelle par défaut de toutes les machines virtuelles. Le second est le pare-feu natif Proxmox, configuré au niveau de l'hyperviseur pour protéger exclusivement les réseaux d'infrastructure internes (gestion, cluster, stockage, migration). Cette séparation de responsabilités garantit qu'un attaquant ayant compromis une VM applicative ne peut pas atteindre directement les nœuds physiques du cluster.

IV.4.4.1 Pare-feu OPNsense : Filtrage Inter-réseaux

OPNsense centralise le routage et applique les politiques de filtrage entre les réseaux applicatifs Dev (172.16.60.0/24), Prod (172.16.70.0/24) et DMZ (172.16.80.0/24). Toutes les machines virtuelles utilisent OPNsense comme passerelle par défaut : tout flux entre zones ou vers Internet transite donc obligatoirement par ce pare-feu. Les règles ont été configurées sous **Firewall > Rules** selon le principe du moindre privilège : tout flux non explicitement autorisé est bloqué par la règle implicite **DENY ALL** placée en dernière position.

Le tableau ?? récapitule les règles de filtrage inter-zones et vers l'interface WAN. Les captures d'écran de l'interface OPNsense correspondantes sont disponibles en **Annexe D**.

TABLEAU IV.4 – Règles de filtrage inter-réseaux configurées sur OPNsense.

Source	Destination	Port / Proto	Action	Justification
172.16.60.0/24	WAN	any	ALLOW	Mises à jour et dépôts
172.16.80.0/24	WAN	any	ALLOW	Sortie des services exposés
172.16.80.0/24	Prod	TCP 8000	ALLOW	HAProxy → Flask app-1/2
172.16.70.0/24	Prod	TCP 5432	ALLOW	Flask app-1/2 → PostgreSQL
any	DMZ	TCP 8080	ALLOW	Accès public vers HAProxy
any	192.168.10.100	UDP 123	ALLOW	Synchro NTP vers PVE-01
172.16.60.0/24	Prod	any	BLOCK	Isolation Dev / Prod
172.16.60.0/24	DMZ	any	BLOCK	Isolation Dev / DMZ
172.16.70.0/24	WAN	any	BLOCK	Trafic Prod via DMZ obligatoire

Ces règles assurent une isolation stricte entre les trois zones tout en autorisant les flux légitimes. La politique de sortie directe de Prod vers WAN est bloquée afin de forcer le passage par la DMZ, seule zone autorisée à exposer des services. Le flux DMZ → Prod sur le port 8000 permet à HAProxy de distribuer les requêtes vers les backends Flask. La règle NTP (UDP 123) autorise les VMs de toutes les zones à synchroniser leur horloge avec PVE-01, qui héberge le serveur Chrony interne.

IV.4.4.2 Pare-feu Proxmox : Filtrage au Niveau Hyperviseur

En complément du filtrage OPNsense, le pare-feu natif Proxmox a été configuré au niveau de l'hyperviseur pour protéger les réseaux d'infrastructure. Ce pare-feu s'organise en trois niveaux hiérarchiques : le niveau *datacenter* définit des objets réutilisables (alias, IPSets, groupes de sécurité) sans appliquer de règles directement ; le niveau *nœud* référence ces groupes et fixe la politique par défaut ; le niveau *VM* ajoute uniquement les règles propres au rôle de chaque machine. Chaque niveau hérite des objets définis au-dessus de lui, ce qui évite toute redondance.

Configuration au niveau datacenter

Trois types d'objets ont été définis au niveau datacenter : des **alias** pour nommer individuellement les VMs applicatives et les nœuds physiques, des **IPSets** pour regrouper les plages réseaux par domaine de sécurité, et des **groupes de sécurité** pour encapsuler les règles de ports par service d'infrastructure.

Alias Des alias symboliques ont été définis pour simplifier l'écriture des règles aux niveaux inférieurs. Le tableau ?? liste l'ensemble des alias créés. Les captures correspondantes dans l'interface Proxmox sont disponibles en **Annexe D**.

TABLEAU IV.5 – Alias définis au niveau datacenter dans le pare-feu Proxmox.

Alias	Adresse IP	Instance
pve-01	192.168.10.100	Nœud physique PVE-01
pve-02	192.168.10.213	Nœud physique PVE-02
pve-03	192.168.10.84	Nœud physique PVE-03
monitoring	192.168.10.99	LXC Monitoring (Grafana, Prometheus, InfluxDB, Loki)
haproxy	172.16.80.10	VM HAProxy (frontal DMZ)
App-1	172.16.70.10	VM Flask app-1 (Prod)
App-2	172.16.70.11	VM Flask app-2 (Prod)
postgres	172.16.70.20	VM PostgreSQL (Prod)

IPSets Des IPSets ont été créés pour regrouper les adresses appartenant à un même domaine de sécurité, permettant d'appliquer une règle à un ensemble de machines sans dupliquer les adresses dans chaque règle individuelle. Le tableau ?? récapitule les IPSets configurés. Pour voir l'ensemble des membres de chaque IPSet dans l'interface Proxmox, consulter l'**Annexe D**.

TABLEAU IV.6 – IPSets configurés au niveau datacenter (pare-feu Proxmox).

Nom de l'IPSet	Plage réseau	Rôle
management-net	192.168.10.0/24	Réseau d'administration
corosync-net	10.10.20.0/24	Heartbeat Corosync
ceph-cluster-net	10.10.30.0/24	Réplication Ceph interne OSD–OSD
ceph-public-net	10.10.40.0/24	Accès RBD public des hyperviseurs
migration-net	10.10.50.0/24	Migration live de VMs entre nœuds
backup-net	10.10.90.0/24	Trafic de sauvegarde

Groupes de sécurité Cinq groupes de sécurité encapsulent les règles de ports associées à chaque service d'infrastructure. Le tableau ?? liste ces groupes de façon synthétique ; les captures d'écran détaillées de chaque groupe dans l'interface Proxmox sont disponibles en **Annexe D**.

TABLEAU IV.7 – Groupes de sécurité Proxmox — synthèse par service.

Groupe	Source (IPSet)	Ports autorisés (IN)
proxmox-management	management-net	TCP 22, 8006, 9283 ; UDP 123 ; ICMP
corosync-cluster	corosync-net	UDP 5404–5405
ceph-storage	ceph-cluster-net	TCP 3300, 6789, 6800–7300
ceph-storage	ceph-public-net	TCP 3300, 6789, 6800–7300
migration-live	migration-net	TCP any (ports dynamiques QEMU)
backup-traffic	backup-net	TCP any (ports dynamiques PBS)

Le groupe **proxmox-management** regroupe tous les accès d'administration : SSH (port 22), interface web Proxmox (port 8006), métriques Ceph MGR pour Prometheus (port 9283), synchronisation NTP de PVE-01 (UDP 123) et diagnostics ICMP. Les groupes **ceph-storage** ouvrent les ports monitors Ceph (3300 en msgr2 et 6789 en legacy) ainsi que les communications OSD (6800–7300) sur les deux réseaux Ceph distincts. Le groupe **migration-live** et le groupe **backup-traffic** autorisent tous les ports TCP dynamiques utilisés respectivement par QEMU lors des migrations et par Proxmox Backup Server lors des sauvegardes.

Configuration au niveau nœud

Sur chacun des trois nœuds PVE-01, PVE-02 et PVE-03, le pare-feu est activé avec la politique par défaut **DROP** en entrée et **ACCEPT** en sortie. Les cinq groupes de sécurité définis au niveau datacenter sont simplement **référencés** : leurs règles s'appliquent automatiquement sans être redéfinies. Le trafic de retour des connexions établies est géré par le suivi d'état (*stateful firewall*) de Proxmox sans règle explicite. Les captures d'écran de la configuration par nœud sont disponibles en **Annexe D**.

Le tableau ?? liste uniquement les groupes référencés et la politique par défaut résultante. Il ne répète pas le détail des ports, déjà documenté dans le tableau ??.

TABLEAU IV.8 – Configuration du pare-feu au niveau nœud (PVE-01, PVE-02, PVE-03).

Élément	Valeur	Remarque
Politique entrée (INPUT)	DROP	Tout trafic non explicitement autorisé est rejeté
Politique sortie (OUTPUT)	ACCEPT	Les nœuds peuvent initier des connexions sortantes
<code>proxmox-management</code>	référéncé	Accès admin, NTP, métriques Ceph
<code>corosync-cluster</code>	référéncé	Heartbeat cluster (VxLAN 20)
<code>ceph-storage</code>	référéncé	Stockage distribué (VxLAN 30 et 40)
<code>migration-live</code>	référéncé	Migrations live (VxLAN 50)
<code>backup-traffic</code>	référéncé	Sauvegardes (VxLAN 90)

L'intérêt de cette approche est double : toute modification d'un groupe de sécurité au niveau datacenter se propage instantanément sur les trois nœuds, et la configuration de chaque nœud reste minimale. Les réseaux applicatifs (`172.16.x.x`) ne figurant dans aucun IPSet autorisé, les VMs ne peuvent initier aucune connexion directe vers les nœuds physiques, même en cas de compromission.

Règles au niveau des VMs

Les règles de pare-feu au niveau VM s'appliquent en complément des groupes de sécurité hérités du datacenter. À ce niveau, seules les règles **propres au rôle applicatif** de chaque VM sont définies : flux entrants sur les ports métier et flux sortants vers les dépendances directes. Les règles d'administration (SSH depuis `management-net`) étant déjà couvertes par le groupe `proxmox-management` hérité, elles ne sont pas redéfinies ici. Le tableau ?? détaille ces règles pour chaque VM applicative ; les captures d'écran correspondantes dans l'interface Proxmox sont disponibles en **Annexe D**.

TABLEAU IV.9 – Règles de pare-feu spécifiques par VM applicative (hors règles héritées).

VM	Dir.	Action	Source / Dest.	Port / Justification
HAProxy (VM 201)	IN	ACCEPT	0.0.0.0/0	TCP 8080 — accès public
HAProxy (VM 201)	IN	ACCEPT	<code>management-net</code>	TCP 8404 — stats HAProxy
HAProxy (VM 201)	OUT	ACCEPT	<code>App-1</code> , <code>App-2</code>	TCP 8000 — backends Flask
Flask app-1/2	IN	ACCEPT	<code>haproxy</code>	TCP 8000 — trafic applicatif
Flask app-1/2	OUT	ACCEPT	<code>postgres</code>	TCP 5432 — base de données
PostgreSQL (VM 205)	IN	ACCEPT	<code>App-1</code> , <code>App-2</code>	TCP 5432 — connexions SQL

HAProxy est la seule VM exposée vers l'extérieur sur le port 8080 ; ses flux sortants sont restreints aux seuls backends Flask identifiés par leurs alias. Le port 8404, limité au réseau de

management, expose l'interface native de statistiques d'HAProxy. Les VMs Flask n'acceptent le trafic applicatif que depuis l'alias **haproxy** et n'émettent en sortie que vers PostgreSQL. La VM PostgreSQL n'accepte les connexions SQL que depuis les deux backends Flask. La politique par défaut **DROP** implicite bloque tout autre flux, assurant une isolation stricte entre les composants de l'application.

IV.5 Partie IV : Services Complémentaires d'Infrastructure

Cette partie présente le déploiement des services complémentaires qui complètent l'infrastructure hyperconvergée : le système de notification, la centralisation des journaux, la synchronisation temporelle, la gestion du code source et la plateforme d'automatisation opérationnelle.

IV.5.1 Système de Notification : Alertmanager

La supervision active de l'infrastructure ne se limite pas à la visualisation des métriques : elle inclut la notification automatique des équipes en cas d'anomalie détectée. Le module Grafana Alerting a été configuré pour évaluer des règles d'alerte sur les métriques collectées et transmettre les notifications via un contact point Gmail utilisant le protocole SMTP.

IV.5.1.1 Configuration des règles d'alerte

Les règles d'alerte sont définies directement dans Grafana sous "Alerting -> Alert Rules". Chaque règle spécifie une expression PromQL ou une requête InfluxDB, un seuil de déclenchement, une durée de maintien avant passage en état "Firing", et le groupe de contact destinataire.

Parmi les règles configurées figurent notamment celles décrites ci-dessous, chacune accompagnée de sa requête et de sa condition de déclenchement.

Charge CPU élevée sur les nœuds Proxmox, requête Flux sur le bucket InfluxDB "proxmox", déclenchée lorsque l'utilisation moyenne dépasse 85 % pendant 5 minutes (Figure ??).

```
Requete (Flux) :
  from(bucket: "proxmox")
    |> range(start: -5m)
    |> filter(fn: (r) => r._measurement == "cpustat" and r._field == "
      cpu")
    |> last()
```

Figure IV.52 – Règle d'alerte, Charge CPU élevée sur les nœuds Proxmox

RAM disponible faible sur les nœuds Proxmox, ratio mémoire utilisée / mémoire totale calculé via Flux, déclenché au-delà de 90 % d'utilisation, soit moins de 10 % de RAM disponible (Figure ??).

```
Requete (Flux) :
  from(bucket: "proxmox")
    |> range(start: -5m)
```

```
|> filter(fn: (r) => r._measurement == "memory"
              and (r._field == "memused" or r._field == "
                  memtotal"))
|> pivot(rowKey: ["_time"], columnKey: ["_field"], valueColumn: "
    _value")
|> map(fn: (r) => ({ r with _value: float(v: r.memused) / float(v:
    r.memtotal) * 100.0 })))
|> last()
```

Figure IV.53 – Règle d’alerte, RAM disponible faible sur les nœuds Proxmox

OSD Ceph hors ligne : requête PromQL instantanée sur la métrique `ceph_osd_up`, déclenchée dès qu’un OSD passe à l’état arrêté (Figure ??).

```
Requete (PromQL, instantanee) : ceph_osd_up
```

Figure IV.54 – Règle d’alerte - OSD Ceph hors ligne

Latence OSD anormale : requête PromQL instantanée sur `ceph_osd_apply_latency_ms`, déclenchée au-delà de 100 ms (Figure ??).

```
Requete (PromQL, instantanee) : ceph_osd_apply_latency_ms
```

Figure IV.55 – Règle d’alerte - Latence OSD Ceph élevée

Migrations excessives / circuit breaker CSLB : comptage des migrations sur 5 minutes via `increase(CSLB_migrations_total[5m])`, déclenché au-delà de 5 migrations (Figure ??).

```
Requete (PromQL, instantanee) : increase(CSLB_migrations_total[5m])
```

Figure IV.56 – Règle d’alerte - Migrations excessives / circuit breaker CSLB

Erreurs API Proxmox / InfluxDB côté CSLB : comptage des erreurs de cycle sur 5 minutes via `increase(CSLB_cycle_errors_total[5m])`, déclenché dès qu’une erreur est détectée (Figure ??).

```
Requete (PromQL, instantanee) : increase(CSLB_cycle_errors_total[5m])
```

Figure IV.57 – Règle d’alerte - Erreurs API Proxmox / InfluxDB côté CSLB

Service CSLB indisponible : requête PromQL instantanée sur `up{job="CSLB"}`, déclenchée lorsque la cible n’est plus joignable (Figure ??).

```
Requete (PromQL, instantanee) : up{job="CSLB"}
```

Figure IV.58 – Règle d’alerte - Service CSLB indisponible

Ces règles couvrent les scénarios de défaillance les plus critiques de l’infrastructure : surcharge des nœuds Proxmox, dégradation du cluster de stockage Ceph et indisponibilité du service d’équilibrage de charge CSLB.

IV.5.1.2 Configuration du contact point Gmail

Le contact point Gmail a été créé dans Grafana sous “Alerting -> Contact Points”. La configuration utilise le serveur SMTP de Google avec authentification par mot de passe d’application, garantissant la compatibilité avec les comptes protégés par la double authentification.

```
# Dans grafana.ini ou via l'interface web :  
[smtp]  
host      = smtp.gmail.com:587  
user      = adresse@gmail.com  
password  = mot_de_passe_application  
from_address = adresse@gmail.com  
starttls_policy = MandatoryStartTLS
```

Figure IV.59 – Paramètres SMTP du contact point Gmail

Dans la Figure ??, l’activation de `MandatoryStartTLS` garantit que les identifiants SMTP ne transitent jamais en clair, conformément aux exigences de sécurité de l’infrastructure.

IV.5.1.3 Validation

La validation du système de notification s’appuie sur deux vérifications. La capture d’écran de la page “Alerting -> Alert Rules” présentant l’ensemble des règles configurées dans Grafana Alerting ainsi que leur état est disponible en Annexe ?? (Figure ??). Le contact point associé pour l’acheminement des notifications est configuré via Gmail, en utilisant l’adresse email de destination directement dans l’interface Grafana Alerting.

IV.5.2 Centralisation des Journaux : Loki et Alloy

La collecte et la centralisation des journaux système constituent un élément essentiel pour le diagnostic des incidents et l’audit de l’infrastructure. Loki, déployé dans le conteneur LXC `monitoring` existant, joue le rôle d’agrégateur de journaux. L’agent Grafana Alloy, installé sur chaque nœud Proxmox, collecte les fichiers de log locaux et les transmet à Loki pour indexation.

IV.5.2.1 Déploiement de Loki

Loki a été installé dans le conteneur LXC `monitoring` (192.168.10.99), aux côtés de Prometheus et Grafana déjà en place. Cette co-localisation simplifie la configuration de Grafana, qui dispose ainsi de Loki comme source de données supplémentaire sans configuration réseau additionnelle.

```
apt install loki  
systemctl enable loki  
systemctl start loki
```

Figure IV.60 – Installation de Loki

Les commandes de la Figure ?? installent et activent Loki, qui écoute par défaut sur le port 3100. La source de données Loki a ensuite été ajoutée dans Grafana en pointant vers `http://localhost:3100`.

IV.5.2.2 Déploiement de l'agent Grafana Alloy

L'agent Grafana Alloy a été installé sur chacun des trois nœuds Proxmox. Sa configuration définit les chemins de fichiers de journaux à surveiller et l'adresse du serveur Loki cible.

```
local.file_match "varlogs" {
  path_targets = [{"__path__" = "/var/log/**/*.log"}]
}

loki.source.file "varlogs" {
  targets      = local.file_match.varlogs.targets
  forward_to   = [loki.write.default.receiver]
}

loki.write "default" {
  endpoint {
    url = "http://192.168.10.99:3100/loki/api/v1/push"
  }
}
```

Figure IV.61 – Configuration de l'agent Alloy pour la collecte des journaux

La configuration de la Figure ?? collecte tous les fichiers *.log sous /var/log/ de chaque nœud et les transmet en flux continu vers Loki. Les labels `host` et `filename` sont automatiquement ajoutés à chaque entrée, permettant de filtrer les journaux par nœud dans Grafana.



FIGURE IV.62 – Journaux de l'infrastructure visualisés dans Grafana via Loki.

La Figure ?? présente la vue “Explore” de Grafana avec Loki comme source de données. Les journaux sont filtrables par hôte et par fichier source via LogQL. La vue complète du dashboard de centralisation des journaux est disponible en Annexe ??.

IV.5.3 Synchronisation Temporelle : NTP/Chrony

La cohérence temporelle est une exigence fondamentale dans un cluster distribué. Une dérive de quelques secondes entre les nœuds peut perturber le quorum Corosync, fausser les journaux

de corrélation et provoquer des incohérences dans les métriques Prometheus. Le serveur Chrony est hébergé directement sur **PVE-01** (192.168.10.100), qui fait référence pour l'ensemble des nœuds Proxmox et des VMs de l'infrastructure.

IV.5.3.1 Configuration du serveur Chrony sur PVE-01

La configuration du fichier `/etc/chrony/chrony.conf` sur PVE-01 définit les serveurs de référence amont, la plage réseau des clients autorisés et le comportement de repli local.

```
# Serveurs NTP de reference amont
pool pool.ntp.org iburst

# Autoriser les clients du reseau de management
allow 192.168.10.0/24

# Fichier de derive
driftfile /var/lib/chrony/drift

# Repli local si perte de synchronisation amont
local stratum 10
```

Figure IV.63 – Configuration du serveur Chrony sur PVE-01

Dans la Figure ??, la directive `allow 192.168.10.0/24` couvre l'ensemble des nœuds Proxmox et des clients directs du réseau de management. Les VMs hébergées sur les VLANs 172.16.60/70/80.0/24 atteignent PVE-01 via un routeur qui effectue une translation d'adresses (NAT) : leurs requêtes NTP arrivent sur PVE-01 avec l'adresse source 192.168.10.65 (interface du routeur côté management), et sont donc couvertes par la même directive `allow` sans qu'il soit nécessaire d'y ajouter les sous-réseaux VLAN. La directive `local stratum 10` garantit que PVE-01 continue à distribuer une référence temporelle cohérente en cas de perte temporaire de connectivité vers `pool.ntp.org`.

IV.5.3.2 Configuration des clients NTP

Sur chaque nœud Proxmox et sur chaque VM, le fichier `chrony.conf` client interroge PVE-01 en priorité, puis bascule vers `pool.ntp.org` si PVE-01 est indisponible.

```
# Source primaire : serveur interne PVE-01
server 192.168.10.100 iburst prefer

# Fallback : serveurs publics si PVE-01 inaccessible
pool pool.ntp.org iburst

driftfile /var/lib/chrony/drift
```

Figure IV.64 – Configuration Chrony côté clients (nœuds et VMs)

La configuration de la Figure ?? interroge PVE-01 en priorité, avec bascule automatique vers `pool.ntp.org` si PVE-01 est indisponible. À la différence des conteneurs LXC qui héritent directement de l'horloge du nœud hôte, les VMs disposent d'une horloge virtuelle indépendante et nécessitent donc une synchronisation NTP explicite.

IV.5.3.3 Déploiement via Ansible

La configuration NTP est appliquée sur les VMs via le playbook Ansible `ntp_sync.yml`. Ce playbook est exécuté à la demande, en passant l'adresse IP de la VM cible, ce qui permet d'intégrer toute nouvelle machine dans la hiérarchie de synchronisation sans intervention manuelle. Le fonctionnement détaillé de l'automatisation Ansible est traité dans la section dédiée.

IV.5.3.4 Validation de la synchronisation

La vérification du bon fonctionnement du serveur Chrony s'effectue depuis PVE-01 via deux commandes complémentaires. La première confirme la connexion aux sources NTP amont, la seconde liste les clients actifs.

```
root@pve-01:~# chronyc -n clients
```

Hostname	NTP	Drop	Int	IntL	Last	Cmd	Drop	Int	Last
192.168.10.213	27	0	6	-	20	0	0	-	-
192.168.10.114	8	0	9	-	21	0	0	-	-
192.168.10.84	26	0	6	-	61	0	0	-	-
192.168.10.65	25	0	6	-	57	0	0	-	-
192.168.10.104	7	0	7	-	39	0	0	-	-
192.168.10.112	7	0	6	-	23	0	0	-	-
192.168.10.115	6	0	7	-	12	0	0	-	-
192.168.10.111	8	0	6	-	1	0	0	-	-

FIGURE IV.65 – Sortie de `chronyc -n clients` sur PVE-01.

La Figure ?? illustre la sortie de la commande `chronyc -n clients` exécutée sur PVE-01. Les nœuds Proxmox PVE-02 (192.168.10.213) et PVE-03 (192.168.10.84) apparaissent individuellement avec leur compteur de requêtes NTP. Les VMs hébergées sur les réseaux distants (172.16.60/70/80.0/24) n'apparaissent pas directement : leurs requêtes NTP arrivent sur PVE-01 avec l'adresse source 192.168.10.65 (interface WAN d'OPNsense), car le routeur effectue une translation d'adresses (NAT) entre les VLANs internes et le réseau de management. Ce comportement est attendu et confirme que les VMs bénéficient bien de la synchronisation NTP via OPNsense.

IV.5.4 Gestion du Code Source et CI/CD : GitLab

La traçabilité du code et l'automatisation des tests constituent des pratiques essentielles dans un environnement d'infrastructure moderne. Un LXC Turnkey GitLab CE a été déployé sur le cluster pour centraliser les dépôts de code de l'infrastructure et y associer des pipelines d'intégration continue.

IV.5.4.1 Déploiement du LXC Turnkey GitLab CE

Le template Turnkey GitLab CE disponible dans le catalogue Proxmox a été utilisé pour simplifier le déploiement initial. Ce template embarque GitLab CE préconfiguré avec Nginx, PostgreSQL et les workers Sidekiq, réduisant le temps d'installation à quelques minutes.

Le conteneur LXC a été créé avec les ressources suivantes : 4 vCPUs, 8 Go de RAM et 50 Go de stockage sur le pool Ceph, permettant d'héberger confortablement les dépôts et les

artefacts de pipeline de l'infrastructure.

IV.5.4.2 Création des dépôts

Deux dépôts ont été créés dans l'instance GitLab pour couvrir les besoins de versionnement de l'infrastructure. Le dépôt **CSLB** contient le code source du service d'équilibrage de charge développé en Go, y compris les fichiers de configuration, les tests unitaires et le fichier de pipeline CI/CD. Le dépôt **ansible-infra** regroupe l'ensemble des playbooks Ansible, l'inventaire et les fichiers de secrets chiffrés avec Ansible Vault.

IV.5.4.3 Configuration des pipelines CI/CD

Un fichier `.gitlab-ci.yml` a été défini dans chaque dépôt pour automatiser les vérifications à chaque push. Pour le projet **CSLB**, le pipeline comprend les stages “Lint” (vérification syntaxique du code Go avec `golangci-lint`), “Tests” (exécution des tests unitaires avec `go test`) et “Build” (compilation du binaire). Pour le projet **ansible-infra**, le pipeline effectue une vérification syntaxique des playbooks avec `ansible-lint`.

IV.5.4.4 Validation

La validation de l'instance GitLab porte sur la présence des dépôts et sur le bon déroulement des pipelines. La Figure ?? présente la page des projets de l'instance GitLab.




FIGURE IV.66 – Page Projects de l'instance GitLab avec les dépôts de l'infrastructure.

IV.5.5 Automatisation Opérationnelle : Rundeck

La délégation de tâches opérationnelles récurrentes à une interface centralisée permet de réduire les erreurs humaines et de tracer l'ensemble des interventions sur l'infrastructure. Run-

deck, déployé dans un conteneur LXC dédié, offre une interface web permettant de déclencher des playbooks Ansible sans accès SSH direct aux nœuds.

IV.5.5.1 Déploiement du LXC Rundeck

Le conteneur LXC Rundeck a été créé sur le cluster Proxmox avec 2 vCPUs et 4 Go de RAM. Rundeck a été installé depuis les dépôts officiels et configuré pour écouter sur le port 4440.

```
apt install -y rundeck
systemctl enable rundeckd
systemctl start rundeckd
```

Figure IV.67 – Installation de Rundeck

Les commandes de la Figure ?? installent le service Rundeck, l’activent au démarrage et le démarrent immédiatement. Une fois actif, Rundeck est accessible via son interface web sur le port 4440 du conteneur LXC.

IV.5.5.2 Intégration du dépôt ansible-infra via GitLab Runner

Après le déploiement du conteneur, le dépôt `ansible-infra` a été cloné depuis l’instance GitLab locale vers `/root` sur la machine Rundeck. Un “GitLab Runner” a ensuite été enregistré sur ce conteneur et intégré au pipeline CI/CD du dépôt.

Le rôle de ce runner est de synchroniser automatiquement les playbooks à chaque push validé : le pipeline copie le contenu du dépôt vers `/opt/ansible-infra`, répertoire appartenant à l’utilisateur système `rundeck` (`chown -R rundeck:rundeck /opt/ansible-infra`). Cette configuration garantit que Rundeck dispose des permissions nécessaires pour lire et exécuter les playbooks directement depuis ce répertoire, sans manipulation manuelle des fichiers.

Les clés SSH générées précédemment pour l’utilisateur `ansible` ont été déposées dans `/opt/ansible-infra/.ssh/`, rendant ce répertoire la source unique de vérité pour à la fois les playbooks et les secrets d’authentification SSH vers les VMs gérées.

IV.5.5.3 Définition des jobs

Les jobs Rundeck ont été définis pour chaque opération récurrente de l’infrastructure. Chaque job référence le playbook Ansible correspondant dans `/opt/ansible-infra` et expose les variables nécessaires sous forme de paramètres saisissables dans l’interface web, permettant à un opérateur de déclencher une opération sans connaissance de la syntaxe Ansible.

Quatre jobs ont été configurés :

- **Provision VM** : exécute `provision_vm.yml`. Les paramètres exposés sont `vm_id`, `vm_name`, ainsi que des paramètres optionnels tels que `vm_cores`, `vm_memory` et `vm_full_clone` pour ajuster les ressources ou le mode de clonage.
- **Provision VM Batch** : exécute `provision_vm_batch.yml` pour le provisionnement en masse. Le paramètre principal est la liste des VMs à créer, passée sous forme de structure YAML.

- **Bootstrap VM** : exécute `bootstrap.yml` pour préparer une VM nouvellement créée à la gestion Ansible. Le paramètre exposé est `target_hosts`, une liste d'adresses IP ou de noms d'hôtes (séparés par des virgules), permettant de cibler aussi bien des machines de l'inventaire que des IPs brutes.
- **NTP Sync** : exécute `ntp_sync.yml` pour configurer ou resynchroniser chrony sur les nœuds. Le paramètre exposé est également `target_hosts`, permettant de cibler un sous-ensemble de nœuds du cluster.

IV.5.5.4 Validation

La validation de Rundeck porte sur la définition des jobs et sur leur exécution. La Figure ?? présente la liste des jobs de provisionnement Ansible configurés dans l'interface web. Le résultat complet d'une exécution, incluant le journal Ansible avec l'état de chaque tâche, est présenté en Annexe ??.




FIGURE IV.68 – Interface Rundeck affichant les jobs de provisionnement Ansible.

IV.6 Conclusion

Ce chapitre a présenté l'implémentation réelle de l'infrastructure hyperconvergente open source mise en place dans le cadre du projet. La couche calcul a permis de déployer Proxmox, le cluster, le monitoring, l'automatisation et les services applicatifs. La couche stockage a été assurée par Ceph avec réplication et tolérance aux pannes. Enfin, la couche réseau a été construite avec Open vSwitch, les tunnels VxLAN, OPNsense et les services d'adressage associés.

Les services complémentaires déployés dans la Partie IV (synchronisation temporelle, centralisation des journaux, notifications, versionnement du code et automatisation opérationnelle) complètent l'infrastructure en lui apportant les briques transverses indispensables à son exploi-

tation en conditions réelles.

Les différents tests réalisés ont confirmé la cohérence de l'architecture proposée et sa capacité à répondre aux objectifs du projet dans un environnement de laboratoire structuré. Le chapitre suivant présentera l'évaluation des performances obtenues ainsi qu'une analyse des résultats expérimentaux.

Conclusion générale

Ce projet est parti d'un constat simple. Pour ses environnements de test et de développement, Sonatrach avait besoin d'une infrastructure fiable, mais sans supporter le coût et la rigidité des solutions propriétaires utilisées en production. La question posée était de savoir si des technologies libres et gratuites pouvaient offrir une alternative crédible et autonome, capable de fonctionner sur du matériel déjà disponible.

Pour y répondre, nous avons conçu et mis en place une infrastructure complète, entièrement open source, sur trois serveurs fournis par l'entreprise. Cette plateforme rassemble dans un même ensemble le calcul, le stockage et le réseau, assure la continuité du service en cas de panne d'un serveur et répartit automatiquement la charge entre les machines. Elle a été complétée par des outils de supervision, de sauvegarde, d'automatisation et de sécurité, afin de former un environnement cohérent et exploitable au quotidien. Son bon fonctionnement a été vérifié par des tests, en particulier une simulation de panne qui a confirmé que le service se rétablit de lui-même, sans perte de données ni intervention manuelle.

Ce travail montre qu'un assemblage de technologies libres, bien choisies et bien intégrées, peut remplir les mêmes fonctions qu'une solution propriétaire, pour un coût d'acquisition nul et avec une maîtrise complète de l'infrastructure. Au-delà du résultat technique, le projet redonne à l'entreprise le contrôle de ses choix et réduit sa dépendance vis-à-vis des éditeurs.

La solution proposée reste néanmoins un point de départ, pensé pour un environnement de laboratoire. Plusieurs améliorations permettraient de la rapprocher d'un usage en production et d'en étendre les possibilités :

- Simplifier et automatiser l'ajout de nouveaux serveurs au cluster, de la mise sous tension jusqu'à leur intégration complète.
- Centraliser la gestion des comptes et des accès pour l'ensemble des outils de la plateforme.
- Renforcer la sécurité par une supervision plus avancée, capable de détecter les intrusions et de relier les événements entre eux.
- Diversifier les moyens de notification afin d'alerter les équipes plus rapidement en cas d'incident.
- Faire évoluer la configuration du réseau vers une gestion plus souple, une fois obtenu l'accès aux équipements de l'entreprise.

En définitive, ce projet confirme qu'une infrastructure autonome, économique et performante est aujourd'hui à la portée d'une grande entreprise grâce aux technologies open source, et ouvre la voie à un déploiement plus large au sein de Sonatrach.

Bibliographie

- [1] I. N. Sonatrach, « Historique et évolution », Institut numérique, 2012. [En ligne]. Disponible : <https://www.institut-numerique.org/2-historique-et-evolution-5028f58cb09d3>
- [2] Sonatrach, « Site officiel du Groupe Sonatrach », Sonatrach. [En ligne]. Disponible : <https://sonatrach.com/>
- [3] Sonatrach, « Organigramme de la Direction Centrale Digitalisation et Systèmes d'Information (DC DSI) », document interne, Sonatrach, 2025.
- [4] J. Schneider, S. Susnjara et I. Smalley, « Hyperconverged infrastructure explained », IBM Think, févr. 2024. [En ligne]. Disponible : <https://www.ibm.com/think/topics/hyperconverged-infrastructure>
- [5] T. Rosado et J. Bernardino, « An overview of OpenStack architecture », dans *Proceedings of the 18th International Database Engineering & Applications Symposium (IDEAS'14)*, ACM, 2014, pp. 366–367. [En ligne]. Disponible : <https://doi.org/10.1145/2628194.2628195>
- [6] A. Pande, « Proxmox vs. Harvester : Can the enterprise-grade platform beat the community favorite? », XDA Developers, févr. 2025. [En ligne]. Disponible : <https://www.xda-developers.com/proxmox-vs-harvester/>
- [7] SUSE, « Harvester HCI Documentation », Harvester HCI. [En ligne]. Disponible : <https://harvesterhci.io/>
- [8] Proxmox Server Solutions, « Proxmox Virtual Environment Overview », Proxmox. [En ligne]. Disponible : <https://www.proxmox.com/en/products/proxmox-virtual-environment/overview>
- [9] S. A. Azeem et S. K. Sharma, « Study of converged infrastructure & hyper converge infrastructure as future of data centre », *International Journal of Advanced Research in Computer Science*, vol. 8, n° 5, pp. 900–903, 2017.
- [10] Open vSwitch Authors, « What is Open vSwitch? », Documentation Open vSwitch. [En ligne]. Disponible : <https://docs.openvswitch.org/en/latest/intro/what-is-ovs/>
- [11] Open vSwitch Authors, « Features », Open vSwitch. [En ligne]. Disponible : <https://www.openvswitch.org/features/>
- [12] VMware, « VMware Distributed Resource Management : Design, Implementation, and Lessons Learned », VMware Technical Journal, mars 2012. [En ligne]. Disponible : <https://www.waldspurger.org/carl/papers/drs-vmtj-mar12.pdf>

- [13] InfluxData, « InfluxDB v2 Documentation », InfluxData. [En ligne]. Disponible : <https://docs.influxdata.com/influxdb/v2/>
- [14] TechWrix, « Containers vs VMs : Choosing the Right Approach for Your Proxmox VE », TechWrix. [En ligne]. Disponible : <https://www.techwrix.com/containers-vs-vm-choosing-the-right-approach-for-your-proxmox-ve-part-4/>
- [15] A. Chandak, K. Jaju, A. Kanfode, P. Lohiya et A. Joshi, « Dynamic Load Balancing of Virtual Machines using QEMU-KVM », *International Journal of Computer Applications*, vol. 46, n° 6, pp. 10–14, mai 2012.
- [16] J. Watts, « A practical approach to dynamic load balancing », Mémoire de master, California Institute of Technology, 1995. [En ligne]. Disponible : https://thesis.caltech.edu/6924/1/Watts_j_1995.pdf
- [17] S. C. Dake, C. Caulfield et A. Beekhof, « The Corosync cluster engine », dans *Proceedings of the Linux Symposium*, vol. 85, 2008.
- [18] Grafana Labs, « Grafana Documentation », Grafana Labs. [En ligne]. Disponible : <https://grafana.com/docs/grafana/latest/>
- [19] W. Tarreau, « HAProxy version 2.8 : configuration manuelle », HAProxy. [En ligne]. Disponible : <https://www.haproxy.org/download/2.8/doc/configuration.txt>
- [20] S. A. Weil, S. A. Brandt, E. L. Miller et D. D. Long, « Ceph : A scalable, high-performance distributed file system », dans *Proceedings of the 7th USENIX Symposium on Operating Systems Design and Implementation (OSDI'06)*, USENIX Association, 2006, pp. 307–320.
- [21] S. A. Weil, S. A. Brandt, E. L. Miller et C. Maltzahn, « CRUSH : Controlled, Scalable, Decentralized Placement of Replicated Data », dans *Proceedings of the 2007 ACM/IEEE Conference on Supercomputing (SC'07)*, ACM, 2007.
- [22] Proxmox Server Solutions, « Proxmox VE Ceph Server », Proxmox VE Wiki, 2024. [En ligne]. Disponible : https://pve.proxmox.com/wiki/Ceph_Server
- [23] T. C. Wilcox Jr., « Dynamic Load Balancing of Virtual Machines Hosted on Xen », Mémoire de master, Brigham Young University, avr. 2009. [En ligne]. Disponible : <https://scholarsarchive.byu.edu/cgi/viewcontent.cgi?article=2653&context=etd>
- [24] GitLab, « GitLab Requirements », Documentation GitLab. [En ligne]. Disponible : <https://docs.gitlab.com/install/requirements/>
- [25] C. Rajendran, *Getting Started with VMware Virtual SAN*, Packt Publishing, 2015, pp. 9–15.
- [26] KVM Authors, « Kernel-based Virtual Machine », Linux KVM. [En ligne]. Disponible : https://www.linux-kvm.org/page/Main_Page
- [27] QEMU Project, « QEMU Documentation », QEMU. [En ligne]. Disponible : <https://www.qemu.org/docs/master/>
- [28] libvirt Project, « libvirt : The virtualization API », libvirt.org. [En ligne]. Disponible : <https://libvirt.org/>
- [29] Proxmox Server Solutions, « High Availability Manager », Proxmox VE Wiki. [En ligne]. Disponible : https://pve.proxmox.com/wiki/High_Availability

- [30] M. Mahalingam et al., « Virtual eXtensible Local Area Network (VXLAN) : A Framework for Overlaying Virtualized Layer 2 Networks over Layer 3 Networks », RFC 7348, IETF, août 2014, p. 6. [En ligne]. Disponible : <https://datatracker.ietf.org/doc/html/rfc7348>
- [31] Microsoft, « Dynamic Optimization in VMM », Microsoft Learn. [En ligne]. Disponible : <https://learn.microsoft.com/en-us/system-center/vmm/>
- [32] oVirt Project, « Scheduling Policies », oVirt Documentation. [En ligne]. Disponible : <https://www.ovirt.org/documentation/>
- [33] OpenStack Foundation, « Nova Scheduler », OpenStack Documentation. [En ligne]. Disponible : <https://docs.openstack.org/nova/latest/admin/scheduling.html>
- [34] Prometheus Authors, « Prometheus Documentation », Prometheus. [En ligne]. Disponible : <https://prometheus.io/docs/>
- [35] Red Hat, « Ansible Documentation », Ansible. [En ligne]. Disponible : <https://docs.ansible.com/>
- [36] Deciso B.V., « OPNsense Documentation », OPNsense. [En ligne]. Disponible : <https://docs.opnsense.org/>
- [37] D. Mills et al., « Network Time Protocol Version 4 : Protocol and Algorithms Specification », RFC 5905, IETF, juin 2010. [En ligne]. Disponible : <https://datatracker.ietf.org/doc/html/rfc5905>

Annexe A

Dashboards Grafana de Supervision

A.1 Dashboard Infrastructure Proxmox





FIGURE A.1 – Dashboard Grafana Infrastructure : vue complète des métriques CPU, mémoire et réseau des trois nœuds Proxmox.



A.4 Règles d'Alerte Grafana Alerting




FIGURE A.4 – Liste des règles d’alerte configurées dans Grafana Alerting (page “Alerting -> Alert Rules”) avec leur état (Normal / Pending / Firing).

Annexe B

Configuration Complète des Interfaces Réseau

B.1 Configuration complète de PVE-01

```
auto lo
iface lo inet loopback

iface nic0 inet manual

auto vmbr0
iface vmbr0 inet static
    address 192.168.10.100/24
    gateway 192.168.10.36
    ovs_type OVSBridge
    ovs_ports nic0

auto nic0
iface nic0 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0

iface nic1 inet manual
iface nic2 inet manual
iface nic3 inet manual

# ===== COROSYNC VXLAN (key=20) =====
auto vxlan20-pve02
iface vxlan20-pve02 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.213 options:
        key=20

auto vxlan20-pve03
iface vxlan20-pve03 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.84 options:key
        =20

auto vxlan20-int
iface vxlan20-int inet static
    address 10.10.20.1/24
    ovs_type OVSIntPort
```

```
    ovs_bridge vmbr0

# ===== CEPH INTERNE VXLAN (key=30) =====
auto vxlan30-pve02
iface vxlan30-pve02 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.213 options:
        key=30

auto vxlan30-pve03
iface vxlan30-pve03 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.84 options:key
        =30

auto vxlan30-int
iface vxlan30-int inet static
    address 10.10.30.1/24
    ovs_type OVSIIntPort
    ovs_bridge vmbr0

# ===== CEPH PUBLIC VXLAN (key=40) =====
auto vxlan40-pve02
iface vxlan40-pve02 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.213 options:
        key=40

auto vxlan40-pve03
iface vxlan40-pve03 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.84 options:key
        =40

auto vxlan40-int
iface vxlan40-int inet static
    address 10.10.40.1/24
    ovs_type OVSIIntPort
    ovs_bridge vmbr0

# ===== MIGRATION LIVE VXLAN (key=50) =====
auto vxlan50-pve02
iface vxlan50-pve02 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.213 options:
        key=50

auto vxlan50-pve03
```

```
iface vxlan50-pve03 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.84 options:key=50

auto vxlan50-int
iface vxlan50-int inet static
    address 10.10.50.1/24
    ovs_type OVSIIntPort
    ovs_bridge vmbr0

# ===== SAUVEGARDE VXLAN (key=90) =====
auto vxlan90-pve02
iface vxlan90-pve02 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.213 options:key=90

auto vxlan90-pve03
iface vxlan90-pve03 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.84 options:key=90

auto vxlan90-int
iface vxlan90-int inet static
    address 10.10.90.1/24
    ovs_type OVSIIntPort
    ovs_bridge vmbr0

# ===== VXLAN 60 (Dev) =====
auto vxlan60-pve02
iface vxlan60-pve02 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.213 options:key=60

auto vxlan60-pve03
iface vxlan60-pve03 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.84 options:key=60

auto vxlan60-int
iface vxlan60-int inet static
    ovs_type OVSIIntPort
    ovs_bridge vmbr0
```

```
# ===== VXLAN 70 (Prod) =====
auto vxlan70-pve02
iface vxlan70-pve02 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.213 options:
        key=70

auto vxlan70-pve03
iface vxlan70-pve03 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.84 options:key
        =70

auto vxlan70-int
iface vxlan70-int inet static
    ovs_type OVSIIntPort
    ovs_bridge vmbr0

# ===== VXLAN 80 (DMZ) =====
auto vxlan80-pve02
iface vxlan80-pve02 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.213 options:
        key=80

auto vxlan80-pve03
iface vxlan80-pve03 inet manual
    ovs_type OVSPort
    ovs_bridge vmbr0
    ovs_options type=vxlan options:remote_ip=192.168.10.84 options:key
        =80

auto vxlan80-int
iface vxlan80-int inet static
    ovs_type OVSIIntPort
    ovs_bridge vmbr0

# ===== VM Bridges =====
auto vmbr60
iface vmbr60 inet manual
    bridge_ports vxlan60-int
    bridge_stp off
    bridge_fd 0

auto vmbr70
iface vmbr70 inet manual
    bridge_ports vxlan70-int
    bridge_stp off
    bridge_fd 0
```

```

auto vmbr80
iface vmbr80 inet manual
    bridge_ports vxlan80-int
    bridge_stp off
    bridge_fd 0

source /etc/network/interfaces.d/*

```

Figure B.1 – Fichier /etc/network/interfaces complet, PVE-01 (192.168.10.100)

Annexe C

Résultat d'Exécution Rundeck

bootstrap

Options:

bootstrap_password:

Zakillies

target:

172.16.60.61

Succeeded

00:21 at 1:25 pm

#49

you

Run Again

Log Output »

100% 1/1 COMPLETE

0 FAILED

0 INCOMPLETE

0 NOT STARTED

Node	Start time	Duration
localhost	1:24:51 pm	0.00:21

1. Command

OK

1:24:51 pm

0.00:21

```

01:24:53
01:24:53 PLAY [Register target(s) in memory] *****
01:24:53
01:24:53 TASK [Add each target to bootstrap group] *****
01:24:53 changed: [localhost] => (item=172.16.60.61)
01:24:53
01:24:53 PLAY [Bootstrap VM - prepare for Ansible management] *****
01:24:53
01:24:53 TASK [Wait for SSH] *****
01:24:56 ok: [172.16.60.61]
01:24:56
01:24:56 TASK [Install python3 and sudo] *****
01:25:00 changed: [172.16.60.61]
01:25:00
01:25:00 TASK [Create ansible user] *****
01:25:03 ok: [172.16.60.61]
01:25:03
01:25:03 TASK [Configure passwordless sudo for ansible user] *****
01:25:07 ok: [172.16.60.61]
01:25:07
01:25:07 TASK [Create .ssh directory for ansible user] *****
01:25:08 ok: [172.16.60.61]
01:25:08
01:25:08 TASK [Deploy SSH public key for ansible user] *****
01:25:12 changed: [172.16.60.61]
01:25:12
01:25:12 PLAY RECAP *****
01:25:12 172.16.60.61 : ok=6 changed=2 unreachable=0 failed=0 skipped=0 rescued=0
01:25:12 ignored=0
01:25:12 localhost : ok=1 changed=1 unreachable=0 failed=0 skipped=0 rescued=0
01:25:12 ignored=0
01:25:12

```

FIGURE C.1 – Résultat d'exécution du job Rundeck Bootstrap VM avec le journal Ansible complet.

Annexe D

Configuration du Pare-feu

D.1 Règles de Filtrage OPNsense




FIGURE D.1 – Règles de filtrage inter-zones dans l'interface OPNsense (Firewall -> Rules).

D.2 IPSets et Alias Proxmox

The first screenshot shows the 'IPSet' configuration page. The left sidebar lists the Datacenter (Cluster-Proxmox) and its components. The main panel shows a list of IPSets with columns for Name, IP/CIDR, and Comment. The 'cluster-nodes' IPSet is selected.

IPSet	IP/CIDR	Comment
backup-net	192.168.10.84	
ceph-cluster-net	192.168.10.213	
ceph-public-net	192.168.10.100	
cluster-nodes		
corosync-net		
management-net		
migration-net		

The second screenshot shows the 'Alias' configuration page. The left sidebar is the same. The main panel shows a list of Aliases with columns for Name, IP/CIDR, and Comment. The 'app1' alias is selected.

Alias	IP/CIDR	Comment
app1	192.168.10.112	
app2	192.168.10.114	
haproxy	192.168.10.111	
opnsense	192.168.10.65	
postgres	192.168.10.115	
pve1	192.168.10.100	
pve2	192.168.10.213	
pve3	192.168.10.84	

FIGURE D.2 – IPSets et alias configurés au niveau datacenter dans le pare-feu Proxmox.

D.3 Groupes de Sécurité Proxmox

The screenshot shows the 'Security Group' configuration page. The left sidebar lists the Datacenter (Cluster-Proxmox) and its components. The main panel shows a list of Security Groups with columns for Name, IP/CIDR, and Comment. The 'proxmox-management' group is selected.

Group	IP/CIDR	Comment
backup-traffic		
ceph-storage		
corosync-cluster		
live-migration		
proxmox-management		
vxlan-overlay		

The 'Rules' section shows a list of rules with columns for On, Type, Action, Macro, Protocol, Source, S., Destination, D.Port, and Log I.

On	Type	Action	Macro	Protocol	Source	S.	Destination	D.Port	Log I
0	☒	in	ACCEPT	udp	+dc/management...		123		nolog
1	☒	in	ACCEPT	tcp	+dc/management...		9283		nolog
2	☒	in	ACCEPT	tcp	+management-net		22		
3	☒	in	ACCEPT	tcp	+management-net		8006		
4	☒	in	ACCEPT	icmp	+management-net				

FIGURE D.3 – Groupes de sécurité configurés au niveau datacenter dans le pare-feu Proxmox.

D.4 Règles Pare-feu au Niveau Nœud




FIGURE D.4 – Règles de pare-feu configurées au niveau nœud PVE-01.

D.5 Règles Pare-feu par VM




FIGURE D.5 – Règles de pare-feu de la VM Monitoring dans l'interface Proxmox.




FIGURE D.6 – Règles de pare-feu des VMs Flask App-1 dans l'interface Proxmox.

Résumé

Ce mémoire présente la conception et le déploiement d'une infrastructure Cloud privée hyperconvergée basée exclusivement sur des technologies open source. L'objectif est d'intégrer les ressources de calcul, de stockage et de réseau au sein d'une plateforme unique offrant une gestion centralisée, une haute disponibilité et une utilisation optimale des ressources. La solution proposée s'appuie sur des outils tels que Proxmox VE, Ceph et Open vSwitch afin de construire un environnement Cloud privé performant, flexible et évolutif. Ce travail met en évidence la pertinence des solutions open source pour la mise en place d'infrastructures modernes, fiables et économiques, tout en permettant une gestion unifiée et automatisée des ressources informatiques.

Les mots clés : Cloud privé, Hyperconvergence, Open Source, Proxmox VE, Ceph, Open vSwitch, Haute disponibilité, Gestion centralisée.

Abstract

This thesis presents the design and deployment of a hyperconverged private cloud infrastructure built entirely with open-source technologies. The main objective is to combine computing, storage, and networking resources into a single platform that provides centralized management, high availability, and efficient resource utilization. The proposed solution relies on tools such as Proxmox VE, Ceph, and Open vSwitch to create a private cloud environment that is reliable, flexible, and scalable. This work demonstrates the effectiveness of open-source solutions for building modern and cost-effective infrastructures while ensuring unified and automated management of IT resources.

Keywords: Private Cloud, Hyperconvergence, Open Source, Proxmox VE, Ceph, Open vSwitch, High Availability, Centralized Management.

ملخص

تتناول هذه المذكرة تصميم ونشر بنية تحتية لسحابة خاصة فائقة التقارب بالاعتماد الكامل على تقنيات مفتوحة المصدر. يهدف هذا العمل إلى دمج موارد الحوسبة والتخزين والشبكات ضمن منصة موحدة توفر إدارة مركزية، وتوافراً عالياً، واستغلالاً أفضل للموارد. تعتمد البنية المقترحة على أدوات مثل Proxmox VE و Ceph و Open vSwitch لبناء بيئة سحابية خاصة تتميز بالأداء والمرونة وقابلية التوسع. كما يبرز هذا العمل فعالية وموثوقية الحلول مفتوحة المصدر في إنشاء بنية تحتية حديثة واقتصادية مع ضمان إدارة موحدة وآلية لموارد تكنولوجيا المعلومات.

كلمات مفتاحية: السحابة الخاصة، التقارب الفائق، البرمجيات مفتوحة المصدر، Open Ceph، VE، Proxmox، vSwitch، التوافر العالي، الإدارة المركزية.